(MATRIISI) (LASKENTA)

Aleksis Koski

3. marraskuuta 2026

Johdanto

Tämä luentomoniste käsittää matriisilaskennan perusteoriaa, alunperin tuotettuna Aalto-yliopiston kurssin *MS-A0001 Matriisilaskenta* sisältöä vastaten. Monisteen ei ole tarkoitus kattaa kaikkia matriisilaskennan aiheita yksityiskohtineen, vaan se on suunniteltu mahdollisimman lähestyttäväksi lukumateriaaliksi aiheeseen ensimmäistä kertaa tutustuvalle opiskelijalle.

Tästä syystä joidenkin todistuksien yksityiskohtia on kevennetty tai ne on sivuutettu. Teoreettisesta tarkkuudesta kiinnostunutta lukijaa kehotetaan täydentämään mahdolliset puuttuvat yksityiskohdat itse, ja osa näistä on tarkoitettu tehtäviksi kurssin laskuharjoitustilaisuuksiin. Matematiikan opiskelussa laskuharjoitusten tekemisen merkitys on hyvin tärkeä, ja tätä monistetta ei ole tarkoitettu opiskeltavaksi ilman, että ohessa osallistuu myös vastaaviin harjoitustilaisuuksiin.

Opiskelijoita kannustetaan etsimään myös vaihtoehtoista lukumateriaalia tämän monisteen lisäksi, etenkin niille, jotka haluavat syventyä aiheeseen jatkossa enemmänkin. Mikäli lukijalla on toiveita lisäysten suhteen tähän monisteeseen, tai tässä materiaalissa ilmenee virheitä, näistä otetaan yhteydenottoja lämpimästi vastaan.

Monisteessa esiintyvät suomenkieliset termit on valittu kirjoittajan mieltymyksen mukaan vastaamaan mahdollisimman paljon puhekielessä käytettäviä ilmaisuja. Joillain käsitteillä on useita eri nimiä, ja näitä on pyritty mainitsemaan myös melko kattavasti.

Luentomonisteen lopusta löytyy sanasto, jossa esitellään tässä materiaalissa käytetyt termit. Sanaston on laatinut Etna Lindy.

Sisällysluettelo

1 Vektorit ja Matriisit **5**
- Vektorit $\mathbb{R}^n$:ssä . . . 5
- Matriisit . . . 11
- Matriisit lineaarikuvauksina . . . 14
- Transpoosi . . . 20
- Bonus: Kompleksiluvut matriiseissa . . . 23

2 Aliavaruudet **25**
- Kanta . . . 27
- Matriisin ydin ja kuva . . . 28

3 Lineaariset yhtälöryhmät **30**
- Yhtälöryhmän ratkaisujoukko . . . 30
- Gaussin eliminaatio . . . 31
- Pivotit . . . 34
- Ytimen ja kuva-avaruuden määrittäminen . . . 37

4 Käänteismatriisi **39**
- Käänteismatriisi Gauss-Jordanin eliminaatiolla . . . 39
- Kääntyvyysehdot . . . 41

5 Ortogonaalisuus **46**
- Ortogonaaliset jonot . . . 46
- Ortogonaalinen projektio . . . 46
- Ortogonalisointi . . . 47
- Ortokomplementti . . . 48
- Ortogonaaliset matriisit . . . 49
- Pienimmän neliösumman ratkaisu yhtälöryhmälle . . . 50

6 Determinantti **52**

7 Ominaisarvot ja ominaisvektorit **56**
- Ominaisavaruudet . . . 59
- Diagonalisointi . . . 60
- Symmetrisen matriisin diagonalisointi . . . 62
- Matriisin normi . . . 63
- Matriisien eksponenttifunktio . . . 64
- Bonus: Kompleksisten matriisien diagonalisointi . . . 70

8 Neliömuodot **71**

9 Matriisihajotelmia **73**
- LU-hajotelma . . . 73
- Singulaariarvohajotelma . . . 76
- Pseudoinverssi . . . 80

10 Täydennyksiä **81**

11 Sanasto **84**

1. Vektorit ja Matriisit

Tässä luvussa esittelemme tämän materiaalin perusobjektit, vektorit ja matriisit, joiden käsittelyyn myöhemmät aiheet perustuvat. Tarkalleen ottaen käsittelemme tässä materiaalissa lähes yksinomaan **reaalisia** vektoreita ja matriiseja. Tämä tarkoittaa sitä, että vektorimme vastaavat n-ulotteisen reaalisen avaruuden $\mathbb{R}^n$ pisteitä, ja matriisimme näiden avaruuksien lineaarikuvauksia.

Vektorit $\mathbb{R}^n$:ssä

Vektori on matemaattinen käsite, jolla voidaan näppärästi pakata useampia lukuja yhteen objektiin. Esimerkiksi luvut $3, -5$, ja 1.5 voidaan asettaa kolmiulotteiseen vektoriin

$$\mathbf{v} = \begin{pmatrix} 3 \\ -5 \\ 1.5 \end{pmatrix}.$$

Vektorissa esiintyvillä luvuilla eli sen **komponenteilla** on järjestys, eli esim vektorit

$$\mathbf{v} = \begin{pmatrix} 3 \\ -5 \\ 1.5 \end{pmatrix} \quad \text{ja} \quad \mathbf{w} = \begin{pmatrix} -5 \\ 1.5 \\ 3 \end{pmatrix}$$

esittävät eri vektoria. Yleisessä n-ulotteisessa vektorissa on n komponenttia, eli vektorin

$$\mathbf{v} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

komponentit ovat $x_1, \ldots, x_n$, ja ne ovat tässä luentomonisteessa aina reaalilukuja $\mathbb{R}$:ssä, ellei toisin sanota. Tämä vektori $\mathbf{v}$ on tarkalleen ottaen **pystyvektori** eli **sarakevektori**. Vastaava **vaakavektori** eli **rivivektori** olisi

$$\mathbf{v}^T = \begin{pmatrix} x_1 & x_2 & \cdots & x_n \end{pmatrix}.$$

Tällä hetkellä pysty- ja vaakavektorit eroavat toisistaan ainoastaan kirjoitustavassa, mutta palaamme matriisien yhteydessä asiaan uudestaan. Tarkoitamme vektorilla tyypillisesti aina pystyvektoria.

Vektoreiden tulkintatavat

Yksi vektorin käsitteen vahvuuksista on se, että vektoria voi ajatella monella eri tavalla:

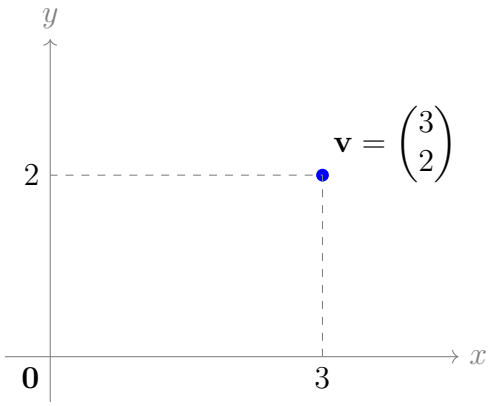
Vektori on lista: Vektoria voidaan ajatella listana informaatiota. Esimerkiksi jos tietyssä lähikaupassa on 2400 tuotetta myynnissä, niiden hinnat voisivat muodostaa 2400-ulotteisen vektorin. Tämä vektori voi olla tallennettuna kaupan tietokantaan, ja hintojen käsittely onnistuu tämän vektorin kautta.

Vektori on piste avaruudessa: Vektoria voidaan ajatella pisteenä n-ulotteisessa avaruudessa. Esimerkiksi kolmiulotteisen avaruuden jokainen piste määräytyy sen x-, y-, ja z-

koordinaatin avulla, joten jokainen kolmiulotteisen avaruuden piste (x, y, z) vastaa yhtä vektoria

$$\mathbf{v} = \begin{pmatrix} x \\ y \\ z \end{pmatrix}.$$

Tällä tavalla vektoreille voidaan antaa geometrinen merkitys, ja samalla tavalla myös yleisen n-ulotteisen avaruuden $\mathbb{R}^n$ pisteitä voidaan ajatella n-ulotteisina vektoreina (vaikka geometrinen hahmottaminen menee n:ssä ulottuvuudessa vaikeammaksi).



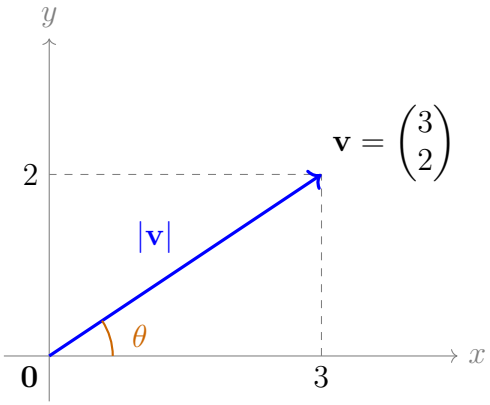
Eräs tärkeä piste $\mathbb{R}^n$:ssä on **origo**, eli piste $(0, 0, \ldots, 0)$, jonka kaikki n koordinaattia ovat nollia. Tätä vastaava pystyvektori, jossa on n nollaa, tunnetaan myös **nollavektorina**

$$\mathbf{0}_n = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix},$$

yleensä nollavektoria merkitään kuitenkin vain symbolilla $\mathbf{0}$.

Vektori on nuoli, jolla on pituus ja suunta: Etenkin fysiikassa vektorit tulkitaan usein nuolina, jotka määräytyvät niiden pituuden ja suunnan avulla. Tämä tulkintatapa voidaan samaistaa edelliseen tapaan seuraavasti. Annettuun pisteeseen $\mathbb{R}^n$:ssä voidaan piirtää nuoli origosta, ja tämän nuolen pituus ja suunta määräytyy pisteestä yksikäsitteisesti. Tämä antaa erityisesti jokaiselle $\mathbb{R}^n$:n vektorille **pituuden** eli **normin**, joka voidaan myös laskea kaavasta

$$|\mathbf{v}| = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}, \qquad \text{missä } \mathbf{v} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$



Tämä tulkintatapa antaa vektoreille lisää geometrista merkitystä, ja se auttaa monesti hahmoittamaan vektoreiden ominaisuuksia ja käsittelyä.

Vektori on matemaattinen objekti: Abstraktein tulkintatapa on ajatella vektoria $\mathbf{v}$ yksinkertaisesti matemaattisena oliona, jolla on tiettyjä ominaisuuksia ja laskutoimituksia. Tässä kontekstissa vektori voi esittää paljon yleisempää asiaa kuin äärellistä listaa lukuja. Vektorit voidaan myös esitellä abstraktimmalla tavalla kuin tässä monisteessa matemaattisten **vektoriavaruuksien** teorian kautta. Emme käsittele vektoriavaruuksia tässä materiaalissa yleisesti, mutta suosittelemme niihin tutustumista niille, jotka haluavat syventää matemaattista ymmärrystään aiheesta.

Tutustutaan seuraavaksi vektorien peruslaskutoimituksiin.

Vektoreiden laskutoimitukset

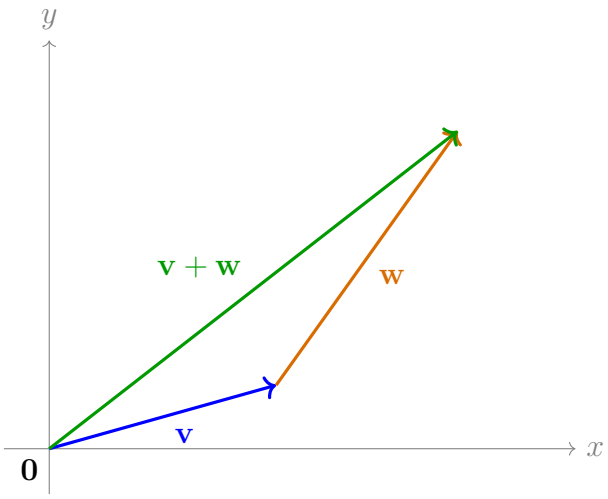
Vektoreiden hyöty matemaattisena käsitteenä ilmenee vielä paremmin erilaisten vektoreiden laskutoimitusten ja toimenpiteiden kautta.

Vektoreiden peruslaskutoimitukset ovat:

Yhteenlasku. Kaksi samankokoista vektoria v, w voidaan laskea yhteen komponenteittain:

$$\mathbf{v} + \mathbf{w} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} + \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_n + y_n \end{pmatrix}, \quad \text{missä } \mathbf{v} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \ \mathbf{w} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

Tämä voidaan tulkita geometrisesti myös seuraavan kuvan osoittamalla tavalla.



Skalaarikertolasku. Mikäli a on jokin reaaliluku (eli *skalaari*), ja $\mathbf{v}$ on vektori, voidaan vektoria $\mathbf{v}$ kertoa luvulla a seuraavasti:

$$a\mathbf{v} = a\begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} ax_1 \\ ax_2 \\ \vdots \\ ax_n \end{pmatrix}, \qquad \text{missä } \mathbf{v} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}.$$

Positiivisella skalaarilla $a > 0$ kertominen pitää vektorin suunnan samana, mutta kertoo sen pituutta luvulla a (mieti miksi). Negatiivisella skalaarilla $a < 0$ kertominen tekee melkein saman, mutta vaihtaa vektorin suunnan käänteiseksi. Vektorin kertominen nollalla $a = 0$ antaa aina nollavektorin tulokseksi.

Vektoreiden laskutoimituksilla on samanlaiset laskusäännöt kuin reaaliluvuilla, kuten

- **Symmetrisyys:** $\mathbf{v} + \mathbf{w} = \mathbf{w} + \mathbf{v}$.
- **Liitännäisyys:** $\mathbf{u} + (\mathbf{v} + \mathbf{w}) = (\mathbf{u} + \mathbf{v}) + \mathbf{w}$.
- **Osittelulaki:** $a(\mathbf{v} + \mathbf{w}) = a\mathbf{v} + a\mathbf{w}$.

Nämä peruslaskutoimitukset määrittävät avaruuden $\mathbb{R}^n$ vektoreiden rakenteen. Tähän liittyvä tärkeä käsite on **lineaarikombinaatio** (tai **lineaariyhdistely**).

Määritelmä 1.1. Kahden vektorin $\mathbf{v}, \mathbf{w}$ **lineaarikombinaatio** on mikä tahansa vektori muotoa

$$a\mathbf{v} + b\mathbf{w}, \qquad \text{missä } a, b \in \mathbb{R}.$$

Yleisemmin N vektorin $\mathbf{v}_1, \ldots, \mathbf{v}_N$ lineaarikombinaatio on mikä tahansa vektori muotoa

$$a_1\mathbf{v}_1 + a_2\mathbf{v}_2 + \cdots + a_N\mathbf{v}_N, \qquad \text{missä } a_1, \ldots, a_N \in \mathbb{R}.$$

Palaamme vektoreiden lineaarikombinaatioiden tarkempaan käsittelyyn osiossa Aliavaruudet.

Esimerkki 1.1. (Standardikanta). Avaruudessa $\mathbb{R}^n$ on hyödyllistä erotella joukosta seuraavat ns. **standardit kantavektorit**:

$$\mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad \mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{pmatrix}, \quad \cdots, \quad \mathbf{e}_n = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{pmatrix}.$$

Nämä n vektoria muodostavat $\mathbb{R}^n$:n vektoreille ns. **kannan**, eli jokainen $\mathbb{R}^n$:n vektori voidaan esittää yksikäsitteisellä tavalla näiden vektoreiden lineaarikombinaationa. Tämä on helppo tarkistaa, sillä jokaiselle vektorille $\mathbf{v}$ voidaan laskea:

$$\mathbf{v} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} x_1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} + \cdots + \begin{pmatrix} 0 \\ 0 \\ \vdots \\ x_n \end{pmatrix} = x_1 \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} + \cdots + x_n \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{pmatrix} = x_1\mathbf{e}_1 + \cdots + x_n\mathbf{e}_n.$$

Näiden kahden peruslaskutoimituksen lisäksi vektoreilla on monia muita hyödyllisiä operaatioita. Yksi tärkeimmistä on vektoreiden **pistetulo** eli **sisätulo**:

Määritelmä 1.2. Kahden vektorin **pistetulo** lasketaan kaavasta

$$\mathbf{v} \cdot \mathbf{w} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \cdot \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = x_1y_1 + x_2y_2 + \cdots + x_ny_n.$$

Pistetuloa merkitään myös $\langle \mathbf{v}, \mathbf{w} \rangle$, ja se antaa siis aina reaaliluvun tulokseksi.

Esimerkki 1.2. Vektorin pituus voidaan laskea pistetulon avulla kaavasta

$$|\mathbf{v}| = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2} = \sqrt{\mathbf{v} \cdot \mathbf{v}}.$$

Esimerkki 1.3. Eräässä kaupassa on 2400 tuotetta myynnissä. Tuotteiden hinnat ja kokonaismäärät on tallennettu vektoreihin

$$\mathbf{v}_{\text{hinnat}} = \begin{pmatrix} 1{,}99\ e \\ 5{,}99\ e \\ \vdots \\ 12{,}49\ e \end{pmatrix}, \qquad \mathbf{v}_{\text{määrät}} = \begin{pmatrix} 12\ \text{kpl} \\ 0\ \text{kpl} \\ \vdots \\ 24\ \text{kpl} \end{pmatrix}.$$

Kaupan kaikkien tuotteiden yhteenlaskettu arvo voidaan nyt laskea suoraan pistetulosta

$$\text{Kokonaisarvo} = \mathbf{v}_{\text{hinnat}} \cdot \mathbf{w}_{\text{määrät}}.$$

Toinen geometrisesti merkittävä käsite on **vektoreiden välinen kulma**. Kaksi vektoria $\mathbf{v}$ ja $\mathbf{w}$ voidaan tulkita kahtena origosta lähtevänä nuolena. Näiden nuolien välillä on jokin kulma α, joka kulkee radiaaneissa välillä $[0, \pi)$, ja jonka voi aina selvittää kaavasta

$$\mathbf{v} \cdot \mathbf{w} = |\mathbf{v}||\mathbf{w}| \cos \alpha.$$

Tarkista seuraavat ominaisuudet:

- Pistetulo on **symmetrinen**, eli pätee $\mathbf{v} \cdot \mathbf{w} = \mathbf{w} \cdot \mathbf{v}$.
- Pistetulo on **bilineaarinen**, eli jos $\mathbf{u}, \mathbf{v}, \mathbf{w}$ ovat vektoreita ja a skalaari, niin

  $$(\mathbf{u} + \mathbf{v}) \cdot \mathbf{w} = \mathbf{u} \cdot \mathbf{w} + \mathbf{v} \cdot \mathbf{w} \qquad \text{ja} \qquad (a\mathbf{v}) \cdot \mathbf{w} = a(\mathbf{v} \cdot \mathbf{w}),$$

  sekä vastaavasti

  $$\mathbf{u} \cdot (\mathbf{v} + \mathbf{w}) = \mathbf{u} \cdot \mathbf{v} + \mathbf{u} \cdot \mathbf{w} \qquad \text{ja} \qquad \mathbf{v} \cdot (a\mathbf{w}) = a(\mathbf{v} \cdot \mathbf{w}).$$

- Vektorit $\mathbf{v}, \mathbf{w}$ ovat **kohtisuorassa** eli **ortogonaaliset**, jos niiden välinen kulma on $\pi/2$. Tämä tapahtuu tasan silloin, kun $\mathbf{v} \cdot \mathbf{w} = 0$.
- Vektorit $\mathbf{v}, \mathbf{w}$ ovat samansuuntaisia tasan silloin, kun $\mathbf{v} \cdot \mathbf{w} = |\mathbf{v}||\mathbf{w}|$.
- Kahden vektorin välinen kulma ei riipu niiden pituuksista.

Ristitulo

Kolmessa ulottuvuudessa vektoreille $\mathbf{v}$ ja $\mathbf{w}$ on mahdollista määritellä myös ns. **ristitulo**

$$\mathbf{v} \times \mathbf{w} = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix} \times \begin{pmatrix} w_1 \\ w_2 \\ w_3 \end{pmatrix} = \begin{pmatrix} v_2 w_3 - v_3 w_2 \\ v_3 w_1 - v_1 w_3 \\ v_1 w_2 - v_2 w_1 \end{pmatrix},$$

joka on aina kohtisuorassa vektoreita $\mathbf{v}$ ja $\mathbf{w}$ vasten. Tutustumme ristituloon lisää luvussa Determinantti.

Matriisit

Siinä missä vektori tarjoavaa tavan asettaa useampi reaaliluku yhteen listaan, matriisi koostuu kokonaisesta taulukosta lukuja. Esimerkikki matriisista voisi olla vaikka

$$A = \begin{pmatrix} 2 & 0 & -1 \\ 5 & 2 & -5 \end{pmatrix}. \tag{1.1}$$

Tässä matriisissa on kaksi **riviä** ja kolme **saraketta**, joten sitä sanotaan 2×3-matriisiksi. Tätä merkitään $A \in \mathbb{R}^{2\times 3}$, ja lukuja $2, 3$ kutsutaan myös matriisin A **dimensioiksi** tai sen **kooksi**. Matriisissa esiintyviä lukuja sanotaan sen **alkioiksi**. Yleistä $m \times n$-matriisia voidaan merkitä

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}.$$

Tällöin matriisin A kohdassa (i, j), eli rivillä i ja sarakkeella j, löytyy alkio a_{ij}. Tätä voidaan lyhyesti merkitä myös $A = (a_{ij})$. Alkiota kohdassa (i, j) merkitään myös A_{ij}

Avaruuden $\mathbb{R}^n$ pystyvektorit ovat itse asiassa vain $n \times 1$-matriiseja, ja vaakavektorit $1 \times n$-matriiseja. Matriiseja voidaan ajatella myös listana vaaka- tai pystyvektoreita. Tutustutaan tähän esimerkin kautta:

Esimerkki 1.4. Kaavan (1.1) matriisi A voidaan tulkita myös seuraavalla kahdella eri tavalla:

Rivivektorit: Matriisi A koostuu kahdesta rivivektorista

$$\mathbf{R}_1 = \begin{pmatrix} 2 & 0 & -1 \end{pmatrix} \quad \text{ja} \quad \mathbf{R}_2 = \begin{pmatrix} 5 & 2 & -5 \end{pmatrix}.$$

Tätä voidaan merkitä myös $A = \begin{pmatrix} \mathbf{R}_1 \\ \mathbf{R}_2 \end{pmatrix}$.

Sarakevektorit: Matriisi A koostuu kolmesta sarakevektorista

$$\mathbf{S}_1 = \begin{pmatrix} 2 \\ 5 \end{pmatrix}, \quad \mathbf{S}_2 = \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \quad \text{ja} \quad \mathbf{S}_3 = \begin{pmatrix} -1 \\ -5 \end{pmatrix}.$$

Tätä voidaan merkitä myös $A = \begin{pmatrix} \mathbf{S}_1 & \mathbf{S}_2 & \mathbf{S}_3 \end{pmatrix}$.

Matriiseja voidaan myös laskea yhteen ja kertoa skalaareilla samalla tavalla kuin vektoreita (mukaanlukien laskusäännöt kuten symmetrisyys, liitännäisyys, yms.), kunhan yhteenlaskettavien matriisien dimensiot ovat samat. Esimerkiksi:

$$\begin{pmatrix} 2 & -1 \\ 0 & 2 \end{pmatrix} + \begin{pmatrix} -1 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 3 \end{pmatrix}, \qquad -2 \begin{pmatrix} 1 & 0 \\ 0 & -1 \\ -3 & 1 \end{pmatrix} = \begin{pmatrix} -2 & 0 \\ 0 & 2 \\ 6 & -2 \end{pmatrix}.$$

Matriisien yhteenlaskun suhteen tärkeä perusmatriisi on **nollamatriisi**, jonka alkiot ovat kaikki nollia. Esimerkiksi 2×3-nollamatriisi on siis

$$0_{2\times 3} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}.$$

Nollamatriisi on matriisien yhteenlaskun suhteen neutraalialkio, eli sen lisääminen ei muuta lisättävää matriisia.

Matriisien olennaisin peruslaskutoimitus on kuitenkin niiden **kertolasku**.

Matriisien kertolasku

Matriisien kertolasku on toiminto, jossa otetaan kaksi matriisia A ja B, ja muodostetaan kolmas matriisi AB. Kertolasku tapahtuu yhdistämällä jokainen **ensimmäisen matriisin A rivi** ja **toisen matriisin B sarake** seuraavasti.

Olkoon A $m \times n$-matriisi ja B $n \times k$-matriisi. Tällöin matriisitulo AB on hyvin määritelty, ja se tulee olemaan $m \times k$-matriisi. Muistisääntö tälle on seuraava:

$$(m \times n)(n \times k) \to (m \times k).$$

Olennaista on, että matriisissa A on yhtä monta saraketta, kuin B:ssä rivejä. Muuten matriisikertolaskua AB ei ole määritelty.

Uuden matriisin AB alkiot voidaan laskea yksitellen seuraavasti. Jos halutaan selvittää matriisin AB alkio kohdassa (i, j), otetaan matriisin A rivi i, matriisin B sarake j, kerrotaan vastaavat luvut keskenään, ja summataan ne yhteen. Siis esimerkiksi

$$\begin{pmatrix} 2 & 0 & 2 \\ 1 & 4 & 2 \end{pmatrix} \begin{pmatrix} 3 & 5 \\ 0 & 2 \\ 6 & 3 \end{pmatrix} = \begin{pmatrix} 18 & 16 \\ 15 & 19 \end{pmatrix}, \qquad 19 = 1 \cdot 5 + 4 \cdot 2 + 2 \cdot 3.$$

Yleisemmin, jos $A = (a_{ij})$ ja $B = (b_{ij})$, niin matriisin AB alkio kohdassa (i, j) saadaan kaavasta

$$(AB)_{ij} = a_{i1}b_{1j} + a_{i2}b_{2j} + \cdots + a_{in}b_{nj}.$$

Matriisien kertolaskun laskeminen käsin on lähinnä työlästä kirjanpitoa, mutta käsitteellisesti matriisien kertolasku avaa niiden todelliset merkitykset ja sovellukset.

Kertolaskun suhteen tärkeä perusmatriisi on **identiteettimatriisi** eli **yksikkömatriisi**. Identiteettimatriisissa on aina sama määrä rivejä ja sarakkeita, eli se on ns. **neliömatriisi**. Yleinen $n \times n$-identiteettimatriisi on muotoa

$$I_n = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix}.$$

Siis se on $n \times n$-matriisi, jonka **diagonaalilla** eli (i, i)-kohdissa olevat alkiot ovat kaikki ykkösiä, ja muut alkiot nollia. Identiteettimatriisia merkitään yleensä pelkästään symbolilla I, kun sen koko on selvä kontekstista.

Identiteettimatriisilla on se tärkeä ominaisuus, että sillä kertominen ei muuta kerrottavaa matriisia. Siis jos A on $m \times n$-matriisi, niin

$$AI_n = A \qquad \text{ja myös} \qquad I_m A = A.$$

Huom!! Matriisien kertolaskun määritelmästä on melko suoraviivaista nähdä, että **matriiseja kerrottaessa järjestyksellä on väliä**. Esimerkiksi $m \times n$-matriisin A ja $n \times k$-matriisin B tulo AB on määritelty, mutta tulo BA ei ole määritelty, ellei $m = k$. Vaikka molemmat kertolaskut olisivatkin määriteltyjä, on tyypillistä, että tulot AB ja BA antavat täysin eri tuloksen.

Lisäksi matriisien jakolaskua ei ole (yleisesti) määritelty, tosin luvussa Käänteismatriisi puhumme tästä aiheesta lisää. Yleisesti voi kuitenkin käydä esim. näin:

$$A = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix} \qquad \Rightarrow \qquad A^2 = 0, \text{ mutta } A \neq 0.$$

Myös seuraava tapaus on hyvä tiedostaa:

$$B = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \; C = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \qquad \Rightarrow \qquad B^2 = C^2, \text{ mutta } B \neq \pm C.$$

Palaamme matriisin kertolaskun eri laskusääntöihin ja ominaisuuksiin pian uudestaan. Käydään kuitenkin heti pari uutta sovellusta, joita matriisikertolasku avaa.

Esimerkki 1.5. Yliopistokurssilla opiskelijan arvostelu perustuu harjoitustehtäviin, sekä väli- ja loppukokeen tuloksiin. Opiskelijoiden arvosanat on tallennettu matriisiin

$$M_{\text{arvosanat}} = \begin{pmatrix} 0.9 & 0.85 & 0.89 \\ 0.84 & 0.77 & 0.81 \\ \vdots & \vdots & \vdots \\ 0.64 & 0.82 & 0.93 \end{pmatrix},$$

missä jokainen rivi vastaa yhtä opiskelijaa, eli sarakkeiden luvut ilmaisevat opiskelijan saaman osuuden kokonaispisteistä harjoituksissa/välikokeessa/loppukokeessa. Jos kurssiarvosanan painotukset ovat

$$\mathbf{v}_{\text{painotus}} = \begin{pmatrix} 0.3 \\ 0.2 \\ 0.5 \end{pmatrix},$$

niin jokaisen opiskelijan lopullinen suoritus saadaan laskemalla tulo

$$M_{\text{arvosanat}}\mathbf{v}_{\text{painotus}} = \begin{pmatrix} 0.9 & 0.85 & 0.89 \\ 0.84 & 0.77 & 0.81 \\ \vdots & \vdots & \vdots \\ 0.64 & 0.82 & 0.93 \end{pmatrix} \begin{pmatrix} 0.3 \\ 0.2 \\ 0.5 \end{pmatrix} = \begin{pmatrix} 0.885 \\ 0.808 \\ \vdots \\ 0.821 \end{pmatrix}.$$

Esimerkki 1.6. Mustavalkoista kuvaa, jonka resoluutio on 1024×1024 pikseliä, vastaa samankokoinen neliömatriisi, esim.

$$A = \begin{pmatrix} 0.012 & 0.013 & \cdots & 0.434 \\ 0.014 & 0.016 & \cdots & 0.442 \\ \vdots & \vdots & \ddots & \vdots \\ 0.671 & 0.677 & \cdots & 0.96 \end{pmatrix},$$

missä jokainen alkio kuvaa vastaavan pikselin kirkkautta. Tutkitaan samankokoista matriisia

$$B = \frac{1}{4}\begin{pmatrix} 3 & 1 & 0 & 0 & \cdots & 0 \\ 1 & 2 & 1 & 0 & \cdots & 0 \\ 0 & 1 & 2 & 1 & \cdots & 0 \\ 0 & 0 & 1 & 2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & 3 \end{pmatrix}.$$

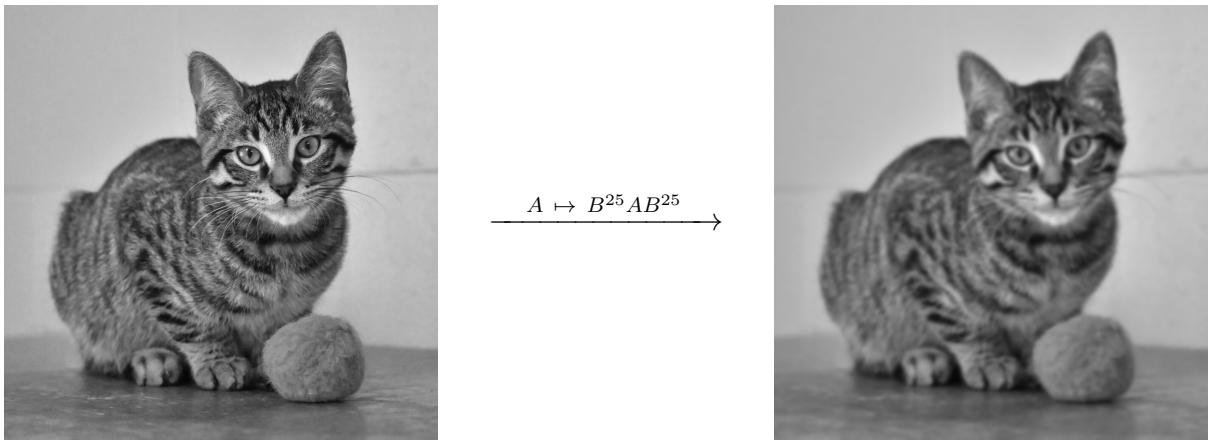
Tämän matriisin B avulla kuvaa A voidaan *sumentaa* seuraavasti. Matriisitulon $A \mapsto BA$ muodostaminen vastaa toimenpidettä, jossa jokaisen pikselin kirkkaus a_{ij} korvataan painotetulla keskiarvolla sen viereisten pikseleiden kirkkauksien kanssa:

$$a_{ij} \mapsto \frac{1}{4}(a_{(i-1)j} + 2a_{ij} + a_{(i+1)j}),$$

eli painotuksella $1:2:1$. Reunapisteitä painotetaan suhteessa $3:1$ viereiseen pikseliin.

Vastaavasti pystysuuntaan saman toimenpiteen voi toistaa kertomalla A:ta B:llä oikealta, eli $A \mapsto AB$.

Molempiin suuntiin sumentaminen onnistuu tekemällä nämä molemmat toimenpiteet, eli soveltamalla muunnosta $A \mapsto BAB$. Tätä muunnosta voidaan myös toistaa, ja sumentaa kuvaa A niin paljon kuin halutaan. Kuvassa esimerkki muunnoksen soveltamisesta 25 kertaa.



Kuva: Matriisimuunnoksen $A \mapsto BAB$ toistuva soveltaminen sumentaa kuvaa enemmän ja enemmän.

Myös monia muita kuvankäsittelytoimenpiteitä voidaan tuottaa matriisien avulla.

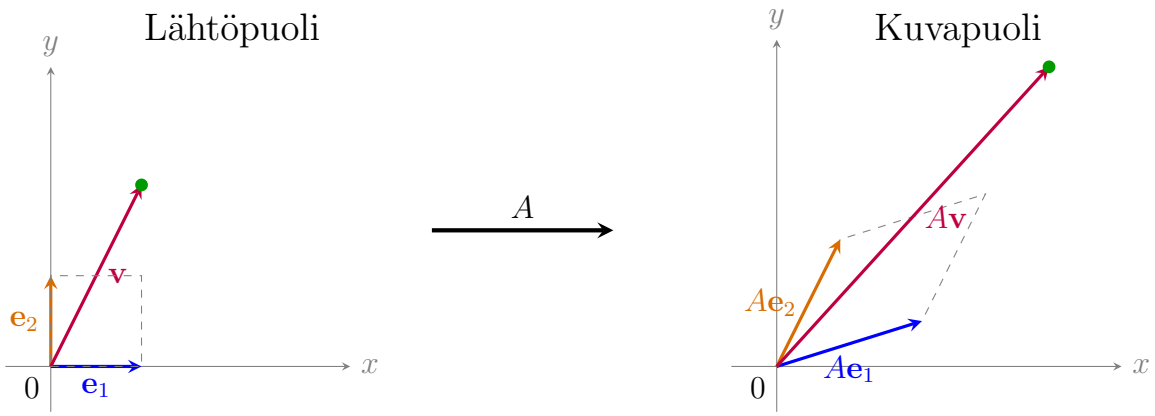
Matriisit lineaarikuvauksina

Myös matriiseja voidaan tulkita geometrisesti, ja tämä tulkinta selvenee, kun matriisilla kerrotaan vektoreita.

Olkoon A $m \times n$-matriisi, ja $\mathbf{v}$ pystyvektori $\mathbb{R}^n$:ssä, eli matriisina tulkittuna $\mathbf{v}$:n dimensiot ovat $n \times 1$. Tällöin matriisikertolasku $A\mathbf{v}$ on määritelty, ja sen dimensiot ovat $m \times 1$, eli kyseessä on m-ulotteinen pystyvektori.

Siispä $m \times n$-matriisilla A kertomista voidaan ajatella **operaationa**, joka ottaa syötteeksi n-ulotteisen vektorin, eli pisteen avaruudessa $\mathbb{R}^n$, ja tulostaa m-ulotteisen vektorin, eli pisteen $\mathbb{R}^m$:ssä. Tällöin matriisia A voidaan ajatella myös kuvauksena/funktiona

$$A : \mathbb{R}^n \to \mathbb{R}^m, \qquad \mathbf{v} \mapsto A\mathbf{v}.$$



Käytämme tässä luentomateriaalissa samaa symbolia esittämään sekä matriisia A, että sen määräämää lineaarikuvausta $A : \mathbb{R}^n \to \mathbb{R}^m$. Täsmällisesti ottaen nämä ovat kaksi eri matemaattista objektia, jotka vastaavat toisiaan luonnollisella tavalla.

Esimerkki 1.7. Lineaarisena kuvauksena tulkittuna identiteettimatriisi $I : \mathbb{R}^n \to \mathbb{R}^n$ on yksinkertaisesti avaruuden $\mathbb{R}^n$ **identiteettikuvaus**, eli kuvaus

$$I\mathbf{v} = \mathbf{v},$$

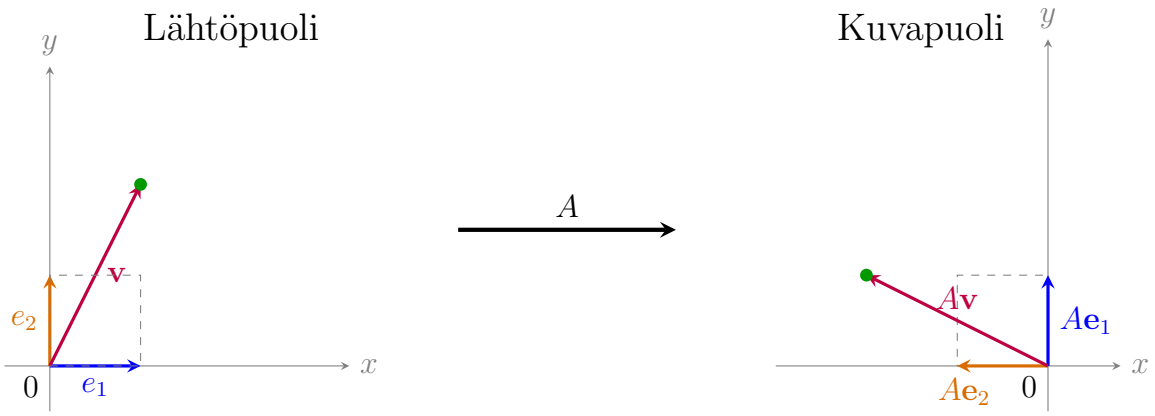
joka kuvaa jokaisen pisteen itselleen.

Esimerkki 1.8. Matriisi

$$A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$$

vastaa kuvausta tasossa, eli $A : \mathbb{R}^2 \to \mathbb{R}^2$. Tarkalleen ottaen matriisi kuvaa tason pisteen (x, y) uudelle pisteelle kaavalla

$$A \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} -y \\ x \end{pmatrix}.$$



Mitä tämä tarkoittaa geometrisesti? Kuvasta voidaan havaita, että matriisi A kiertää jokaista pistettä origon ympäri vastapäivään (eli positiiviseen suuntaan) tasan 90 astetta. Tämä voidaan myös tarkistaa laskemalla pistetulo

$$A\begin{pmatrix} x \\ y \end{pmatrix} \cdot \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} -y \\ x \end{pmatrix} \cdot \begin{pmatrix} x \\ y \end{pmatrix} = -yx + xy = 0.$$

Tällaista matriisia sanotaan **kiertomatriisiksi** tai **rotaatiomatriisiksi**, ja jokainen origokeskinen kierto tasossa annetulla kulmalla θ voidaan esittää yksikäsitteisellä tavalla 2×2-matriisina:

$$A_\theta = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}.$$

Esimerkki 1.9. Matriisi

$$A = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

Vastaa kuvausta $A : \mathbb{R}^3 \to \mathbb{R}^2$. Matriisi kuvaa kolmiulotteisen avaruuden pisteen (x, y, z) kaksiulotteisen tason pisteelle kaavalla

$$A\begin{pmatrix} x \\ y \\ z \end{pmatrix} = A = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}\begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} y \\ z \end{pmatrix}.$$

Geometrisesti tätä matriisia voi ajatella ns. **projektiona**. Se lähettää jokaisen avaruuden pisteen sen (y, z)-koordinaatteihin tasossa, eli litistää kolmiulotteisen avaruuden kahteen ulottuvuuteen.

<u>Matriisikertolaskun laskusäännöt</u>

Matriisikertolaskulla on myös monta tärkeää laskusääntöä, jotka avaavat matriisien geometrista tulkintaa vielä enemmän. Tutustutaan seuraavaksi näihin laskusääntöihin ja niiden geometrisiin tulkintoihin. Kaikki seuraavaksi esiteltävät kaavat on mahdollista todistaa oikeiksi suoraan määritelmistä pienellä työllä, mutta pidämme esityksen tiiviinä ja sivuutamme todistukset. Joitain todistuksia on esillä monisteen lopussa luvussa Täydennyksiä.

Kertolaskun liitännäislaki. Jos A on $m \times n$-matriisi, B on $n \times k$-matriisi, ja C on $k \times l$ matriisi, niin pätee

$$(AB)C = A(BC).$$

Koska sulkujen paikalla ei ole väliä, voidaan yllä olevaa tuloa merkitä yksinkertaisesti ABC. Erityisesti jos C:n paikalle laitetaan on $k \times 1$-vektori $\mathbf{v}$, niin huomataan, että

$$(AB)\mathbf{v} = A(B\mathbf{v}).$$

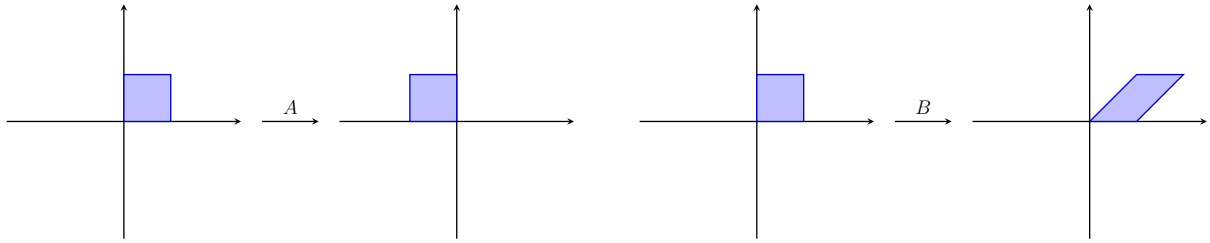
Tämä antaa myös kahden matriisin kertolaskulle **geometrisen tulkinnan:** Tulo AB vastaa yhdistettyä kuvausta $A \circ B : \mathbb{R}^k \to \mathbb{R}^m$, joka saadaan käyttämällä syötteeseen $\mathbf{v}$ ensin kuvausta $B : \mathbb{R}^k \to \mathbb{R}^n$, ja sitten tulokseen $B\mathbf{v}$ kuvausta $A : \mathbb{R}^n \to \mathbb{R}^m$.

Huom! Erityisesti yhdistetty kuvaus $A \circ B$ muodostetaan oikealta vasemmalle, eli B ensin, sitten A.

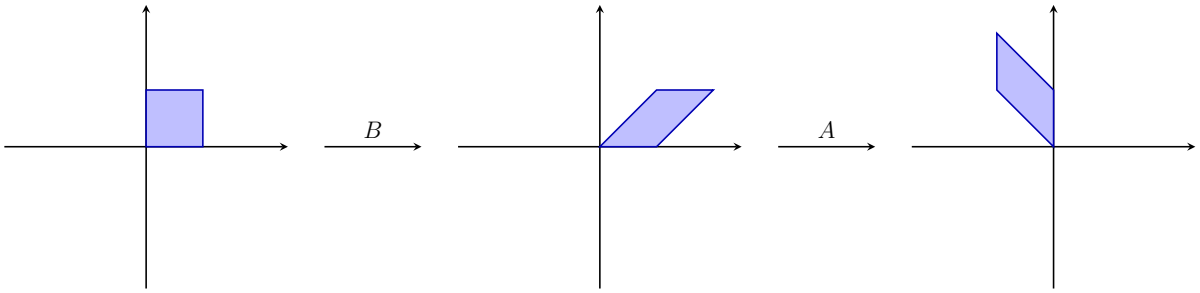
Esimerkki 1.10. Olkoon

$$A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} \qquad \text{ja} \qquad B = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}.$$

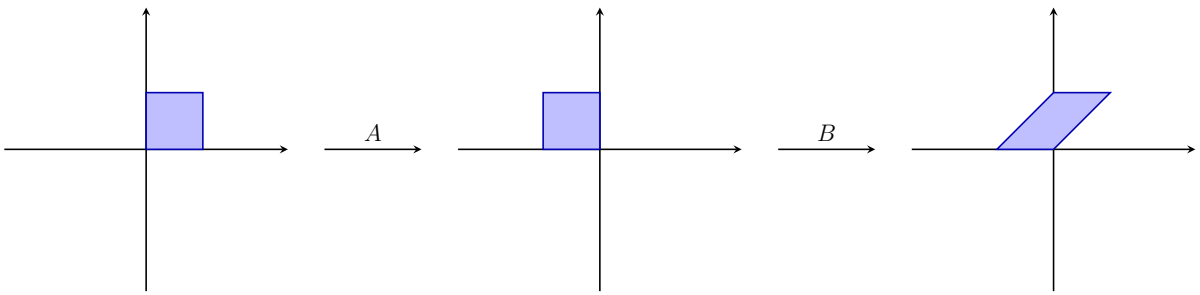
Siis A on aiemmasta esimerkistä tuttu 90 asteen kierto, ja B on kuvaus $\begin{pmatrix} x \\ y \end{pmatrix} \mapsto \begin{pmatrix} x+y \\ y \end{pmatrix}$. Nämä kuvaavat tason yksikköneliötä seuraavasti:



Tutkitaan seuraavaksi, miten kuvaukset AB ja BA kuvaavat yksikköneliön Kuvaus AB saadaan yhdistämällä kuvaukset:



Sen sijaan BA saadaan yhdistämällä kuvaukset toisessa järjestyksessä:



Tästä nähdään myös geometrisesti, että $AB \neq BA$.

Kertolaskun lineaarisuus. Mikäli A ja B ovat molemmat $m \times n$-matriiseja, ja C ja D $n \times k$-matriiseja, pätevät molemmat osittelulait

$$(A+B)C = AC + BC, \qquad \text{ja} \qquad A(C+D) = AC + AD.$$

Lisäksi jos $t \in \mathbb{R}$ on skalaari, pätee

$$A(tC) = (tA)C = t(AC).$$

Erityisesti seuraa, että matriisilla kertominen pelaa hyvin yhteen vektoreiden lineaarikombinaatioiden kanssa. Mikäli $\mathbf{v}_1, \ldots, \mathbf{v}_N$ ovat $n \times 1$-vektoreita ja $q_1, \ldots, q_N$ ovat skalaareja, niin

$$A(q_1\mathbf{v}_1 + \cdots + q_N\mathbf{v}_N) = q_1A\mathbf{v}_1 + \cdots q_NA\mathbf{v}_N.$$

Kun matriisia A ajatellaan kuvauksena $A : \mathbb{R}^n \to \mathbb{R}^m$, niin ylläoleva ominaisuus tunnetaan **linearisuutena**. Jokainen matriisi määrittelee siis lineaarisen geometrisen kuvauksen, eli **lineaarikuvauksen**.

Käänteinen väite pätee myös: Jokainen kuvaus $F : \mathbb{R}^n \to \mathbb{R}^m$, joka on lineaarinen eli toteuttaa ominaisuuden

$$F(q_1\mathbf{v}_1 + \cdots + q_N\mathbf{v}_N) = q_1F(\mathbf{v}_1) + \cdots + q_NF(\mathbf{v}_N)$$

kaikilla mahdollisilla vektoreiden v_i ja skalaarien q_i valinnoilla, määrittyy eräästä $m \times n$-matriisista $A = (a_{ij})$. (Todistus harjoituksissa)

Tarinan opetus: Matriisit voidaan tulkita geometrisesti täsmälleen lineaarisina kuvauksina $A : \mathbb{R}^n \to \mathbb{R}^m$. Tällaisiin lineaarikuvauksiin kuuluvat mm. erilaiset venytykset, kierrot, peilaukset, ja niiden yhdistelmät.

Matriisien geometrisen tulkinnan ansiosta niillä on laajasti sovelluksia tietokonegrafiikassa, robotiikassa, navigoinnissa (ilmailu, avaruus, yms.), ja monilla muilla aloilla, joissa käsitellään koordinaatteja ja niiden välisiä muunnoksia.

Lineaarikuvaukset ovat kuitenkin vain yksi tapa hyödyntää matriiseja, ja esittelemme tulevissa kappaleissa lisää matriisien ominaisuuksia sekä sovelluksia.

Affiinit kuvaukset

Yksinkertaisuudestaan huolimatta siirtokuvaus

$$\mathbf{v} \mapsto \mathbf{v} + \mathbf{b},$$

joka siirtää jokaista $\mathbb{R}^n$:n pistettä vektorilla $\mathbf{b}$, ei ole lineaarikuvaus, ellei $\mathbf{b} = \mathbf{0}$. Ilmiselvin syy tälle on se, että jokainen lineaarikuvaus kuvaa nollavektorin nollavektorille, eli $A\mathbf{0} = \mathbf{0}$ kaikille matriiseille A (tosin nollavektorin ulottuvuus saattaa muuttua). Sen sijaan siirrossa nollavektori kuvautuu vektorille $\mathbf{b}$.

Siirto on kuitenkin sen verran tavanomainen toimenpide, että on järkevää määritellä lineaarikuvauksia yleisempi luokka nimeltä **affiinikuvaukset**. Yleinen affiinikuvaus on muotoa

$$\mathbf{v} \mapsto A\mathbf{v} + \mathbf{b}$$

jollain matriisilla A ja vektorilla $\mathbf{b}$. Affiinikuvaukset laajentavat lineaarikuvauksia siis sallimalla myös siirrot. Tarkista seuraavaksi, että kahden affiinikuvauksen yhdiste on myös affiinikuvaus.

Tutkitaan seuraavaksi vielä esimerkkien kautta pari uutta tulkintaa matriisien kertolaskulle.

Esimerkki 1.11. (Markovin prosessit). Eräässä kylässä sää on päivittäin joko aurinkoista tai sateista. Seuraavan päivän sää riippuu aina edellisen päivän säästä seuraavalla tavalla:

- Jos tänään paistoi aurinko, huomenna auringonpaisteen todennäköisyys on 0.8 ja sateen 0.2.
- Jos tänään satoi, huomenna auringonpaisteen todennäköisyys on 0.4 ja sateen 0.6.

Ilmaistaan nyt päivittäinen säätilanne vektorina

$$\mathbf{p} = \begin{pmatrix} \text{auringonpaisteen todennäköisyys} \\ \text{sateen todennäköisyys} \end{pmatrix}.$$

Mikäli tänään paistaa aurinko, tiedetään, että tämän päivän todennäköisyysjakauma on

$$\mathbf{p} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

Huomisen todennäköisyysjakauma saadaan aina kertomalla muunnosmatriisilla

$$M = \begin{pmatrix} 0.8 & 0.4 \\ 0.2 & 0.6 \end{pmatrix}.$$

Eli huomisen todennäköisyysjakauma olisi

$$M\mathbf{p} = \begin{pmatrix} 0.8 & 0.4 \\ 0.2 & 0.6 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.8 \\ 0.2 \end{pmatrix}.$$

Viikon päästä jakauman voi laskea kertomalla matriisilla M seitsemän kertaa:

$$M(M(M(M(M(M(M\mathbf{p})))))) = M^7\mathbf{p} = \begin{pmatrix} 0.6672128 \\ 0.3327872 \end{pmatrix}.$$

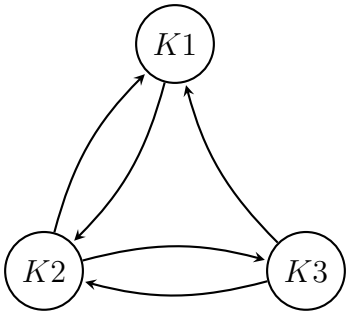
Tämän toimenpiteen toistaminen suppenee (varsin nopeasti) vektoriin $\mathbf{p}_\infty = \begin{pmatrix} 0.66... \\ 0.33... \end{pmatrix}$, joka kuvaa sitä, että kylässä satunnaisesti valittuna päivänä vuodesta todennäköisyys auringonpaisteelle on 66.6... % ja sateelle 33.3... %.

Esimerkki 1.12. (Vierusmatriisi). Erään yhtiön lentokoneet liikennöivät kolmen kaupungin välillä. Lentoratoja kuvaa ns. **vierusmatriisi**, 3×3-matriisi

$$M = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix},$$

missä matriisin alkio kohdassa (i, j) on yksi, jos kaupungista i on kaupunkiin j kulkeva lentoyhteys, ja 0 muulloin.
Tutkitaan, mitä matriisi M^2 kuvaa:

$$M^2 = MM = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 1 \\ 1 & 2 & 0 \\ 1 & 1 & 1 \end{pmatrix}.$$



Kuva: Kenttien väliset lentoradat.

Hieman tätä laskua tutkimalla huomataan, että matriisin M^2 alkioista voidaan lukea, montako yhden vaihdon reittiä löytyy kaupungista i kaupunkiin j:

Esimerkiksi kaupungista 1 pääsee kaupunkiin 3 yhdellä vaihdolla vain yhtä eri lentoreittiä pitkin – kaupungin 2 kautta. Kertolaskussa tämä ilmeni siinä, että matriisin M alkiot kohdissa $(1,2)$ ja $(2,3)$ ovat molemmat 1, ja muita vastaavia pareja rivillä 1 ja sarakkeella 3 ei ollut. Korostaen:

$$\begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 1 \\ 1 & 2 & 0 \\ 1 & 1 & 1 \end{pmatrix}, \quad \text{sillä } 1 = 0 \cdot 0 + 1 \cdot 1 + 0 \cdot 0$$

Vastaavasti kahden vaihdon lentoreittejä voi laskea matriisilla M^3, ja niin edespäin. Yleisesti ottaen matemaattisten **verkkojen** teoriaa voidaan tutkia myös matriisien avulla, ja matriisit yksinkertaistavat monen verkoissa esiintyvien suureiden laskemista.

Edellisen kahden esimerkin opetus on, että matriiseilla voidaan myös kuvata erilaisia muuttuvia systeemejä, kuten satunnaisesti muuttuvan järjestelmän kehitystä ja polkujen määriä matemaattisessa verkossa.

Transpoosi

Vielä yksi hyödyllinen matriisioperaatio on **transpoosi**, joka määritellään seuraavasti. Mikäli $A = (a_{ij})$ on $m \times n$-matriisi, niin sen transpoosi on $n \times m$-matriisi $A^T = (a_{ji})$. Käytännössä tämä näyttää tältä:

$$A = \begin{pmatrix} 3 & 2 & 0 \\ -1 & -3 & 5 \end{pmatrix} \qquad \Rightarrow \qquad A^T = \begin{pmatrix} 3 & -1 \\ 2 & -3 \\ 0 & 5 \end{pmatrix}.$$

Transpoosi siis vaihtaa rivit sarakkeiksi, ja päinvastoin. Pystyvektorin transpoosi on aina vastaava vaakavektori, ja tästä saadaan pystyvektoreiden pistetulolle myös kaava

$$\mathbf{v} \cdot \mathbf{w} = \mathbf{v}^T\mathbf{w} = \mathbf{w}^T\mathbf{v},$$

missä kaksi jälkimmäisintä lauseketta tulkitaan matriisitulona.

Neliömatriisia A sanotaan **symmetriseksi**, mikäli $A^T = A$. Siis esim. matriisi

$$A = \begin{pmatrix} 1 & 0 & 4 \\ 0 & -2 & 6 \\ 4 & 6 & 0 \end{pmatrix}$$

on symmetrinen. Transpoosin kaksi peruslaskukaavaa ovat

$$\boxed{(A+B)^T = A^T + B^T \quad \text{ja} \quad (AB)^T = B^T A^T.} \tag{1.2}$$

Lisäksi transpoosilla on tärkeä yhteys vektorien pistetuloon

$$\boxed{\mathbf{v} \cdot (A\mathbf{w}) = (A^T\mathbf{v}) \cdot \mathbf{w} \qquad \text{kaikilla vektoreilla } \mathbf{v} \in \mathbb{R}^m, \mathbf{w} \in \mathbb{R}^n.} \tag{1.3}$$

Matriisitulon rivi- ja sarakekehitelmä

Matriisituloa voidaan toisinaan yksinkertaistaa jakamalla kerrottava(t) matriisi(t) pienempiin palasiin. Yksi tärkeä esimerkki tästä on matriisin ja vektorin tulo, joka voidaan esittää näppärästi rivi- ja sarakevektoreiden avulla. Mikäli A on $m \times n$-matriisi ilmaistuna muodoissa

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix} = \begin{pmatrix} \mathbf{R}_1 \\ \mathbf{R}_2 \\ \vdots \\ \mathbf{R}_m \end{pmatrix} = \begin{pmatrix} \mathbf{S}_1 & \mathbf{S}_2 & \dots & \mathbf{S}_n \end{pmatrix},$$

niin sen tulo mielivaltaisen $n \times 1$-vektorin $\mathbf{v} = \begin{pmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_n \end{pmatrix}^T$ kanssa voidaan laskea myös kaavoista

$$\boxed{A\mathbf{v} = \begin{pmatrix} \mathbf{R}_1 \\ \mathbf{R}_2 \\ \vdots \\ \mathbf{R}_m \end{pmatrix} \mathbf{v} = \begin{pmatrix} \mathbf{R}_1\mathbf{v} \\ \mathbf{R}_2\mathbf{v} \\ \vdots \\ \mathbf{R}_m\mathbf{v} \end{pmatrix} = \begin{pmatrix} \mathbf{R}_1^T \cdot \mathbf{v} \\ \mathbf{R}_2^T \cdot \mathbf{v} \\ \vdots \\ \mathbf{R}_m^T \cdot \mathbf{v} \end{pmatrix}}$$

ja

$$\boxed{A\mathbf{v} = \begin{pmatrix} \mathbf{S}_1 & \mathbf{S}_2 & \cdots & \mathbf{S}_n \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = x_1\mathbf{S}_1 + x_2\mathbf{S}_2 + \cdots + x_n\mathbf{S}_n}$$

Vielä yleisemmin, on usein hyödyllistä jakaa matriisi pienempiin palasiin eli **lohkoihin**. Esimerkiksi 3×4-matriisi voitaisiin jakaa seuraavasti

$$A = \left(\begin{array}{c|ccc} 1 & 0 & 3 & 1 \\ \hline -2 & -1 & 6 & 5 \\ 0 & -1 & 2 & -1 \end{array}\right).$$

Lohkoihin jaettaessa matriisi pilkotaan siis pienempiin osiin, joista jokainen osa itsessään esittää matriisia. Jos kaksi matriisia A ja B on jaettu sopivan kokoisiin lohkoihin, voidaan matriisitulo laskea myös kaavalla

$$AB = \begin{pmatrix} A_1 & A_2 \\ A_3 & A_4 \end{pmatrix} \begin{pmatrix} B_1 & B_2 \\ B_3 & B_4 \end{pmatrix} = \begin{pmatrix} A_1B_1 + A_2B_3 & A_1B_2 + A_2B_4 \\ A_3B_1 + A_4B_3 & A_3B_2 + A_4B_4 \end{pmatrix},$$

mikäli kaikki tässä esiintyvät lohkojen matriisitulot ovat määriteltyjä, eli lohkot on valittu sopivan kokoisiksi, että matriisitulot onnistuvat.

Esimerkki 1.13. (Yksinkertainen hakualgoritmi). Tietokannassa on 95000 eri tietuetta. Jokaista tietuetta vastaa yksi 500×1-vektori $\mathbf{v}_i$, ja niistä muodostetaan normalisoidut vektorit $\mathbf{u}_i = \mathbf{v}_i/|\mathbf{v}_i|$. Vektori $\mathbf{u}_i$ on siis se ykkösen pituinen vektori, joka on samansuuntainen kuin vektori $\mathbf{v}_i$. Vektoreita $\mathbf{u}_i$ vastaavat vaakavektorit tallennetaan 95000×500-matriisiin

$$M = \begin{pmatrix} \mathbf{u}_1^T \\ \vdots \\ \mathbf{u}_{95000}^T \end{pmatrix}.$$

Olkoon $\mathbf{h}$ hakusana, joka on myös normalisoitu ykkösen pituiseksi 500×1-vektoriksi. Tällöin matriisitulon rivikehitelmä antaa

$$M\mathbf{h} = \begin{pmatrix} \mathbf{u}_1^T \\ \vdots \\ \mathbf{u}_{95000}^T \end{pmatrix} \mathbf{h} = \begin{pmatrix} \mathbf{u}_1 \cdot \mathbf{h} \\ \vdots \\ \mathbf{u}_{95000} \cdot \mathbf{h} \end{pmatrix}.$$

Tuloksena saadun vektorin komponentit $\mathbf{u}_i \cdot \mathbf{h}$ vastaavat vektoreiden $\mathbf{u}_i$ ja $\mathbf{h}$ välisen kulman θ_i kosinia, sillä normalisoinnin takia

$$\mathbf{u}_i \cdot \mathbf{h} = |\mathbf{u}_i||\mathbf{h}| \cos\theta_i = \cos\theta_i.$$

Mitä lähempänä tämä kosini on ykköstä, sitä lähempänä vektorit $\mathbf{u}_i$ ja $\mathbf{h}$ ovat toisiaan. Nyt jos vektorin $M\mathbf{h}$ komponentit järjestetään suuruusjärjestyksessä, niin voidaan nähdä, mitkä tietueet parhaiten vastaavat hakusanaa $\mathbf{h}$.

Tämä menetelmä on varsin alkeellinen, mutta myös hienostuneemmat hakualgoritmit käyttävät paljon matriisilaskentaa. Esimerkiksi Googlen asema suosituimpana hakukoneena pohjautuu sen 2000-luvun alussa kehittämään algoritmiin *PageRank*, joka soveltaa matriiseja vahvasti. Lisää tästä myöhemmin.

Bonus: Kompleksiluvut matriiseissa

Tässä materiaalissa keskitymme matriiseihin, joiden alkiot ovat kaikki reaalilukuja. Sekä sovelluksia, että matriisien täyttä teoriaa varten on kuitenkin tarve esitellä myös **kompleksiluvut** ja tutkia myös matriiseja, joiden alkiot ovat näitä kompleksilukuja.

Kompleksiluvut ovat jälleen yksi uusi tapa ajatella tason pisteitä. Tason pistettä (x, y) vastaa kompleksiluku

$$x + iy,$$

missä i on ns. **imaginääriyksikkö**, joka vastaa y-akselin pistettä $(0, 1)$. Kompleksiluvun $z = x + iy$ koordinaattia x kutsutaan sen **reaaliosaksi** $\mathrm{Re}(z)$ ja koordinaattia y sen **imaginääriosaksi** $\mathrm{Im}(z)$.

Kompleksiluvut elävät siis tasossa $\mathbb{R}^2$, jota kutsutaan tässä kontekstissa myös **kompleksitasoksi**, ja sitä merkitään symbolilla $\mathbb{C}$. Jokaista reaalilukua x voidaan ajatella kompleksilukuna $x + i0$, ja kompleksitasoa usein ajatellaan reaaliakselin laajennuksena.

Kompleksilukuja voi laskea yhteen samalla tavalla kuin vektoreita:

$$(x + iy) + (a + ib) = (x + a) + i(y + b).$$

Kompleksilukuja voi kuitenkin myös kertoa keskenään. Tämä tapahtuu samoilla laskusäännöillä kuin reaalilukujen kertolasku, kun asetetaan imaginääriyksikölle lisäehto $i^2 = i \cdot i = -1$. Esimerkiksi

$$(1 + 2i) \cdot (-i) = 1 \cdot (-i) + 2i \cdot (-i) = -i - 2i^2 = -i + 2.$$

Yleinen kahden kompleksiluvun tulo saadaan kaavalla

$$\begin{aligned}(x + iy)(a + ib) &= xa + x(ib) + (iy)a + (iy)(ib) \\ &= xa + i(xb + ya) + i^2yb \\ &= xa - yb + i(xb + ya).\end{aligned}$$

Kuten vektoreita, myös kompleksilukuja voi ajatella niiden **pituuden** eli **modulin**

$$|z| = |x + iy| = \sqrt{x^2 + y^2}$$

sekä suunnan avulla. Tasossa suunta määräytyy täysin kulman suhteen, joka kompleksilukuun z piirretty jana origosta muodostaa reaaliakselin suhteen. Tätä kulmaa kutsutaan kompleksiluvun **argumentiksi** ja sitä merkitään $\arg z$.

Kompleksilukujen kertolaskulla on myös yksinkertainen geometrinen tulkinta: Kahden kompleksiluvun z_1 ja z_2 kertolaskussa lukujen z_1 ja z_2 modulit kerrotaan keskenään, ja argumentit summataan. Siis

$$\boxed{|z_1 z_2| = |z_1||z_2|, \qquad \arg(z_1 z_2) = \arg z_1 + \arg z_2.}$$

Kompleksiluvun $z = x + iy$ **liittoluku** eli **kongugaatti** on

$$\overline{z} = x - iy.$$

Liittoluvun ottaminen vastaa kompleksitasossa peilausta x-akselin suhteen. Tällöin pätee myös, että $|\overline{z}| = |z|$ sekä $\arg \overline{z} = -\arg z$. Liittoluvun hyödyllinen ominaisuus on, että kompleksiluvun moduli saadaan myös kaavasta

$$|z|^2 = x^2 + y^2 = (x + iy)(x - iy) = z\overline{z}.$$

Kompleksiluvun $z = x + iy \neq 0$ käänteisluku $1/z$ voidaan laskea kaavasta

$$\frac{1}{z} = \frac{x - iy}{x^2 + y^2} = \frac{\overline{z}}{|z|^2}, \qquad \text{sillä} \qquad z\frac{1}{z} = \frac{z\overline{z}}{|z|^2} = 1.$$

Kompleksiset matriisit

Myös kompleksilukuja voi asettaa matriiseihin samaan tapaan kuin reaalilukuja. Jos A on $m \times n$-matriisi jonka alkiot ovat kompleksilukuja, merkitään $A \in \mathbb{C}^{m \times n}$. Esimerkiksi

$$A = \begin{pmatrix} 1+i & -1 & i \\ 1-2i & -i & 3i \end{pmatrix}$$

on kompleksinen 2×3-matriisi.

Kompleksimatriisien kertolasku lasketaan aivan samalla tavalla kuin reaalisten matriisien, mutta toki alkioiden välisiä kertolaskuja laskettaessa käytetään kompleksilukujen kertolaskua.

Ainoa oleellinen muutos on transpoosia laskiessa. Kompleksisten matriisien yhteydessä sovelletaan transpoosin sijaan lähes aina **konjugaattitranspoosia**. Konjugaattitranspoosissa annetun matriisin $A = (a_{ij})$ rivit ja sarakkeet vaihdetaan jälleen, mutta lisäksi jokainen alkio korvataan sen liittoluvulla. Sitä merkitään $A^* = (\overline{a_{ji}})$. Esim. yllä määritellyn matriisin A konjugaattitranspoosi on

$$A^* = \begin{pmatrix} 1-i & 1+2i \\ -1 & i \\ -i & -3i \end{pmatrix}.$$

Syy, miksi tavallinen transpoosi ei kelpaa, piilee kompleksisten vektorien pistetulossa. Kahden kompleksilukuja sisältävän vektorin pistetulo määritelläänkin kaavalla

$$\langle \mathbf{v}, \mathbf{w} \rangle = v_1\overline{w_1} + \cdots + v_n\overline{w_n}, \qquad \text{missä } \mathbf{v} = \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix}, \ \mathbf{w} = \begin{pmatrix} w_1 \\ \vdots \\ w_n \end{pmatrix}.$$

Jälkimmäisen vektorin komponenteista on otettu liittoluku, sillä tämä takaa, että pistetulosta saadaan edelleen vektorin pituus kaavalla

$$\langle \mathbf{v}, \mathbf{v} \rangle = |\mathbf{v}|^2.$$

Nyt konjugaattitranspoosille pätee aina kaava

$$\langle A\mathbf{v}, \mathbf{w} \rangle = \langle \mathbf{v}, A^*\mathbf{w} \rangle.$$

2. Aliavaruudet

Tässä luvussa vahvistamme ymmärrystä siitä, miten matriisit käyttäytyvät lineaarikuvauksina, ja mitä avaruuden osajoukkoja niiden käsittelyyn liittyy.

Aliavaruuden virittäminen

Aloitetaan esimerkkitilanteesta, jossa meillä on käytössä kaksi vektoria

$$\mathbf{v} = \begin{pmatrix} -1 \\ 0 \\ 0 \end{pmatrix} \qquad \text{ja} \qquad \mathbf{w} = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix},$$

jotka elävät siis kolmiulotteisessa avaruudessa $\mathbb{R}^3$. Näiden vektoreiden **virittämä** joukko eli **span** koostuu kaikista niiden lineaarikombinaatioista, ja sitä merkitään

$$\operatorname{span}(\mathbf{v}, \mathbf{w}) = \{a\mathbf{v} + b\mathbf{w} : a, b \in \mathbb{R}\}.$$

Koska tämä joukko varmasti sisältää myös kaikki jäsentensä lineaarikombinaatiot, on se esimerkki ns. **aliavaruudesta** eli **vektorialiavaruudesta**.

> **Määritelmä 2.1.** Avaruuden $\mathbb{R}^n$ epätyhjä osajoukko V on **aliavaruus**, mikäli kaikki sen vektoreiden $\mathbf{v}_1, \ldots, \mathbf{v}_N \in V$ lineaarikombinaatiot
>
> $$a_1\mathbf{v}_1 + a_2\mathbf{v}_2 + \cdots + a_N\mathbf{v}_N, \qquad a_1, \ldots, a_N \in \mathbb{R}$$
>
> kuuluvat edelleen osajoukkoon V.

Geometrisesti aliavaruus on aina joko suora, taso, kolmiulotteinen avaruus, tai niin edespäin. Myös triviaali aliavaruus $V = \{\mathbf{0}\}$, joka sisältää pelkän origon/nollavektorin, on tärkeä erikoistapaus. Jokaisen aliavaruuden täytyy aina sisältää nollavektori (koska yllä voidaan valita $a_1, \ldots, a_N = 0$).

Edellä annetut vektorit $\mathbf{v}, \mathbf{w}$ virittävät täsmälleen xz-tason, sillä jokainen xz-tason piste voidaan lausua muodossa

$$\begin{pmatrix} x \\ 0 \\ z \end{pmatrix} = \begin{pmatrix} -(z-x)+z \\ 0 \\ z \end{pmatrix} = (z-x)\begin{pmatrix} -1 \\ 0 \\ 0 \end{pmatrix} + z\begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = (z-x)\mathbf{v} + z\mathbf{w}.$$

Taso on kaksiulotteinen, ja käy järkeen, että kaksi vektoria $\mathbf{v}, \mathbf{w}$ virittäisivät kaksiulotteisen objektin. Tämä sääntö ei kuitenkaan päde ihan aina, sillä esimerkiksi vektorit

$$\mathbf{u} = \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix} \qquad \text{ja} \qquad \mathbf{p} = \begin{pmatrix} -2 \\ 2 \\ -2 \end{pmatrix}$$

virittävät ainoastaan suoran, sillä molemmat vektorit ovat tällä suoralla, ja toinen saadaan aina toisesta kertomalla sopivalla skalaarilla. Ongelma on, että vektorit $\mathbf{u}$ ja $\mathbf{p}$ ovat ns. **lineaarisesti riippuvia** toisistaan.

Määritelmä 2.2. Vektorit $\mathbf{v}_1, \ldots, \mathbf{v}_N$ ovat **lineaarisesti riippuvia**, mikäli löytyy sellaiset reaaliluvut $a_1, \ldots, a_N$, jotka eivät kaikki ole nollia, mutta

$$a_1\mathbf{v}_1 + \cdots + a_N\mathbf{v}_N = \mathbf{0}.$$

Muulloin sanotaan, että vektorit $\mathbf{v}_1, \ldots, \mathbf{v}_N$ ovat **lineaarisesti riippumattomia**.

Lineaarinen riippuvuus ja -riippumattomuus ovat hyvin keskeisiä käsitteitä vektoreiden ja matriisien teoriassa, ja tämä käsite tulee myöhemmin olemaan tärkeässä roolissa monissa matriisien sovelluksissa.

Yleisesti: Aina jos vektorijoukkoon lisää jonkin niiden kanssa lineaarisesti riippuvan vektorin, niin tämän vektorijoukon virittämä aliavaruus ei muutu.

Sen sijaan N kappaletta **lineaarisesti riippumattomia** vektoreita $\mathbf{v}_1, \ldots, \mathbf{v}_N$ määrittää aina aidosti N-ulotteisen aliavaruuden $\text{span}(\mathbf{v}_1, \ldots, \mathbf{v}_N)$. Eli yksi tällainen vektori määrittää aina suoran, kaksi tason, ja niin edelleen.

Esimerkki 2.1. Tutkitaan origon kautta kulkevaa suoraa kolmessa ulottuvuudessa:

$$L = \{(x, 2x, -x) : x \in \mathbb{R}\}.$$

Vektoreina esitettynä suoralla olevat pisteet ovat muotoa

$$\mathbf{v} = \begin{pmatrix} x \\ 2x \\ -x \end{pmatrix} = x \begin{pmatrix} 1 \\ 2 \\ -1 \end{pmatrix}.$$

Siis suoralla olevat pisteet saadaan skaalaamalla pystyvektoria $\mathbf{u} = \begin{pmatrix} 1 & 2 & -1 \end{pmatrix}^T$. Tästä nähdään, että $L = \text{span}(\mathbf{u})$. Tällä suoralla olevan pisteen (x, y, z) voisi määritellä myös kahdella yhtälöllä seuraavasti:

$$\begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} x \\ 2x \\ -x \end{pmatrix} \qquad \Leftrightarrow \qquad \begin{cases} y = 2x \\ z = -x \end{cases}$$

Esimerkki 2.2. Tutkitaan origon kautta kulkevaa tasoa T kolmessa ulottuvuudessa, jonka määrittää yhtälö $x + 2y - z = 0$, eli

$$T = \{(x, y, z) : x + 2y - z = 0\}.$$

Taso voidaan esittää seuraavalla tavalla kahden vektorin virittämänä aliavaruutena. Ratkaistaan tason määrittävästä yhtälöstä yksi muuttuja, esim $z = x + 2y$. Tällöin

$$\begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} x \\ y \\ x + 2y \end{pmatrix} = x \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} + y \begin{pmatrix} 0 \\ 1 \\ 2 \end{pmatrix}.$$

Siispä tason piste (x, y, z) voidaan esittää aina lineaarikombinaationa vektoreista $\mathbf{v} = \begin{pmatrix} 1 & 0 & 1 \end{pmatrix}^T$ ja $\mathbf{w} = \begin{pmatrix} 0 & 1 & 2 \end{pmatrix}^T$. Täten $T = \text{span}(\mathbf{v}, \mathbf{w})$.

Kanta

Sanotaan, että joukko vektoreita $\mathbf{v}_1, \ldots, \mathbf{v}_N$ on avaruuden $\mathbb{R}^n$ (tai jonkin sen aliavaruuden V) **kanta**, mikäli nämä vektorit ovat lineaarisesti riippumattomia ja niiden virittämä joukko $\operatorname{span}(\mathbf{v}_1, \ldots, \mathbf{v}_N)$ on koko avaruus $\mathbb{R}^n$ (tai vastaavasti annettu aliavaruus V). Mikäli kyseessä on koko avaruus $\mathbb{R}^n$, täytyy pakosti olla $N = n$.

Aiemmin totesimme jo, että standardikantavektorit $\mathbf{e}_1, \ldots, \mathbf{e}_n$ (kts. Esimerkki 1.1) määrittävät yhden kannan avaruudelle $\mathbb{R}^n$. Avaruudella (tai aliavaruudella) voi kuitenkin olla useampia kantoja. Esimerkiksi mitkä tahansa kaksi vektoria $\mathbf{v}, \mathbf{w}$ tasossa $\mathbb{R}^2$ määrittävät tason kannan, kunhan $\mathbf{v}$ ja $\mathbf{w}$ eivät ole saman- tai vastakkaissuuntaisia.

Kanta on loistava käsite aliavaruuksien rakenteen ymmärtämiseen. Emme tässä käy yksityiskohtaisia todistuksia seuraaville väitteille, mutta kehotamme lukijaa pohtimaan niitä omassa rauhassa:

- Jokaiselle aliavaruudelle voidaan löytää kanta.
- Jos aliavaruudella V on kaksi eri kantaa, on niissä kuitenkin sama määrä vektoreita. Tätä lukumäärää sanotaan aliavaruuden **dimensioksi** tai **ulottuvuudeksi** (suora = 1, taso = 2, jne.), ja sitä merkitään $\dim V$. Triviaalin aliavaruuden $\{\mathbf{0}\}$ dimensio on nolla.
- Jokaisen k-ulotteisen aliavaruuden V kantaan voidaan lisätä $n - k$ vektoria niin, että ne muodostavat yhdessä avaruuden $\mathbb{R}^n$ kannan.
- Jos vektorit $\mathbf{v}_1, \ldots, \mathbf{v}_N$ ovat lineaarisesti riippumattomia, ne muodostavat kannan virittämälleen aliavaruudelle $\operatorname{span}(\mathbf{v}_1, \ldots, \mathbf{v}_N)$.
- Jos vektorit $\mathbf{v}_1, \ldots, \mathbf{v}_N$ virittävät aliavaruuden V, niin $N \geq \dim V$. Lisäksi näistä vektoreista voidaan poistaa $N - \dim V$ kappaletta niin, että jäljelle jää jokin V:n kanta.

Esimerkki 2.3. Tutkitaan $\mathbb{R}^4$:n aliavaruutta

$$V = \{(x, y, z, a) \in \mathbb{R}^4 : x - y + 2z + 3a = 0, 2y = a\}.$$

Etsitään aliavaruudelle V kanta ja sen dimensio. Yhtälöistä saadaan yhtäpitävästi ratkaistua $a = 2y$ ja $x = y - 2z - 3a = -5y - 2z$. Siispä

$$\mathbf{v} \in V \quad \Leftrightarrow \quad \mathbf{v} = \begin{pmatrix} -5y - 2z \\ y \\ z \\ 2y \end{pmatrix} = y \begin{pmatrix} -5 \\ 1 \\ 0 \\ 2 \end{pmatrix} + z \begin{pmatrix} -2 \\ 0 \\ 1 \\ 0 \end{pmatrix}.$$

Tästä nähdään suoraan, että joukko V on kahden vektorin virittämä taso neliulotteisessa avaruudessa $\mathbb{R}^4$:

$$V = \operatorname{span}\left(\begin{pmatrix} -5 \\ 1 \\ 0 \\ 2 \end{pmatrix}, \begin{pmatrix} -2 \\ 0 \\ 1 \\ 0 \end{pmatrix} \right).$$

Nämä kaksi vektoria antavat V:lle myös kannan, sillä ne eivät ole lineaarisesti riippuvia. Aliavaruuden V dimensio on $\dim V = 2$.

Matriisin ydin ja kuva

Jokaiselle $m \times n$-matriisille A on mahdollista määritellä kaksi tärkeää joukkoa. Nämä ovat matriisin A **ydin** eli **nolla-avaruus** (eng. *kernel*)

$$\operatorname{Ker} A = \{\mathbf{v} \in \mathbb{R}^n : A\mathbf{v} = \mathbf{0}\}.$$

Ydin $\operatorname{Ker} A$ koostuu siis niistä avaruuden $\mathbb{R}^n$ vektoreista, jotka matriisi A kuvaa nollavektoriksi $\mathbb{R}^m$:ssä. Toinen tärkeä joukko on matriisin A **kuva** eli **kuva-avaruus** (eng. *image*)

$$\operatorname{Im} A = \{A\mathbf{v} \in \mathbb{R}^m : \mathbf{v} \in \mathbb{R}^n\}.$$

Kuva $\operatorname{Im} A$ siis koostuu kaikista niistä vektoreista avaruudessa $\mathbb{R}^m$, jotka saadaan jonkun vektorin $\mathbf{v} \in \mathbb{R}^n$ kuvavektorina $A\mathbf{v}$ kuvauksessa $A : \mathbb{R}^n \to \mathbb{R}^m$. Kuva-avaruus voidaan myös rakentaa seuraavasti:

Matriisin kuva-avaruus on sen sarakkeiden $A = \begin{pmatrix}\mathbf{S}_1 & \mathbf{S}_2 & \cdots & \mathbf{S}_n\end{pmatrix}$ virittämä aliavaruus $\operatorname{span}(\mathbf{S}_1, \mathbf{S}_2, \ldots, \mathbf{S}_n)$.

Tämä siksi, että matriisitulon sarakekehitelmän avulla

$$Av = \begin{pmatrix}\mathbf{S}_1 & \mathbf{S}_2 & \cdots & \mathbf{S}_n\end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = x_1\mathbf{S}_1 + x_2\mathbf{S}_2 + \cdots + x_n\mathbf{S}_n,$$

eli matriisin kertominen vektorilla $\mathbf{v} = \begin{pmatrix} x_1 & \cdots & x_n \end{pmatrix}^T$ antaa saman tuloksen, kuin jos sarakkeista ottaa lineaarikombinaation kertoimilla x_i. Tämän takia kuva-avaruutta kutsutaan myös matriisin **sarakeavaruudeksi** ja sitä merkitään joskus $\operatorname{col} A$. Vastaavasti rivivektoreiden virittämää joukkoa kutsutaan matriisin **riviavaruudeksi**, ja sitä merkitään $\operatorname{row} A$. Luonnollisesti pätee $\operatorname{row} A = \operatorname{col} A^T$.

Kuva-avaruus on siis erityisesti $\mathbb{R}^m$:n aliavaruus, ja sen ulottuvuuksien määrä tunnetaan matriisin A **asteena** (myös **säännöllisyysaste** tai **rangi**)

$$\operatorname{rank} A = \dim \operatorname{Im} A.$$

On myös varsin suoraviivaista todistaa, että matriisin ydin muodostaa aliavaruuden $\mathbb{R}^n$:ssä. (Todistus harjoituksissa)

Ytimen ja kuvan rooli selviää pian, kun tutkimme, miten lineaariset yhtälöryhmät ratkaistaan matriisien avulla. Käsitteellisesti ne auttavat myös suuresti ymmärtämään matriisien yleistä käyttäytymistä, kuten toivottavasti seuraava esimerkki hieman havainnollistaa.

Esimerkki 2.4. Tutkitaan lineaarikuvausta $A : \mathbb{R}^3 \to \mathbb{R}^2$, jonka matriisi on

$$A = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix}.$$

Tällöin A kuvaa kolmiulotteisia vektoreita kaavalla

$$A\begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix}\begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} x+z \\ y+z \end{pmatrix}.$$

Matriisin ydin $\operatorname{Ker} A$ muodostuu niistä vektoreista, joilla $x+z=0$ ja $y+z=0$. Siis yleinen ytimen vektori on muotoa

$$\begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} -z \\ -z \\ z \end{pmatrix} = z\begin{pmatrix} -1 \\ -1 \\ 1 \end{pmatrix}.$$

Täten ydin $\operatorname{Ker} A$ on yksiulotteinen suora, jonka virittää vektori $\begin{pmatrix} -1 & -1 & 1 \end{pmatrix}^T$. Vastaavasti matriisin kuva $\operatorname{Im} A$ on kaksiulotteinen, sillä jokainen tason $\mathbb{R}^2$ piste (x, y) voidaan esittää muodossa

$$\begin{pmatrix} x \\ y \end{pmatrix} = A\begin{pmatrix} x \\ y \\ 0 \end{pmatrix} = A\mathbf{v}, \qquad \text{missä} \quad \mathbf{v} = \begin{pmatrix} x \\ y \\ 0 \end{pmatrix}.$$

Siis matriisin aste on kaksi, koska sen kuva-avaruus on kaksiulotteinen taso $\mathbb{R}^2$. Matriisi A tiputtaa siis kolmiulotteisesta avaruudesta yhden ulottuvuuden pois (tämä ulottuvuus jää näkyviin sen ytimeen), ja lopputuloksena on kaksiulotteinen kuvajoukko $\operatorname{Im} A$.

Seuraavaksi vielä yksi perusesimerkki matriisien sovelluksista, tällä kertaa differentiaaliyhtälöiden numeerisessa ratkaisemisessa.

Esimerkki 2.5. (Differentiaaliyhtälön ratkaisuapproksimaatio). Harmonisen värähtelijän liikettä kuvaa lineaarinen toisen asteen differentiaaliyhtälö, kuten

$$x'' - 2x' + 3x = 0,$$

jossa ratkaistava funktio $x(t)$ kuvaa värähtelijän sijaintia. Tämän yhtälön voi ratkaista numeerisesti seuraavalla tavalla. Määritellään ensin $y = x'$, jolloin yhtälön voi esittää kahden yhtälön systeeminä

$$\begin{cases} x' = y \\ y' = -3x + 2y \end{cases}$$

Ratkaistaan yhtälö numeerisesti alkuarvolla $x(0) = x_0$ ja $x'(0) = y(0) = y_0$. Olkoon aika-askel pieni luku Δt, ja määritellään $t_n = n\Delta t$, $x_n = x(t_n)$ ja $y_n = y(t_n)$. Tällöin

$$\begin{cases} x_{n+1} \approx x_n + x'(t_n)\Delta t = x_n + y_n\Delta t \\ y_{n+1} \approx y_n + y'(t_n)\Delta t = y_n + (-3x_n + 2y_n)\Delta t \end{cases}$$

Jos $\mathbf{v}_n = \begin{pmatrix} x_n \\ y_n \end{pmatrix}$, tämä voidaan ilmaista yksinkertaisessa vektorimuodossa

$$\mathbf{v}_{n+1} = \mathbf{v}_n + \Delta t\begin{pmatrix} 0 & 1 \\ -3 & 2 \end{pmatrix}\mathbf{v}_n,$$

josta ratkaisuapproksimaatio saadaan laskettua. Samaa ideaa voidaan soveltaa myös monimutkaisempiin tapauksiin, kuten useamman muuttujan differentiaaliyhtälösysteemeihin.

---

3. Lineaariset yhtälöryhmät

Tutkitaan seuraavaa käytännön ongelmaa:

Tehtävä: Kaupassa omena maksaa **kaksi euroa**, ja banaani **yhden euron**. Haluat ostaa yhteensä **viisi hedelmää**, ja käyttää niihin **seitsemän euroa**.

Tämän tehtävän voi ratkaista kirjoittamalla se yhtälöryhmänä

$$\begin{cases} x + y = 5 \\ 2x + y = 7 \end{cases},$$

missä x ja y vastaavat omenoiden ja banaanien määrää. Tästä ratkaisu on varsin helppo löytää, mutta kiinnitetään ennemminkin huomiota siihen, että se voidaan ilmaista myös matriisitulon avulla:

$$\begin{pmatrix} 1 & 1 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 5 \\ 7 \end{pmatrix},$$

eli muodossa

$$A\mathbf{v} = \mathbf{b}, \quad \text{missä } A = \begin{pmatrix} 1 & 1 \\ 2 & 1 \end{pmatrix},\ \mathbf{v} = \begin{pmatrix} x \\ y \end{pmatrix},\ \mathbf{b} = \begin{pmatrix} 5 \\ 7 \end{pmatrix}.$$

Yleisesti ottaen, jos A on $m \times n$-matriisi, $\mathbf{b}$ on $m \times 1$-vektori, ja $\mathbf{v}$ on tuntematon $n \times 1$-vektori, niin yhtälö

$$A\mathbf{v} = \mathbf{b}$$

kuvaa yleistä lineaarista yhtälöryhmää, jossa on n tuntematonta, ja m yhtälöä.

Tämä avaa matriiseille jälleen uuden tärkeän sovelluksen. Esittelemme ensin, mitä uutta teoreettista ymmärrystä matriisit avaavat lineaarisiin yhtälöryhmiin, ja palataan sitten yhtälöryhmien ratkaisemiseen käytännössä.

Yhtälöryhmän ratkaisujoukko

Tavoitteemme on ymmärtää, milloin lineaarisella yhtälöryhmällä

$$A\mathbf{v} = \mathbf{b}$$

on ratkaisu, ja voiko ratkaisuja olla useampia. Tässä edelleen $A \in \mathbb{R}^{m \times n}$ ja $\mathbf{b} \in \mathbb{R}^m$ ovat kiinnitettyjä, ja $\mathbf{v} \in \mathbb{R}^n$ on tuntematon.

Tehdään ensin kriittinen huomio:

Yhtälöryhmällä $A\mathbf{v} = \mathbf{b}$ on ratkaisu $\mathbf{v}$ tasan silloin, kun $\mathbf{b} \in \operatorname{Im} A$.

Tämä huomio seuraa suoraan kuvan $\operatorname{Im} A$ määritelmästä, sillä vektori $\mathbf{b} \in \mathbb{R}^m$ kuuluu kuva-avaruuteen tasan silloin, kun on olemassa $\mathbf{v} \in \mathbb{R}^n$, jolle $A\mathbf{v} = \mathbf{b}$. Huomio ei välttämättä kerro vielä mitään siitä, miten yhtälöryhmä ratkaistaan käytännössä, mutta se kertoo meille esimerkiksi, että ne vektorit $\mathbf{b}$, joilla yhtälö ratkeaa, muodostavat aliavaruuden $\mathbb{R}^m$:ssä.

Esimerkiksi jos $A : \mathbb{R}^3 \to \mathbb{R}^3$ on projektio xy-tasoon, niin yhtälöryhmällä $A\mathbf{v} = \mathbf{b}$ on ratkaisu vain, jos vektori $\mathbf{b}$ on xy-tasossa.

Ratkaisujoukon rakenne

Mikäli $\mathbf{b} \in \operatorname{Im} A$, täytyy yhtälöryhmällä $A\mathbf{v} = \mathbf{b}$ olla siis ainakin yksi ratkaisu $\mathbf{v}$. Mutta voiko näitä ratkaisuja olla useampi, ja millaisen joukon kaikki mahdolliset ratkaisut muodostavat?

Tehdään ensin seuraava päättely: Olkoon $\mathbf{v}_1$ ja $\mathbf{v}_2$ kaksi ratkaisua. Tällöin

$$A(\mathbf{v}_1 - \mathbf{v}_2) = A\mathbf{v}_1 - A\mathbf{v}_2 = \mathbf{b} - \mathbf{b} = \mathbf{0}.$$

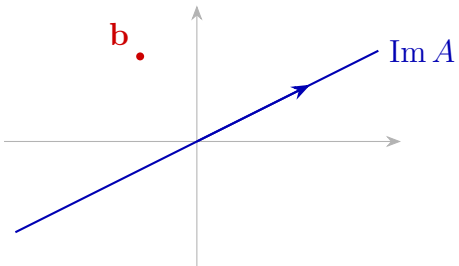
Siispä erotus $\mathbf{v}_1 - \mathbf{v}_2$ kuuluu määritelmän mukaan matriisin A ytimeen $\operatorname{Ker} A$. Vastaavasti jos $\mathbf{v}$ on yhtälön $A\mathbf{v} = \mathbf{b}$ ratkaisu ja $\mathbf{w} \in \operatorname{Ker} A$, niin $\mathbf{v} + \mathbf{w}$ on myös ratkaisu:

$$A(\mathbf{v} + \mathbf{w}) = A\mathbf{v} + A\mathbf{w} = \mathbf{b} + \mathbf{0} = \mathbf{b}.$$

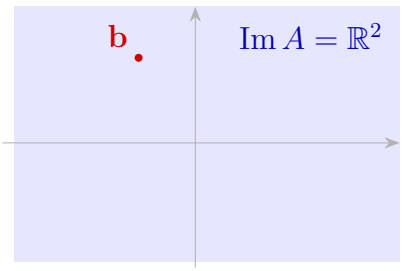
Siispä matriisin ydin paljastaa ratkaisujoukon rakenteen: Mikäli yhtälöryhmällä $A\mathbf{v} = \mathbf{b}$ on yksi ratkaisu $\mathbf{v}$, niin kaikkien ratkaisujen joukko saadaan siirtämällä aliavaruutta $\operatorname{Ker} A$ vektorilla $\mathbf{v}$.

Tämän pohdinnan lopputulos on, että yhtälöryhmän $A\mathbf{v} = \mathbf{b}$ ratkeavuudelle on oleellisesti kolme eri tapausta:

- **Tapaus 1:** Yhtälöllä ei ole ratkaisua, koska $\mathbf{b}$ ei kuulu kuvaan $\operatorname{Im} A$.
- **Tapaus 2a:** Yhtälöllä on ratkaisu $\mathbf{v}$, ja $\mathbf{v}$ on yksikäsitteinen, sillä $\operatorname{Ker} A = \{\mathbf{0}\}$ on triviaali aliavaruus.
- **Tapaus 2b:** Yhtälöllä on ratkaisu $\mathbf{v}$, ja $\operatorname{Ker} A \neq \{\mathbf{0}\}$. Tällöin kaikki ratkaisut muodostavan äärettömän joukon (suora, taso, jne.), joka on samanulotteinen kuin $\operatorname{Ker} A$.



Ei ratkaisua,
$\mathbf{b} \notin \operatorname{Im} A$



Ratkaisuja löytyy

Gaussin eliminaatio

Haluaisimme seuraavaksi löytää menetelmän ratkaista lineaarisia yhtälöryhmiä, joka tepsii kaikkiin kolmeen yllä johdettuun tapaukseen. Tätä varten on olemassa kätevä, mutta varsin mekaaninen algoritmi nimeltä **Gaussin eliminaatio**.

Gaussin eliminaatio perustuu seuraavaan kahteen huomioon:

- Yhtälöryhmän ratkaisu ei muutu, jos sen kaksi riviä vaihtaa keskenään paikkaa. Esim. yhtälöryhmillä

$$\begin{cases} x + y = 1 \\ 3x - 2y = 8 \end{cases} \quad \text{ja} \quad \begin{cases} 3x - 2y = 8 \\ x + y = 1 \end{cases} \quad \text{on samat ratkaisut.}$$

- Yhtälöryhmän ratkaisu ei muutu, jos sen riviin i lisää jonkin toisen rivin j kerrottuna jollain reaaliluvulla. Esim. yhtälöryhmillä

$$\begin{cases} x + y = 1 \\ 3x - 2y = 8 \end{cases} \quad \downarrow \times 2 \qquad \text{ja} \qquad \begin{cases} x + y = 1 \\ 5x = 10 \end{cases} \qquad \text{on samat ratkaisut.}$$

Jälkimmäinen huomio voidaan perustella sillä, että toisesta yhtälöryhmästä päästään aina takaisin edelliseen vähentämällä rivistä i rivi j samalla kertoimella. Näitä kahta toimenpidettä sanotaan **rivioperaatioiksi**.

Huom! Nämä huomiot voi myös perustella täsmällisesti matriiseilla. Kahdessa äskeisessä esimerkissä tehdyt rivioperaatiot voi myös toteuttaa kertomalla vasen yhtälöryhmä puolittain matriisilla

$$\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} \qquad \text{tai} \qquad \begin{pmatrix} 1 & 0 \\ 2 & 1 \end{pmatrix}.$$

Tarkista, että näin todellakin on.

Gaussin eliminaatio perustuu edellä esitettyjen rivioperaatioiden toistamiseen, kunnes yhtälöryhmä on helposti ratkaistavassa muodossa. Havainnollistetaan algoritmia esimerkillä. Ratkaistaan yhtälöryhmä

$$\begin{pmatrix} 2 & 4 & -2 \\ 4 & 9 & -3 \\ -2 & -3 & 7 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 2 \\ 8 \\ 10 \end{pmatrix}.$$

Kirjoitetaan yhtälöryhmä hieman tiiviimmässä muodossa:

$$\left(\begin{array}{ccc|c} 2 & 4 & -2 & 2 \\ 4 & 9 & -3 & 8 \\ -2 & -3 & 7 & 10 \end{array}\right)$$

Nyt sovelletaan rivioperaatioita, ja eliminoidaan ensimmäisestä sarakkeesta kaikki luvut ensimmäisen luvun alapuolelta seuraavasti:

$$\left(\begin{array}{ccc|c} 2 & 4 & -2 & 2 \\ 4 & 9 & -3 & 8 \\ -2 & -3 & 7 & 10 \end{array}\right) \begin{array}{l} \\ \leftarrow -2 \cdot (\text{Rivi } 1) \\ \leftarrow 1 \cdot (\text{Rivi } 1) \end{array} \quad \Rightarrow \quad \left(\begin{array}{ccc|c} 2 & 4 & -2 & 2 \\ 0 & 1 & 1 & 4 \\ 0 & 1 & 5 & 12 \end{array}\right)$$

Sitten eliminoidaan toisesta sarakkeesta kaikki toisen luvun alapuolelta käyttämällä toista riviä:

$$\left(\begin{array}{ccc|c} 2 & 4 & -2 & 2 \\ 0 & 1 & 1 & 4 \\ 0 & 1 & 5 & 12 \end{array}\right) \begin{array}{l} \\ \\ \leftarrow -1 \cdot (\text{Rivi } 2) \end{array} \quad \Rightarrow \quad \left(\begin{array}{ccc|c} 2 & 4 & -2 & 2 \\ 0 & 1 & 1 & 4 \\ 0 & 0 & 4 & 8 \end{array}\right)$$

Yhtälöryhmä on nyt saatu haluttuun muotoon:

$$\left(\begin{array}{ccc|c} \boxed{2} & 4 & -2 & 2 \\ 0 & \boxed{1} & 1 & 4 \\ 0 & 0 & \boxed{4} & 8 \end{array}\right)$$

Tätä sanotaan **porrasmuodoksi**. Yhtälöryhmä on porrasmuodossa, kun:

- Nollarivit (jos niitä on) ovat alimpina.
- Muiden rivien ensimmäinen nollasta poikkeava alkio (ns. **pivot**) on edellisen rivin pivotin oikealla puolella.
- Jokaisen pivotin alapuolella on pelkkiä nollia.

Porrasmuodosta ratkaisu on helppo löytää aloittaen viimeisestä yhtälöstä

$$4z = 8 \quad \Rightarrow \quad z = 2.$$

Tämä voidaan sijoittaa toiseen yhtälöön, ja saadaan

$$y + z = 4 \quad \Rightarrow \quad y = 2.$$

Lopulta ensimmäisestä yhtälöstä saadaan

$$2x + 4y - 2z = 2 \quad \Rightarrow \quad x = 1.$$

Tämä algoritmi tepsii myös tapauksiin, joissa ratkaisuja ei löydy, tai löytyy äärettömästi. Käydään lisää esimerkkitapauksia vielä läpi.

Esimerkki 3.1. Ratkaistaan yhtälöryhmä

$$\left(\begin{array}{ccc|c} 1 & 2 & 1 & 10 \\ 1 & -1 & 2 & 8 \\ 2 & 1 & 3 & 16 \end{array}\right)$$

Ensimmäinen eliminaatio antaa

$$\left(\begin{array}{ccc|c} 1 & 2 & 1 & 10 \\ 1 & -1 & 2 & 8 \\ 2 & 1 & 3 & 16 \end{array}\right) \begin{array}{l} \\ \leftarrow -1 \cdot (\text{Rivi } 1) \\ \leftarrow -2 \cdot (\text{Rivi } 1) \end{array} \quad \Rightarrow \quad \left(\begin{array}{ccc|c} 1 & 2 & 1 & 10 \\ 0 & -3 & 1 & -2 \\ 0 & -3 & 1 & -4 \end{array}\right)$$

Toinen antaa

$$\left(\begin{array}{ccc|c} 1 & 2 & 1 & 10 \\ 0 & -3 & 1 & -2 \\ 0 & -3 & 1 & -4 \end{array}\right) \begin{array}{l} \\ \\ \leftarrow -1 \cdot (\text{Rivi } 2) \end{array} \quad \Rightarrow \quad \left(\begin{array}{ccc|c} 1 & 2 & 1 & 10 \\ 0 & -3 & 1 & -2 \\ 0 & 0 & 0 & -2 \end{array}\right)$$

Yhtälöryhmä on nyt porrasmuodossa, mutta viimeisessä yhtälössä lukee $0 = -2$. Yhtälöllä ei siis ole ratkaisua.

Esimerkki 3.2. Ratkaistaan yhtälöryhmä

$$\left(\begin{array}{cc|c} 1 & -1 & 2 \\ -2 & 2 & -4 \end{array}\right)$$

Eliminaatio antaa ensimmäisellä askeleella suoraan porrasmuodon

$$\left(\begin{array}{cc|c} 1 & -1 & 2 \\ 0 & 0 & 0 \end{array}\right)$$

Jälkimmäinen yhtälö ei anna mitään ehtoa muuttujalle y, joten y on vapaa parametri. Sen sijaan ensimmäinen yhtälö antaa muuttujalle x ehdon $x = 2+y$, joten yleinen ratkaisu on muotoa

$$\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 2+y \\ y \end{pmatrix}.$$

Esimerkki 3.3. Edellisissä tapauksissa rivien vaihtaminen keskenään ei ollut tarpeellista. Tämä kuitenkin tulee välillä tarpeeseen, esimerkiksi yhtälöryhmässä

$$\left(\begin{array}{ccc|c} 0 & -1 & 1 & 2 \\ 2 & 1 & -1 & 2 \end{array}\right)$$

Tässä edellinen tapa aloittaa ei toimi, koska ensimmäisen rivin ensimmäinen alkio on 0, eli ensimmäisellä rivillä ei voi eliminoida alemman rivin ensimmäistä alkiota. Siis vaihdetaan rivit keskenään, ja saadaan porrasmuodossa oleva yhtälöryhmä:

$$\left(\begin{array}{ccc|c} 2 & 1 & -1 & 2 \\ 0 & -1 & 1 & 2 \end{array}\right)$$

Tämä on kolmen muuttujan (esim. x, y, z) yhtälöryhmä, jossa kolmatta yhtälöä ei ole. Siis viimeiselle muuttujalle z ei tule ehtoa, joten se on vapaa parametri. Lisäksi saadaan

$$y = z - 2 \quad \text{ja} \quad 2x + y - z = 2 \;\Rightarrow\; x = 2.$$

Siis ratkaisu on

$$\begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 2 \\ z - 2 \\ z \end{pmatrix}.$$

Pivotit

Gaussin eliminaation päättyessä yhtälöryhmä $A\mathbf{v} = \mathbf{b}$ on palautunut muotoon kuten

$$\left(\begin{array}{cccc|c} 3 & -2 & 0 & 6 & 2 \\ 0 & 0 & -1 & 3 & -7 \\ 0 & 0 & 0 & 4 & 0 \end{array}\right)$$

Yllä eroteltuja johtavia alkioita sanotaan siis **pivoteiksi**. Pivotien sijainneista voidaan päätellä suoraan, miltä yhtälöryhmän ratkaisu näyttää.

Tapaus 1: Yhtälöryhmällä ei ole ratkaisua tasan silloin, kun pivotien alapuolelle jää jokin rivi, jossa vasemmalla on pelkkiä nollia ja oikealla on nollasta poikkeava luku. Siis kuten Esimerkissä 3.1.

Mikäli näin ei tapahdu, yhtälö ratkeaa, ja tapauksia on taas kaksi:

Tapaus 2a: Yhtälöryhmällä on yksikäsitteinen ratkaisu tasan silloin, kun jokaisella sarakkeella on yksi pivot. Tällöin pivotit asettuvat kaikki diagonaalille. Siis esimerkiksi:

$$\left(\begin{array}{ccc|c} 1 & 0 & 4 & 2 \\ 0 & -5 & 1 & -3 \\ 0 & 0 & 6 & 12 \end{array}\right)$$

Tapaus 2b: Yhtälöryhmällä on äärettömän monta ratkaisua silloin, kun jollain sarakkeella ei ole pivotia. Tällöin näitä sarakkeita vastaavat muuttujat ovat **vapaita muuttujia**, ja pivotien sarakkeita vastaavat muuttujat ovat ratkaistavia **pivotmuuttujia**. Esim.

$$\left(\begin{array}{ccccc|c} 1 & 4 & -1 & 0 & 2 & 0 \\ 0 & 0 & 2 & 5 & -2 & 1 \\ 0 & 0 & 0 & 4 & -1 & 2 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{array}\right)$$

Tässä yhtälöryhmässä on 5 saraketta, eli 5 muuttujaa (esim. x, y, z, a, b). Toinen ja viimeinen (eli y, b) ovat vapaita, ja muut (eli x, z, a) ovat pivotmuuttujia.

Vapaiden muuttujien lukumäärä kertoo ratkaisuavaruuden ulottuvuuksien määrän, mikä on sama kuin yhtälöryhmän matriisin A ytimen $\operatorname{Ker} A$ dimensio.

Pivotmuuttujien lukumäärä taas kertoo, kuinka monta vapausastetta kuva-avaruudessa on, eli matriisin A asteen $\operatorname{rank} A$. Koska pivotmuuttujien ja vapaiden muuttujien määrä on yhteensä sarakkeiden lkm, voimme päätellä seuraavan tuloksen.

Lause 3.1. *Olkoon A $m \times n$-matriisi. Tällöin*

$$\dim \operatorname{Ker} A + \operatorname{rank} A = n.$$

Tämä tulos tunnetaan **Rank-Nullity lauseena**. Lause antaa teoreettisen merkityksen seuraavalle intuitiiviselle kaavalle:

$$\underbrace{\text{Lähtoavaruuden dimensio}}_{n} - \underbrace{\text{Hävitetyt dimensiot}}_{\dim \operatorname{Ker} A} = \underbrace{\text{Kuva-avaruuden dimensio}}_{\operatorname{rank} A}.$$

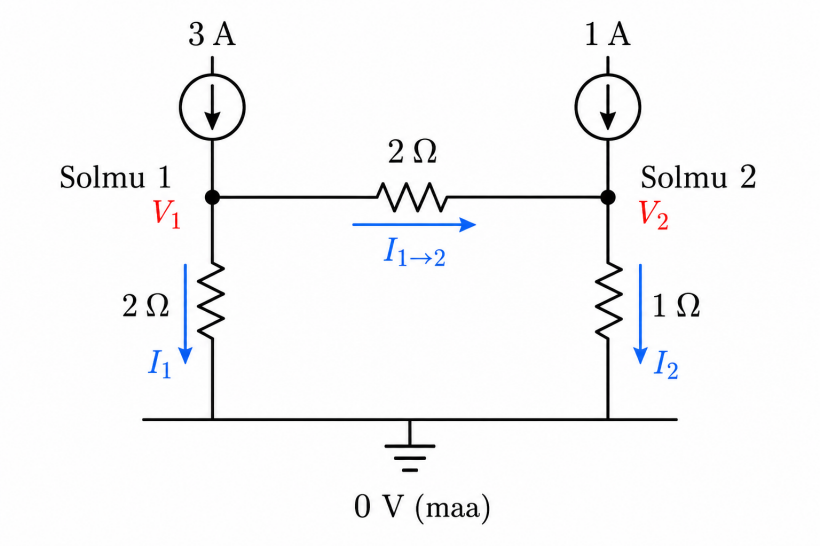
Siis esimerkiksi matriisille, jonka ydin on triviaali aliavaruus $\operatorname{Ker} A = \{0\}$, kuva-avaruuden $\operatorname{Im} A$ dimensio on sama kuin lähtöavaruuden. Tällaista matriisia sanotaan **täysasteiseksi**.

Tutkitaan seuraavaksi tilanteita, joissa lineaariset yhtälöryhmät tulevat esiin sovelluksissa.

Esimerkki 3.4. Virtapiirissä on kaksi solmua, Solmu 1 ja 2.

- Solmuun 1 virtaa kolmen ampeerin sähkövirta.
- Solmuun 2 virtaa yhden ampeerin sähkövirta.
- Solmu 1 on yhdistetty maahan kahden ohmin vastuksella.
- Solmut 1 ja 2 on yhdistetty toisiinsa kahden ohmin vastuksella.
- Solmu 2 on yhdistetty maahan yhden ohmin vastuksella.

Halutaan selvittää jännitteet Solmuissa 1 ja 2, olkoon nämä V_1 ja V_2. Sovitaan, että maaperän jännite on 0. Kuvaan on merkitty myös vastusten läpi menevät virrat I_1, I_2, ja $I_{1\to 2}$.



Ohmin lain mukaan

$$I = \frac{V}{R},$$

missä I kuvaa vastuksen virtaa, V kuvaa jännitteen erotusta vastuksen päissä, ja R on resistanssi.

- Koska Solmuun 1 virtaa kolmen ampeerin virta, siitä lähtevien vastuksien virta antaa kaavan:
$$3 = I_1 + I_{1\to 2} = \frac{V_1}{2} + \frac{V_1 - V_2}{2}.$$
- Koska Solmuun 2 virtaa yhden ampeerin virta, siitä lähtevien vastuksien virta antaa kaavan:
$$1 = I_1 + I_{2\to 1} = \frac{V_2}{1} + \frac{V_2 - V_1}{2}.$$
Huom! $I_{2\to 1} = -I_{1\to 2}$, sillä sähkövirran suunta on vastakkainen.

Tästä saadaan yhtälöryhmä

$$\begin{cases} 2V_1 - V_2 = 6 \\ -V_1 + 3V_2 = 2 \end{cases}.$$

Siis virtapiirin jännitteitä voidaan kuvata lineaarisena yhtälöryhmänä.

Esimerkki 3.5. Yksinkertaistetussa GPS-paikannuksessa neljä satelliittia lentää avaruudessa. Olkoon niiden sijannit nykyhetkellä

$$\mathbf{s}_1 = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, \quad \mathbf{s}_2 = \begin{pmatrix} 0 \\ 2 \\ -1 \end{pmatrix}, \quad \mathbf{s}_3 = \begin{pmatrix} 3 \\ 5 \\ -2 \end{pmatrix}, \quad \text{ja} \quad \mathbf{s}_4 = \begin{pmatrix} -1 \\ 0 \\ 7 \end{pmatrix}.$$

Henkilön sijainti on kolmiulotteinen tuntematon vektori $\mathbf{p} = \begin{pmatrix} x & y & z \end{pmatrix}^T$. Henkilön GPS-paikannin vastaanottaa signaalin kaikilta satelliiteiltä, ja päättelee tästä etäisyydet jokaiseen

satelliittiin. Olkoon nämä etäisyydet $5, 3, 4$, ja 3. Tästä saadaan yhtälöt

$$\begin{aligned} x^2 + y^2 + z^2 &= 25 \\ x^2 + (y-2)^2 + (z+1)^2 &= 9 \\ (x-3)^2 + (y-5)^2 + (z+2)^2 &= 16 \\ (x+1)^2 + y^2 + (z-7)^2 &= 9. \end{aligned}$$

Nämä eivät toki muodosta lähtökohtaisesti lineaarista yhtälöryhmää. Mutta vähentämällä ensimmäinen yhtälö muista saadaan lineaariset yhtälöt

$$\begin{aligned} -4y + 2z &= -21 \\ -6x - 10y + 4z &= -47 \\ 2x - 14z &= -66, \end{aligned}$$

joista voidaan ratkaista sijainti $\mathbf{p}$. Todellisuudessa GPS-paikannuksessa pitää ottaa mukaan mittaushäiriöt sekä sijainnissa, että ajassa, sekä estää tilanteet, joissa kaikki satelliitit ovat samassa osassa taivasta. Tämän takia GPS-paikannuksessa sovelletaan paljon suurempaa määrää satelliitteja, jolloin yhtälöitä on enemmän kuin muuttujia. Tällaiselle yhtälöryhmälle ei välttämättä löydy tarkkaa ratkaisua, mutta esimerkiksi ns. pienimmän neliösumman ratkaisuapproksimaatio voidaan etsiä. Lisää tästä osiossa Ortogonaalisuus.

Ytimen ja kuva-avaruuden määrittäminen

Gaussin eliminaatiota voi soveltaa monella tapaa määrittämään matriisin ominaisuuksia. Edellä totesimme jo, että pivotien lukumäärästä voi päätellä matriisin asteen, ja tätä kautta myös esimerkiksi matriisin ytimen ulottuvuuden. Tutkimme seuraavaksi paria muuta konkreettista sovellusta.

Ytimen selvittäminen. Matriisin A ytimeen $\operatorname{Ker} A$ kuuluu kaikki ne vektorit $\mathbf{v}$, jotka toteuttavat yhtälön

$$A\mathbf{v} = \mathbf{0}.$$

Tämä yhtälöryhmä voidaan toki myös ratkaista Gaussin eliminaatiolla. Erityisesti, koska rivioperaatiot eivät vaikuta yhtälön ratkaisujoukkoon, voidaan päätellä, että *rivioperaatiot eivät vaikuta matriisin ytimeen.* Siis esimerkiksi 3×3-matriisin ydin voidaan laskea Gaussin eliminaatiolla:

$$\begin{pmatrix} 3 & -1 & 1 \\ -9 & 2 & -2 \\ 9 & -4 & 4 \end{pmatrix} \xrightarrow{\text{Gaussin eliminaatio}} \begin{pmatrix} 3 & -1 & 1 \\ 0 & -1 & 1 \\ 0 & 0 & 0 \end{pmatrix}$$

Tästä voidaan päätellä, että vasemmalla olevan matriisin ydin on sama kuin oikealla puolella olevan, eli vektori $\begin{pmatrix} x & y & z \end{pmatrix}^T$ on ytimessä kunhan

$$\begin{cases} 3x - y + z = 0 \\ -y + z = 0 \end{cases} \quad \Rightarrow \quad \begin{cases} 3x = 0 \\ y = z \end{cases} \quad \Rightarrow \quad \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 0 \\ y \\ y \end{pmatrix} = y \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix},$$

eli ydin on suora, jonka virittää vektori $\begin{pmatrix} 0 & 1 & 1 \end{pmatrix}^T$.

Kuva-avaruuden selvittäminen. Myös kuva-avaruus voidaan selvittää kahdella eri tavalla Gaussin eliminaatiolla. Jos halutaan etsiä kuva-avaruudelle kantavektorit, niin riittää huomata, että *rivioperaatiot eivät vaikuta matriisin riviavaruuteen.* Erityisesti kuva-avaruus $\operatorname{Im} A$, joka on myös matrisin sarakeavaruus, voidaan laskea transpoosin riviavaruutena:

$$\operatorname{Im} A = \operatorname{col} A = \operatorname{row} A^T.$$

Tehdään tämä käytännössä edellisen esimerkin matriisille:

$$A^T = \begin{pmatrix} 3 & -9 & 9 \\ -1 & 2 & -4 \\ 1 & -2 & 4 \end{pmatrix} \xrightarrow{\text{Gaussin eliminaatio}} \begin{pmatrix} 3 & -9 & 9 \\ 0 & -1 & -1 \\ 0 & 0 & 0 \end{pmatrix}$$

Kuva avaruuden yksi mahdollinen kanta saadaan siis esimerkiksi vektoreista

$$\mathbf{v} = \begin{pmatrix} 3 \\ -9 \\ 9 \end{pmatrix} \qquad \text{ja} \qquad \mathbf{w} = \begin{pmatrix} 0 \\ -1 \\ -1 \end{pmatrix}.$$

Toinen tapa määrittää kuva-avaruus on ratkaista yleinen kaava vektoreille $\mathbf{b}$, joilla yhtälö $A\mathbf{v} = \mathbf{b}$ ratkeaa. Tämä hoituu myös Gaussin eliminaatiolla, pitämällä vektorin $\mathbf{b}$ komponentit mukana oikealla puolella eliminaatiossa:

$$\left(\begin{array}{ccc|c} 3 & -1 & 1 & b_1 \\ -9 & 2 & -2 & b_2 \\ 9 & -4 & 4 & b_3 \end{array}\right) \xrightarrow{\text{Gaussin eliminaatio}} \left(\begin{array}{ccc|c} 3 & -1 & 1 & b_1 \\ 0 & -1 & 1 & b_2 + 3b_1 \\ 0 & 0 & 0 & b_3 - 6b_1 - b_2 \end{array}\right)$$

Tästä nähdään, että yhtälö ratkeaa tasan silloin, kun $b_3 - 6b_1 - b_2 = 0$. Tämän yhtälön määräämä taso on siis matriisin A kuva-avaruus, ja yllä määritetyt vektorit $\mathbf{v}, \mathbf{w}$ ovat eräs sen kanta.

Esimerkki 3.6. Olkoon

$$\mathbf{v} = \begin{pmatrix} 1 \\ 0 \\ 2 \\ -1 \end{pmatrix}, \quad \mathbf{w} = \begin{pmatrix} -1 \\ 2 \\ 1 \\ 1 \end{pmatrix}, \quad \text{ja} \quad \mathbf{b} = \begin{pmatrix} 4 \\ 2 \\ 0 \\ 1 \end{pmatrix}.$$

Halutaan selvittää, onko $\mathbf{b}$ vektoreiden $\mathbf{v}$ ja $\mathbf{w}$ virittämässä aliavaruudessa $\operatorname{span}(\mathbf{v}, \mathbf{w})$. Tästä saadaan lineaarinen yhtälöryhmä:

$$x\mathbf{v} + y\mathbf{w} = \mathbf{b} \quad \Leftrightarrow \quad \begin{pmatrix} 1 & -1 \\ 0 & 2 \\ 2 & 1 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 4 \\ 2 \\ 0 \\ -4 \end{pmatrix}.$$

Gaussin eliminaatiosta saadaan:

$$\left(\begin{array}{cc|c} 1 & -1 & 4 \\ 0 & 2 & 2 \\ 2 & 1 & 0 \\ -1 & 1 & -4 \end{array}\right) \xrightarrow{\text{Gaussin eliminaatio}} \left(\begin{array}{cc|c} 1 & -1 & 4 \\ 0 & 2 & 2 \\ 0 & 0 & -11 \\ 0 & 0 & 0 \end{array}\right)$$

Kolmas rivi on ristiriitainen nollarivi, joten yhtälöllä ei ole ratkaisua. Vektori $\mathbf{b}$ ei siis kuulu aliavaruuteen $\operatorname{span}(\mathbf{v}, \mathbf{w})$.

4. Käänteismatriisi

Olkoon A neliömatriisi, eli $n \times n$-matriisi jollain n. Tällöin on mahdollista, että A:lla on olemassa **käänteismatriisi** A^{-1}, mikäli löytyy sellainen $n \times n$-matriisi A^{-1}, jolle pätee

$$A^{-1}A = I = AA^{-1}.$$

Käänteismatriisilla kertominen molemmilta puolilta siis antaa samankokoisen identiteettimatriisin tulokseksi. Tällöin sanotaan, että matriisi A on **kääntyvä** tai **säännöllinen**.

Huom! Osoittautuu, että jos A ja B ovat neliömatriiseja ja joko $AB = I$ tai $BA = I$, niin välttämättä $B = A^{-1}$. Siis käänteismatriisin ehto täytyy tarkistaa vain toiseen suuntaan. Perustelun tälle voi päätellä myöhemmin, kun esittelemme eri ehtoja kääntyvyydelle.

Lineaarikuvauksena tulkittuna $A^{-1} : \mathbb{R}^n \to \mathbb{R}^n$ on kuvauksen A **käänteiskuvaus**, mikäli sellainen löytyy.

Käänteismatriisi ja yhtälöryhmät

Jos käänteismatriisi A^{-1} sattuu olemaan tiedossa, niin mikä tahansa yhtälöryhmä

$$A\mathbf{v} = \mathbf{b}, \qquad \text{missä } \mathbf{v} \text{ ja } \mathbf{b} \text{ ovat molemmat } n \times 1\text{-vektoreita,}$$

on varsin helppo ratkaista. Kerrotaan yhtälö molemmin puolin matriisilla A^{-1}, ja saadaan

$$\begin{aligned} A^{-1}A\mathbf{v} &= A^{-1}\mathbf{b} \quad \Leftrightarrow \\ I\mathbf{v} &= A^{-1}\mathbf{b} \quad \Leftrightarrow \\ \mathbf{v} &= A^{-1}\mathbf{b}. \end{aligned}$$

Tämä huomio pätee myös toiseen suuntaan. Mikäli yhtälöryhmällä $A\mathbf{v} = \mathbf{b}$ on jokaisella $\mathbf{b} \in \mathbb{R}^n$ olemassa yksikäsitteinen ratkaisu $\mathbf{v_b} \in \mathbb{R}^n$, on matriisin A pakko olla kääntyvä. Tarkka perustelu tälle voidaan löytää osoittamalla, että kuvaus $\mathbf{b} \mapsto \mathbf{v_b}$ määrittelee lineaarikuvauksen, jonka täytyy vastata A:n käänteismatriisia (pohdi miksi). On kuitenkin myös toinen tapa päätellä sama asia, ja tämä antaa myös tavan laskea käänteismatriisi käytännössä.

Käänteismatriisi Gauss-Jordanin eliminaatiolla

Myös käänteismatriisin määrittämiseen voidaan soveltaa Gaussin eliminaatiota, tosin menetelmää täytyy yleistää hieman. Tämän yleistyksen nimi on **Gauss-Jordanin menetelmä**. Otetaan esimerkiksi matriisi:

$$A = \begin{pmatrix} 1 & 3 & -2 \\ 0 & 4 & 1 \\ -2 & -2 & 3 \end{pmatrix}.$$

Käänteismatriisin muodostamista varten kirjoitetaan matriisi A vierekkäin identiteettimatriisin kanssa:

$$\left(\begin{array}{ccc|ccc} 1 & 3 & -2 & 1 & 0 & 0 \\ 0 & 4 & 1 & 0 & 1 & 0 \\ -2 & -2 & 3 & 0 & 0 & 1 \end{array}\right)$$

Gaussin eliminaation jälkeen tämä saadaan porrasmuotoon

$$\left(\begin{array}{ccc|ccc} 1 & 3 & -2 & 1 & 0 & 0 \\ 0 & 4 & 1 & 0 & 1 & 0 \\ 0 & 0 & -2 & 2 & -1 & 1 \end{array}\right)$$

Haluamme tästä kuitenkin vielä jatkaa eliminointia, kunnes vasemmalle puolelle jää vain identiteettimatriisi. Tämä saavutetaan ensin kertomalla rivejä sopivilla luvuilla, että pivotien paikalle saadaan ykköset:

$$\left(\begin{array}{ccc|ccc} 1 & 3 & -2 & 1 & 0 & 0 \\ 0 & 4 & 1 & 0 & 1 & 0 \\ 0 & 0 & -2 & 2 & -1 & 1 \end{array}\right) \begin{array}{l} \\ \\ \leftarrow \times\frac{-1}{2} \end{array} \quad \Rightarrow \quad \left(\begin{array}{ccc|ccc} 1 & 3 & -2 & 1 & 0 & 0 \\ 0 & 1 & \frac{1}{4} & 0 & \frac{1}{4} & 0 \\ 0 & 0 & 1 & -1 & \frac{1}{2} & -\frac{1}{2} \end{array}\right)$$

Sitten alempien rivien pivoteja käytetään eliminoimaan ylemmiltä riveiltä nollasta poikkeavat alkiot pivotin oikealla puolella:

$$\begin{array}{ll} & \left(\begin{array}{ccc|ccc} 1 & 3 & -2 & 1 & 0 & 0 \\ 0 & 1 & \frac{1}{4} & 0 & \frac{1}{4} & 0 \\ 0 & 0 & 1 & -1 & \frac{1}{2} & -\frac{1}{2} \end{array}\right) \leftarrow (-3) \times (\text{Rivi } 2) \\ \Rightarrow & \left(\begin{array}{ccc|ccc} 1 & 0 & -\frac{11}{4} & 1 & -\frac{3}{4} & 0 \\ 0 & 1 & \frac{1}{4} & 0 & \frac{1}{4} & 0 \\ 0 & 0 & 1 & -1 & \frac{1}{2} & -\frac{1}{2} \end{array}\right) \begin{array}{l} \leftarrow \frac{11}{4} \times (\text{Rivi } 3) \\ \leftarrow \frac{-1}{4} \times (\text{Rivi } 3) \\ \\ \end{array} \\ \Rightarrow & \left(\begin{array}{ccc|ccc} 1 & 0 & 0 & -\frac{7}{4} & \frac{5}{8} & -\frac{11}{8} \\ 0 & 1 & 0 & \frac{1}{4} & \frac{1}{8} & \frac{1}{8} \\ 0 & 0 & 1 & -1 & \frac{1}{2} & -\frac{1}{2} \end{array}\right) \end{array}$$

Lopulta vasemmalle jää 3×3-identiteettimatriisi, ja oikealla puolella oleva matriisi on alkuperäisen matriisin A käänteismatriisi

$$A^{-1} = \begin{pmatrix} -\frac{7}{4} & \frac{5}{8} & -\frac{11}{8} \\ \frac{1}{4} & \frac{1}{8} & \frac{1}{8} \\ -1 & \frac{1}{2} & -\frac{1}{2} \end{pmatrix}.$$

Perustelu miksi tämä toimii on varsin yksinkertainen: Olkoon $\mathbf{v}$ jokin vektori, ja määritellään $\mathbf{b} = A\mathbf{v}$. Jokainen Gauss-Jordanin rivioperaatio vastaa samaa, kuin yhtälöä $A\mathbf{v} = \mathbf{b}$ kerrottaisi puolittain jollain sopivalla matriisilla, esimerkiksi

$$\underbrace{\begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}}_{\text{Rivien 1 ja 2 vaihto}} \qquad \underbrace{\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -2 & 0 & 1 \end{pmatrix}}_{\text{Riviin 3 lisätään } (-2)\times(\text{Rivi 1})} \qquad \underbrace{\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & \frac{1}{2} \end{pmatrix}}_{\text{Rivi 3 kerrotaan luvulla } \frac{1}{2}}$$

Merkitään eliminaatiossa esiintyviä matriiseja $E_1, E_2, \ldots, E_N$. Lopulta yhtälön vasemmalle puolelle jää vain identiteettimatriisi, eli symbolisesti se menee muotoon

$$I\mathbf{v} = E_N \cdots E_1 \mathbf{b}.$$

Tästä voidaan päätellä, että oikealle puolelle jäänyt matriisi $E_N \cdots E_1$ on täsmälleen A:n käänteismatriisi, sillä

$$\mathbf{v} = I\mathbf{v} = E_N \cdots E_1 \mathbf{b} = (E_N \cdots E_1)\, A\mathbf{v}.$$

Siis täytyy olla $A^{-1} = E_N \cdots E_1$.

Esimerkki 4.1. (Cramerin sääntö). Tutkitaan, milloin 2×2-matriisilla

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

on käänteismatriisi. Väitämme, että tämä käänteismatriisi saadaan aina kaavasta

$$\boxed{A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}}$$

mikäli lauseke $ad - bc$ ei ole nolla. Tämä tunnetaan **Cramerin sääntönä**. Nopea tarkistus:

$$AA^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix} \begin{pmatrix} a & b \\ c & d \end{pmatrix} = \frac{1}{ad - bc} \begin{pmatrix} ad - bc & 0 \\ 0 & -bc + ad \end{pmatrix} = I_2.$$

Myös $A^{-1}A = I_2$ samanlaisella laskulla.

Siis kappaleen alussa esiintynyt yhtälöryhmä

$$\begin{cases} x + y = 5 \\ 2x + y = 7 \end{cases}$$

voitaisiin ratkaista muodostamalla matriisin

$$A = \begin{pmatrix} 1 & 1 \\ 2 & 1 \end{pmatrix} \text{ käänteismatriisi } A^{-1} = \frac{1}{1 - 2} \begin{pmatrix} 1 & -1 \\ -2 & 1 \end{pmatrix} = \begin{pmatrix} -1 & 1 \\ 2 & -1 \end{pmatrix},$$

ja kertomalla tällä vektoria $\begin{pmatrix} 5 \\ 7 \end{pmatrix}$, antaen lopputuloksena ratkaisun $\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 2 \\ 3 \end{pmatrix}$.

Kääntyvyysehdot

Matriisin kääntyvyys voidaan tarkistaa monella eri tavalla. Seuraava lause esittelee osan eri tavoista.

Lause 4.1. *Olkoon A $n \times n$-neliömatriisi. Tällöin seuraavat ehdot ovat yhtäpitäviä*

- *A on kääntyvä.*
- $\operatorname{Ker} A = \{\mathbf{0}\}$.
- $\operatorname{rank} A = n$.
- *A:n rivivektorit ovat lineaarisesti riippumattomia.*
- *A:n sarakevektorit ovat lineaarisesti riippumattomia.*

Todistus. Matriisin kääntyvyys on yhtäpitävää sen kanssa, että yhtälöryhmällä $A\mathbf{v} = \mathbf{b}$ on yksikäsitteinen ratkaisu kaikilla vektoreilla $\mathbf{b}$. Gaussin eliminaatiosta huomattiin, että tämä tapahtuu juuri silloin, kun porrasmuodossa on tasan n kappaletta pivoteja (tällöin myöskään nollarivejä ei jää, sillä A on neliömatriisi).

Tämä on ensinnäkin yhtäpitävää ehdon $\operatorname{Ker} A = \{\mathbf{0}\}$ kanssa, sillä ytimen $\operatorname{Ker} A$ dimensio vastaa vapaiden muuttujien lukumäärää. Eli kun vapaita muuttujia ei ole, ydin on nollaulotteinen ja sisältää vain nollavektorin.

Rank-Nullity lauseen perusteella tämä on ekvivalenttia sen kanssa, että matriisi on täysasteinen, $\operatorname{rank} A = n$. Ja koska matriisin kuva-avaruus on sen sarakevektoreiden virittämä, on tämä jälleen sama asia, kuin sarakevektoreiden lineaarinen riippumattomuus.

Lopulta perustellaan, miksi rivivektorit ovat myös lineaarisesti riippumattomia. Yksi helppo perustelu on transpoosin kautta: Matriisi A on kääntyvä tasan silloin, kun transpoosi A^T on myös kääntyvä, sillä

$$(A^T)^{-1} = (A^{-1})^T.$$

Todistus tälle harjoitustehtävissä. Koska transpoosin sarakevektorit ovat A:n rivivektorit, on myös rivivektoreiden lineaarinen riippumattomuus yhtäpitävää kääntyvyyden kanssa.

Kannanvaihto

Kääntyvän $n \times n$-matriisin A sarakkeet ovat siis lineaarisesti riippumattomia. Koska sarakkeita on n kappaletta, muodostavat ne kannan avaruudelle $\mathbb{R}^n$. Tätä kautta matriisia A voi tulkita myös ns. **kannanvaihtona**. Motivoidaan tätä käsitettä ensin hieman:

Avaruudessa $\mathbb{R}^n$ elävillä olennoilla ei ole vaikeuksia puhua navigoinnista, sillä kaikkialla heidän maailmassaan on näkyvillä yhdessä sovitut koordinaattiakselien suuntaiset kantavektorit $\mathbf{e}_1, \ldots, \mathbf{e}_n$. Mutta todellisessa maailmassa mitään tälläisiä kanonisia kantavektoreita ei ole olemassa, vaan tosiasiassa on monenlaisia erilaisia järkeviä tapoja valita seurattava koordinaatisto.

Tällaisessa tilanteessa tarvitaan tapoja verrata eri koordinaatistoja toisiinsa. Oliot A ja B saattavat molemmat ajatella omia suuntiaan (edes/takaisin, vasen/oikea, ylös/alas) standardikantana $\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3$, mutta tosiasiassa heidän koordinaatistot voivat olla täysin eri. Ajatellaan hetkeksi maailmaa Olion A näkökulmasta, jossa Olion A suuntia ajatellaan standardikantavektoreina $\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3$. Sen sijaan Olion B kantavektoreiden $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$ esitys Olion A kannassa voisi olla esimerkiksi

$$\mathbf{v}_1 = \mathbf{e}_1 - 2\mathbf{e}_2 = \begin{pmatrix} 1 \\ -2 \\ 0 \end{pmatrix}_A, \quad \mathbf{v}_2 = \mathbf{e}_2 + \mathbf{e}_3 = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}_A, \quad \text{ja} \quad \mathbf{v}_3 = 3\mathbf{e}_1 + \mathbf{e}_2 - \mathbf{e}_3 = \begin{pmatrix} 3 \\ 1 \\ -1 \end{pmatrix}_A.$$

Tällöin, jos Olio A on puhelimessa Olion B kanssa ja Olio B sanoo liikkuvansa eteenpäin, Olion A täytyy ymmärtää, että Olio B ei ole liikkumassa vektorin $\mathbf{e}_1$ suuntaan, vaan vektorin $\mathbf{v}_1$ suuntaan. Tällaista kommunikaatiota helpottaa **kannanvaihtomatriisi**

$$P_{B\to A} = \begin{pmatrix} 1 & 0 & 3 \\ -2 & 1 & 1 \\ 0 & 1 & -1 \end{pmatrix},$$

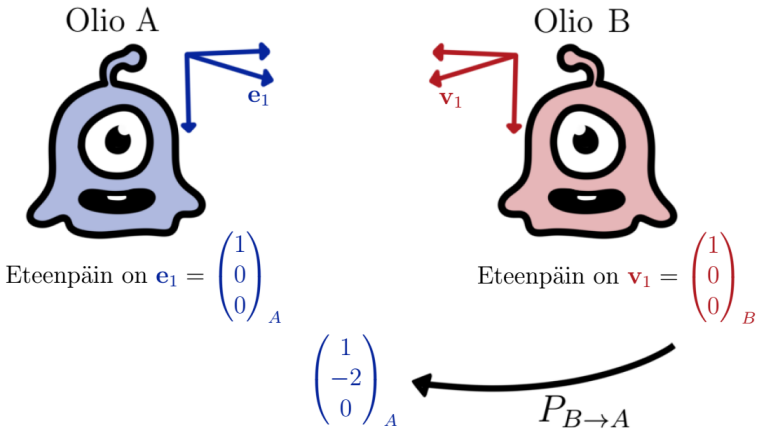
jonka sarakkeet ovat vektoreiden $\mathbf{v}_i$ kertoimet kannassa $\mathbf{e}_i$. Kannanvaihtomatriisin $P_{B\to A}$ avulla Olion B koordinaatistosta voidaan päästä takaisin Olion A koordinaatistoon seuraavasti. Olion B kannassa kantavektoreiden $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$ esitys on yksinkertaisesti

$$\mathbf{v}_1 = \begin{pmatrix}1\\0\\0\end{pmatrix}_B, \quad \mathbf{v}_2 = \begin{pmatrix}0\\1\\0\end{pmatrix}_B, \quad \text{ja} \quad \mathbf{v}_3 = \begin{pmatrix}0\\0\\1\end{pmatrix}_B.$$

Kannanvaihtomatriisilla $P_{B\to A}$ nämä esitykset Olion B kannassa voidaan muuttaa niiden esityksiin Olion A kannassa, eli

$$P_{B\to A}\begin{pmatrix}1\\0\\0\end{pmatrix}_B = \begin{pmatrix}1\\-2\\0\end{pmatrix}_A, \quad P_{B\to A}\begin{pmatrix}0\\1\\0\end{pmatrix}_B = \begin{pmatrix}0\\1\\1\end{pmatrix}_A, \quad \text{ja} \quad P_{B\to A}\begin{pmatrix}0\\0\\1\end{pmatrix}_B = \begin{pmatrix}3\\1\\-1\end{pmatrix}_A.$$

Matriisi $P_{B\to A}$ siis muuttaa vektorit Olion B maailmasta esitykseen Olion A maailmassa.



Kuva: Kannanvaihto $P_{B\to A}$ paljastaa Olion B kantavektoreiden esityksen Olion A kannassa.

Sen sijaan Olion A koordinaatistosta voidaan päästä Olion B koordinaatistoon vastaavanlaisella matriisilla, ja luonnollisesti tämä on matriisin $P_{B\to A}$ käänteismatriisi $P_{B\to A}^{-1} = P_{A\to B}$.

Esimerkki 4.2. Robotti-imuri liikkuu pitkin lattiaa seuraavasti. Robotin näkökulmasta sillä on kaksi suuntaa liikkua, joko eteenpäin/taakse tai vasemmalle/oikealle. Sillä on myös tallennettuna kartta asunnosta, joka on kaksiulotteisessa koordinaatistossa. Sovitaan, että aloitustilanteessa robotti on asetettu tämän koordinaatiston akselien suuntaisesti, eli sen liikkumasuunnat ovat standardikannan vektorit

$$\mathbf{e}_1 = \begin{pmatrix}1\\0\end{pmatrix} \quad \text{ja} \quad \mathbf{e}_2 = \begin{pmatrix}0\\1\end{pmatrix}.$$

Robotti liikkuu jonkin aikaa näiden vektoreiden suuntaisesti, mutta sitten tulee tarve kääntyä. Robotti osaa kääntyä minkä tahansa kulman verran tasossa, ja tällä kertaa sen täytyy kääntyä 45 astetta vastapäivään. Vastaava kiertomatriisi on

$$R_{\pi/4} = \frac{1}{\sqrt{2}}\begin{pmatrix}1 & -1\\1 & 1\end{pmatrix}.$$

Kierron jälkeen tämän matriisin sarakkeet

$$\mathbf{v}_1 = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix} \qquad \text{ja} \qquad \mathbf{v}_2 = \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$$

antavat robotin uudet liikkumasuunnat, eli uudet kantavektorit sen liikkeille. Omasta näkökulmastaan robotti liikuu edelleen vain eteen/taakse ja vasemmalle/oikealle, mutta ympäröivässä avaruudessa nämä liikkeet muodostuvat nyt vektoreista $\mathbf{v}_1$ ja $\mathbf{v}_2$. Jos robotti liikkuu nyt a yksikköä eteen ja b vasemmalle, sen sijainti muuttuu siis vektorin $a\mathbf{v}_1 + b\mathbf{v}_2$ verran.

Esimerkki 4.3. Kolmannen asteen polynomeja on tapana kirjoittaa muodossa

$$p(x) = ax^3 + bx^2 + cx + d,$$

missä a, b, c, d ovat reaalisia kertoimia. Sanotaan tätä vaikkapa polynomin esitykseksi kannassa $B_0 = \{x^3, x^2, x, 1\}$. Jokaista tällaista polynomia vastaa siis neliulotteinen vektori

$$\mathbf{v}_p = \begin{pmatrix} a \\ b \\ c \\ d \end{pmatrix}_{B_0}.$$

Toisaalta esimerkiksi Taylorin kehitelmissä on usein tapana kirjoittaa polynomin kertoimet jonkin toisen lausekkeen suhteen, esimerkiksi

$$p(x) = e(x-1)^3 + f(x-1)^2 + g(x-1) + h.$$

Kutsutaan tätä vastikään polynomin esitykseksi kannassa $B_1 = \{(x-1)^3, (x-1)^2, x-1, 1\}$. Tätä tapaa kirjoittaa polynomi p uudelleen voidaan ajatella myös kannanvaihtona

$$\begin{pmatrix} a \\ b \\ c \\ d \end{pmatrix}_{B_0} \quad \to \quad \begin{pmatrix} e \\ f \\ g \\ h \end{pmatrix}_{B_1}.$$

Selvitetään seuraavaksi, mikä matriisi tätä kannanvaihtoa vastaa. Kannanvaihtomatriisin voi selvittää, kunhan tiedetään miten monomit $x^3, x^2, x, 1$ esitetään uudessa kannassa,

sillä nämä vastaavat kannan B_0 vektoreina standardikantavektoreita $\mathbf{e}_1, \ldots, \mathbf{e}_4$.

$$x^3 = ((x-1)+1)^3 = (x-1)^3 + 3(x-1)^2 + 3(x-1) + 1 \quad \Rightarrow \quad \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \end{pmatrix}_{B_0} = \begin{pmatrix} 1 \\ 3 \\ 3 \\ 1 \end{pmatrix}_{B_1}$$

$$x^2 = ((x-1)+1)^2 = (x-1)^2 + 2(x-1) + 1 \quad \Rightarrow \quad \begin{pmatrix} 0 \\ 1 \\ 0 \\ 0 \end{pmatrix}_{B_0} = \begin{pmatrix} 0 \\ 1 \\ 2 \\ 1 \end{pmatrix}_{B_1}$$

$$x = (x-1)+1 \quad \Rightarrow \quad \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \end{pmatrix}_{B_0} = \begin{pmatrix} 0 \\ 0 \\ 1 \\ 1 \end{pmatrix}_{B_1}$$

$$1 = 1 \quad \Rightarrow \quad \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \end{pmatrix}_{B_0} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \end{pmatrix}_{B_1}$$

Siis kannanvaihtomatriisi kannasta B_0 kantaan B_1 on

$$P_{B_0 \to B_1} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 3 & 1 & 0 & 0 \\ 3 & 2 & 1 & 0 \\ 1 & 1 & 1 & 1 \end{pmatrix}.$$

---

5. Ortogonaalisuus

Vektorit-osiossa totesimme, että kaksi vektoria $\mathbf{v}, \mathbf{w}$ ovat **kohtisuorassa** tai **ortogonaaliset**, mikäli $\mathbf{v} \cdot \mathbf{w} = 0$. Tyypillisesti geometriassa kohtisuoruus määritellään suorien välisen kulman avulla, mutta osoittautuu, että sen määritteleminen pistetulon avulla on monella tapaa luonnollisempi ja käytännöllisempi vaihtoehto. Tässä kappaleessa tutkimme, mitä uusia mahdollisuuksia tämä lähestymistapa avaa.

Pythagoraan lause: Mikäli vektorit $\mathbf{v}$ ja $\mathbf{w}$ ovat ortogonaaliset, täytyy päteä, että

$$|\mathbf{v} + \mathbf{w}|^2 = |\mathbf{v}|^2 + |\mathbf{w}|^2.$$

Tämä on varsin suora seuraus pistetulon ominaisuuksista, sillä jos $\mathbf{v} \cdot \mathbf{w} = 0$, niin

$$|\mathbf{v}+\mathbf{w}|^2 = (\mathbf{v}+\mathbf{w})\cdot(\mathbf{v}+\mathbf{w}) = \mathbf{v}\cdot\mathbf{v}+\mathbf{v}\cdot\mathbf{w}+\mathbf{w}\cdot\mathbf{v}+\mathbf{w}\cdot\mathbf{w} = |\mathbf{v}|^2+2(\mathbf{v}\cdot\mathbf{w})+|\mathbf{w}|^2 = |\mathbf{v}|^2+|\mathbf{w}|^2.$$

Ortogonaaliset jonot

Olkoon $\mathbf{v}_1, \ldots, \mathbf{v}_N$ jono nollasta poikkeavia vektoreita. Sanomme, että vektorit $\mathbf{v}_j$ muodostavat **ortogonaalisen jonon** tai **-kannan**, mikäli ne ovat kaikki toisiaan vastaan kohtisuorassa, eli

$$\mathbf{v}_i \cdot \mathbf{v}_j = 0, \qquad \text{kun } i \neq j.$$

Lisäksi sanomme, että jono $(\mathbf{v}_i)$ on **ortonormaali**, mikäli lisäksi jokaisen vektorin $\mathbf{v}_i$ pituus on yksi, eli $\mathbf{v}_i \cdot \mathbf{v}_i = 1$. Esimerkiksi avaruuden $\mathbb{R}^n$ standardikanta $\mathbf{e}_1, \ldots, \mathbf{e}_n$ on ortonormaali.

Ortogonaalinen/ortonormaali vektorijono on aina lineaarisesti riippumaton. Tämä voidaan todistaa määritelmän kautta, sillä jos

$$\begin{aligned} a_1\mathbf{v}_1 + \cdots + a_N\mathbf{v}_N = \mathbf{0}, \qquad \text{niin} \qquad & \mathbf{v}_i \cdot (a_1\mathbf{v}_1 + \cdots + a_N\mathbf{v}_N) = 0 \\ \Rightarrow \quad & a_1\,\mathbf{v}_i\cdot\mathbf{v}_1 + \cdots + a_N\,\mathbf{v}_i\cdot\mathbf{v}_N = 0 \\ \Rightarrow \quad & a_i\,\mathbf{v}_i\cdot\mathbf{v}_i = 0 \\ \Rightarrow \quad & a_i = 0. \end{aligned}$$

Siis kaikkien kertoimien a_i täytyy olla nollia, eli vektorit $\mathbf{v}_1, \ldots, \mathbf{v}_N$ ovat lineaarisesti riippumattomia.

Ortogonaalinen projektio

Olkoon $\mathbf{v}_1, \ldots, \mathbf{v}_N$ jokin ortogonaalinen kanta aliavaruudelle

$$V = \operatorname{span}(\mathbf{v}_1, \ldots, \mathbf{v}_N).$$

Jos $\mathbf{b} \in \mathbb{R}^n$ on jokin vektori, joka ei kuulu aliavaruuteen V, on luonnollista pohtia, miten lasketaan pisteen $\mathbf{b}$ ja aliavaruuden V etäisyys. Tätä varten täytyy selvittää sellainen aliavaruuden vektori $\mathbf{w} \in V$, jonka etäisyys vektorista $\mathbf{b}$ on pienin mahdollinen.

Geometrian perusteella järkevä arvaus on, että vektori $\mathbf{w}$ pitää valita niin, että vektori $\mathbf{b}-\mathbf{w}$ on kohtisuorassa aliavaruutta V, eli jokaista sen vektoria, vasten. Tällaista vektoria

$\mathbf{w}$ sanotaan vektorin $\mathbf{b}$ **ortogonaaliseksi projektioksi** aliavaruudelle V. Sitä merkitään $\operatorname{proj}_V(\mathbf{b})$ (tai $\operatorname{proj}_{\mathbf{v}_1,\ldots,\mathbf{v}_N}(\mathbf{b})$) ja sen voi laskea kaavasta

$$\operatorname{proj}_V(\mathbf{b}) = \sum_{i=1}^{N} \frac{\mathbf{b}\cdot\mathbf{v}_i}{|\mathbf{v}_i|^2}\mathbf{v}_i.$$

Erityisesti ortogonaalinen projektio jonkin vektorin $\mathbf{v}$ määräämälle suoralle saadaan kaavasta

$$\operatorname{proj}_{\mathbf{v}}(\mathbf{b}) = \frac{\mathbf{b}\cdot\mathbf{v}}{|\mathbf{v}|^2}\mathbf{v},$$

ja projektio yleiselle ortogonaalisen kannan määräämälle aliavaruudelle V saadaan täten laskemalla yhteen yksiulotteiset projektiot jokaisen kantavektorin suuntaan.

Ortogonaalinen projektio $\operatorname{proj}_V(\mathbf{b})$ on se yksikäsitteinen vektori, jolle vektori $\mathbf{b}-\operatorname{proj}_V(\mathbf{b})$ on kohtisuorassa jokaista aliavaruuden V vektoria kohti (perustelu hetken päästä). Tarkistetaan nyt, että tämä todellakin antaa $\mathbf{b}$:n lähimmän mahdollisen vektorin aliavaruudessa V. Jos $\mathbf{u}\in V$ on mikä tahansa vektori, niin Pythagoraan lauseella

$$\begin{aligned}|\mathbf{b}-\mathbf{u}|^2 &= |\mathbf{b}-\operatorname{proj}_V(\mathbf{b})+(\operatorname{proj}_V(\mathbf{b})-\mathbf{u})|^2\\ &= |\mathbf{b}-\operatorname{proj}_V(\mathbf{b})|^2 + |\operatorname{proj}_V(\mathbf{b})-\mathbf{u}|^2\\ &\geq |\mathbf{b}-\operatorname{proj}_V(\mathbf{b})|^2.\end{aligned}$$

Siis valinta $\mathbf{u}=\operatorname{proj}_V(\mathbf{b})$ todellakin minimoi etäisyyden $|\mathbf{b}-\mathbf{u}|$.

Tarkistetaan vielä, että $\mathbf{b}-\operatorname{proj}_V(\mathbf{b})$ on varmasti kohtisuorassa aliavaruutta V vasten. Jokaisella $j=1,\ldots,N$ pätee

$$\begin{aligned}(\mathbf{b}-\operatorname{proj}_V(\mathbf{b}))\cdot\mathbf{v}_j &= \sum_{i=1}^{N}\left(\mathbf{b}\cdot\mathbf{v}_j - \frac{\mathbf{b}\cdot\mathbf{v}_i}{|\mathbf{v}_i|^2}\mathbf{v}_i\cdot\mathbf{v}_j\right)\\ &= \left(\mathbf{b}\cdot\mathbf{v}_j - \frac{\mathbf{b}\cdot\mathbf{v}_j}{|\mathbf{v}_j|^2}\mathbf{v}_j\cdot\mathbf{v}_j\right) \qquad (\text{Sillä } i\neq j \Rightarrow \mathbf{v}_i\cdot\mathbf{v}_j=0)\\ &= (\mathbf{b}\cdot\mathbf{v}_j - \mathbf{b}\cdot\mathbf{v}_j)\\ &= 0.\end{aligned}$$

Ja jos $\mathbf{u}=\sum_{j=1}^{N} a_j\mathbf{v}_j$ on jokin aliavaruuden V vektori esitettynä kannassa $(\mathbf{v}_j)$, niin

$$(\mathbf{b}-\operatorname{proj}_V(\mathbf{b}))\cdot\mathbf{u} = \sum_{j=1}^{N} a_j(\mathbf{b}-\operatorname{proj}_V(\mathbf{b}))\cdot\mathbf{v}_j = \sum_{j=1}^{N} a_j\cdot 0 = 0.$$

□

Ortogonalisointi

Olkoon $\mathbf{v}_1,\ldots,\mathbf{v}_N$ kanta avaruuden $\mathbb{R}^n$ aliavaruudelle. Tällöin on olemassa toinen kanta $\mathbf{u}_1,\ldots,\mathbf{u}_N$ samalle aliavaruudelle siten, että vektorit $\mathbf{u}_i$ ovat ortonormaaleja.

Tämän uuden kannan muodostaminen onnistuu **Gram-Schmidtin ortogonalisoinnilla**. Tämän algoritmin idea on edetä vektorit $\mathbf{v}_i$ läpi järjestyksessä, ja poistaa aina jokaisesta vektorista edellisten vektoreiden kanssa samansuuntaiset osuudet. Menetelmä toimii käytännössä näin:

(1) Olkoon $\mathbf{u}_1 = \mathbf{v}_1/|\mathbf{v}_1|$.

(2) Olkoon $\mathbf{u}_2^* = \mathbf{v}_2 - \mathrm{proj}_{\mathbf{u}_1}(\mathbf{v}_2)$. Tällöin $\mathbf{u}_2 = \mathbf{u}_2^*/|\mathbf{u}_2^*|$ on yksikkövektori, joka on kohtisuorassa vektoria $\mathbf{u}_1$ vasten.

(3) Olkoon yleisesti

$$\mathbf{u}_j^* = \mathbf{v}_j - \mathrm{proj}_{\mathbf{u}_1,\mathbf{u}_2,\ldots,\mathbf{u}_{j-1}}(\mathbf{v}_j).$$

Tällöin $\mathbf{u}_j = \mathbf{u}_j^*/|\mathbf{u}_j^*|$ on yksikkövektori, joka on kohtisuorassa kaikkia vektoreita $\mathbf{u}_1, \mathbf{u}_2, \ldots, \mathbf{u}_{j-1}$ vasten.

Tämä tuottaa lopulta ortonormaalin vektorijonon $\mathbf{u}_1, \ldots, \mathbf{u}_N$ joka virittää saman aliavaruuden, kuin vektorit $\mathbf{v}_1, \ldots, \mathbf{v}_N$.

Käymme tästä hetken päästä esimerkkilaskun.

Ortokomplementti

Jos V on avaruuden $\mathbb{R}^n$ aliavaruus, on mielekäs ja usein hyvin tärkeä kysymys pohtia, millaisen joukon muodostavat ne vektorit, jotka ovat aliavaruutta V kohtisuorassa. Tällaista joukkoa sanotaan V:n **ortokomplementiksi**, ja se määritellään

$$V^\perp = \{\mathbf{w} \in \mathbb{R}^n : \mathbf{v} \cdot \mathbf{w} = 0 \text{ kaikilla } \mathbf{v} \in V\}.$$

On varsin suoraviivaista näyttää, että ortokomplementti $V^\perp$ on myös aliavaruus (pohdi miksi). Sen dimensio on aina $\dim V^\perp = n - \dim V$.

Pohditaan seuraavaksi, miten annetun aliavaruuden V ortokomplementin voisi selvittää. Sovitaan, että aliavaruudelle V on tiedossa kanta

$$V = \mathrm{span}(\mathbf{v}_1, \ldots, \mathbf{v}_N).$$

Pistetulon lineaarisuuden takia vektori $\mathbf{w}$ kuuluu tällöin ortokomplementtiin $V^\perp$ tasan silloin, kun $\mathbf{w} \cdot \mathbf{v}_i = 0$ kaikilla $i = 1, \ldots, N$. Tämä voidaan myös ilmaista matriisien avulla seuraavasti. Asetetaan vastaavat vaakavektorit $\mathbf{v_i}^T$ erään $N \times n$-matriisin A riveiksi:

$$A = \begin{pmatrix} \mathbf{v}_1^T \\ \vdots \\ \mathbf{v}_N^T \end{pmatrix} \qquad \Rightarrow \qquad A\mathbf{w} = \begin{pmatrix} \mathbf{v}_1 \cdot \mathbf{w} \\ \vdots \\ \mathbf{v}_N \cdot \mathbf{w} \end{pmatrix} = \mathbf{0}.$$

Siispä $\mathbf{w} \in V^\perp$ tasan silloin, kun $\mathbf{w} \in \mathrm{Ker}\, A$. Tässä on toki kyse vain lineaarisesta yhtälöryhmästä, joka voidaan tutulla tapaa ratkaista Gaussin eliminaatiolla.

Lasketaan seuraavaksi esimerkin kautta Gram-Schmidtin menetelmän käytännön sovellus, ja tutustutaan samalla ortokomplementin määrittämiseen edellä esitetyllä tavalla.

Esimerkki 5.1. Olkoon

$$\mathbf{v}_1 = \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix}, \qquad \text{ja} \qquad \mathbf{v}_2 = \begin{pmatrix} 2 \\ 0 \\ 1 \end{pmatrix}$$

Vektorit $\mathbf{v}_1$ ja $\mathbf{v}_2$ eivät ole kohtisuorassa, mutta ne ovat lineaarisesti riippumattomia ja virittävät tason $\mathbb{R}^3$:ssa. Etsitään tälle tasolle ensin ortogonaalinen kanta Gram-Schmidtin menetelmällä:

- Ensin määritellään
$$\mathbf{u}_1 = \frac{\mathbf{v}_1}{|\mathbf{v}_1|} = \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \\ 0 \end{pmatrix}.$$

- Sitten lasketaan
$$\mathbf{u}_2^* = \mathbf{v}_2 - \mathrm{proj}_{\mathbf{u}_1}(\mathbf{v}_2) = \mathbf{v}_2 - (\mathbf{v}_2 \cdot \mathbf{u}_1)\,\mathbf{u}_1 = \begin{pmatrix} 2 \\ 0 \\ 1 \end{pmatrix} - \frac{2}{\sqrt{2}} \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}.$$

  Lopuksi normalisoidaan vielä
$$\mathbf{u}_2 = \frac{\mathbf{u}_2^*}{|\mathbf{u}_2^*|} = \begin{pmatrix} 1/\sqrt{3} \\ 1/\sqrt{3} \\ 1/\sqrt{3} \end{pmatrix}.$$

Täten $\mathbf{u}_1$ ja $\mathbf{u}_2$ ovat ortonormaali kanta vektoreiden $\mathbf{v}_1$ ja $\mathbf{v}_2$ virittämälle tasolle.

Selvitetään lopuksi vielä sellainen kolmas vektori $\mathbf{u}_3$, että vektorit $\mathbf{u}_i$ muodostavat avaruuden $\mathbb{R}^3$ ortonormaalin kannan. Tämän voisi laskea kolmiulotteisten vektorien ristitulolla suoraan, mutta tehdään se yleispätevällä Gaussin eliminaatiolla etsimällä matriisin
$$A = \begin{pmatrix} \mathbf{v}_1^T \\ \mathbf{v}_2^T \end{pmatrix} = \begin{pmatrix} 1 & -1 & 0 \\ 2 & 0 & 1 \end{pmatrix}$$
ydin $\mathrm{Ker}\, A$. Saamme tästä yhtälöryhmän muodossa
$$\left.\begin{array}{ccc|c} 1 & -1 & 0 & 0 \\ 2 & 0 & 1 & 0 \end{array}\right.$$
Josta yhdellä eliminaatiolla saadaan suoraan porrasmuoto
$$\left.\begin{array}{ccc|c} 1 & -1 & 0 & 0 \\ 0 & 2 & 1 & 0 \end{array}\right.$$
Tästä voidaan nopeasti ratkaista
$$\mathbf{w} = \begin{pmatrix} x \\ y \\ z \end{pmatrix} \in \mathrm{Ker}\, A \quad \Leftrightarrow \quad \mathbf{w} = \begin{pmatrix} x \\ x \\ -2x \end{pmatrix}.$$
Siis ortokomplementin virittää (normalisoitu) vektori $\mathbf{u}_3 = (\sqrt{6})^{-1} \begin{pmatrix} 1 & 1 & -2 \end{pmatrix}^T$. Tämä muodostaa ortonormaalin kannan vektoreiden $\mathbf{u}_1$ ja $\mathbf{u}_2$ kanssa (tarkista!).

Ortogonaaliset matriisit

Sanotaan, että neliömatriisi Q on **ortogonaalinen**, mikäli
$$Q^T Q = I.$$

Ortogonaalisuuden voi ilmaista usealla eri tavalla

Lause 5.1. *Olkoon Q $n \times n$-neliömatriisi. Tällöin seuraavat ehdot ovat yhtäpitäviä*

- *Q on ortogonaalinen.*
- *Q on kääntyvä ja $Q^{-1} = Q^T$.*
- *Matriisin Q sarakkeet muodostavat ortonormaalin kannan avaruudelle $\mathbb{R}^n$.*
- *Matriisin Q rivit muodostavat ortonormaalin kannan avaruudelle $\mathbb{R}^n$.*
- *Lineaarikuvaus $Q : \mathbb{R}^n \to \mathbb{R}^n$ säilyttää vektorien pituudet ja niiden väliset kulmat, eli*

$$Q\mathbf{u} \cdot Q\mathbf{v} = \mathbf{u} \cdot \mathbf{v} \qquad \textit{kaikilla } \mathbf{u}, \mathbf{v} \in \mathbb{R}^n.$$

Geometrisesti ortogonaaliset muunnokset ovat kiertoja/peilauksia.

Ortogonaalisen matriisin käänteismatriisi on myös ortogonaalinen.

Pienimmän neliösumman ratkaisu yhtälöryhmälle

Olemme huomanneet aiemmin, että yleisellä lineaarisella yhtälöryhmällä

$$A\mathbf{v} = \mathbf{b}$$

ei aina ole ratkaisua. Tämä tapahtuu tasan silloin, kun $\mathbf{b}$ ei ole kuva-avaruudessa $\operatorname{Im} A$. Käytännössä näin tapahtuu erityisen usein, kun yhtälöryhmässä on huomattavasti enemmän yhtälöitä kuin muuttujia.

Tällaisessa tapauksessa on kuitenkin järkevä pohtia, onko olemassa jotain vektoria $\mathbf{v}$, joka on jossain mielessä 'mahdollisimman lähellä' yhtälön ratkaisemista. Luonnollinen tapa tehdä tästä täsmällistä, on etsiä vektori $\mathbf{v}$, jolla suure

$$|A\mathbf{v} - \mathbf{b}|^2$$

on pienin mahdollinen. Tämän optimointiongelman ratkaisua $\mathbf{v}$ sanotaan **pienimmän neliösumman ratkaisuksi** yhtälöryhmälle

$$A\mathbf{v} = \mathbf{b}.$$

Suureen $|A\mathbf{v} - \mathbf{b}|^2$ minimointi tarkoittaa erityisesti sitä, että haluamme etsiä matriisin A kuva-avaruuden vektoria $\mathbf{w} = A\mathbf{v}$, jolla etäisyys $|\mathbf{w} - \mathbf{b}|$ on mahdollisimman pieni. Tämä saavutetaan silloin, kun $\mathbf{w}$ on vektorin $\mathbf{b}$ ortogonaalinen projektio kuva-avaruudelle $\operatorname{Im} A$.

Erityisesti vektori $\mathbf{b} - \mathbf{w} = \mathbf{b} - A\mathbf{v}$ on tällöin kohtisuorassa kuva-avaruutta vasten, joten se kuuluu kuva-avaruuden ortokomplementtiin, eli transpoosin A^T ytimeen $\operatorname{Ker} A^T$. Siispä

$$A^T(\mathbf{b} - A\mathbf{v}) = \mathbf{0} \qquad \Leftrightarrow \qquad A^T A\mathbf{v} = A^T\mathbf{b}.$$

Tätä kutsutaan **normaaliyhtälöksi**. Erityisesti pienimmän neliösumman ratkaisu $\mathbf{v}$ voidaan löytää ratkaisemalla normaaliyhtälö. Tutkitaan vielä, miten normaaliyhtälön ratkaisemisesta päästään pienimmän neliösumman ratkaisuun.

Ensinnäkin normaaliyhtälöllä $A^TA\mathbf{v} = A^T\mathbf{b}$ on varmasti ainakin yksi ratkaisu $\mathbf{v}_0$, sillä olemme jo päätelleet, että tällainen ratkaisu löytyy ottamalla vektorin $\mathbf{b}$ ortogonaalinen projektio kuva-avaruudelle $\operatorname{Im} A$. Yleinen ratkaisujoukko on siis muotoa

$$\mathbf{v} = \mathbf{v}_0 + \mathbf{u}, \qquad \text{missä} \quad \mathbf{u} \in \operatorname{Ker} A^TA.$$

Mutta huomataan, että jos $\mathbf{u} \in \operatorname{Ker} A^TA$, niin myös $\mathbf{u} \in \operatorname{Ker} A$, sillä

$$0 = (A^TA\mathbf{u}) \cdot \mathbf{u} = (A\mathbf{u}) \cdot (A\mathbf{u}) = |A\mathbf{u}|^2. \tag{5.1}$$

Siis suure $|A\mathbf{v} - \mathbf{b}|^2$ antaa saman arvon kaikilla normaaliyhtälön ratkaisuilla $\mathbf{v}$. Mikäli toivomme, että pienimmän neliösumman ratkaisu on yksikäsitteinen, täytyy siis lisäksi olettaa, että $\operatorname{Ker} A = \{0\}$, eli että matriisi A on täysasteinen.

Pienimmän neliösumman ratkaisu on mahdollista löytää myös suoraan käyttämällä matriisin A ns. **pseudoinverssiä**. Tämä vaatii matriisin singulaariarvohajotelman eli SVD-hajotelman, jota käsittelemme luvussa Matriisihajotelmia.

Esimerkki 5.2. (Suoran sovitus). Olkoon annettu N kappaletta pisteitä (x_i, y_i), $i = 1, \ldots, N$ tasossa. Pyrimme etsimään suoraa

$$y = c_1x + c_2,$$

joka parhaiten approksimoi pistejoukkoa (x_i, y_i). Tämä on luonnollista muotoilla pienimmän neliösumman ongelmana, jossa

$$A = \begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_N & 1 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}, \quad \text{ja} \quad \mathbf{v} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix}.$$

Sillä tällöin suure

$$|A\mathbf{v} - \mathbf{b}|^2 = \sum_{i=1}^{N} |(c_1x_i + c_2) - y_i|^2$$

ilmaisee neliösummaa pisteiden (x_i, y_i) poikkeamista suoran $y = c_1x + c_2$ suhteen.

Samalla idealla voidaan sovittaa pistejoukkoihin myös esim. korkeamman asteen polynomeja, taso kolmessa ulottuvuudessa, jne.

---

6. Determinantti

Jokaiseen neliömatriisiin voidaan liittää lukuarvo nimeltä **determinantti**. Matriisin A determinanttia merkitään $\det A$.

Geometrisesti determinantti kuvaa sitä, kuinka paljon kuvaus $A : \mathbb{R}^n \to \mathbb{R}^n$ venyttää avaruutta. Otetaan esimerkiksi 2×2-matriisi

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}.$$

Tämä matriisi A tekee geometrisesti kahta asiaa: Se venyttää x-suunnassa kertoimella 2, ja y-suunnassa kertoimella 3. Siis minkä tahansa tasokuvion **pinta-ala** kuusinkertaistuu, kun sitä venytetään kuvauksella A. Tämän takia matriisin A determinantti on $\det A = 6$.

Katsotaan seuraavaksi kahta muuta esimerkkiä

$$B = \begin{pmatrix} 1 & -1 \\ 1 & -1 \end{pmatrix} \qquad \text{ja} \qquad C = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

Huomataan, että matriisin B rivit (ja sarakkeet) ovat lineaarisesti riippuvia. Matriisi B kuvaa mielivaltaisen pisteen seuraavasti:

$$B \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x - y \\ x - y \end{pmatrix}.$$

Huomataan, että jokainen B:n tuottama kuvapiste on muotoa $\begin{pmatrix} z \\ z \end{pmatrix}$ jollain $z \in \mathbb{R}$, joten B:n kuvajoukko on yksinkertaisesti suora $\{x = y\}$ tasossa. Koska suoran pinta-ala on nolla, kuvaa B jokaisen tasokuvion yksiulotteiseksi kuvioksi, jonka pinta-ala on nolla. Tämän takia B:n determinantti on $\det B = 0$.

Sen sijaan C toimii kuvauksena yksinkertaisesti vaihtamalla koordinaattien paikkaa:

$$C \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} y \\ x \end{pmatrix}.$$

Tämän voi myös geometrisesti tulkita peilauksena suoran $\{x = y\}$ suhteen. Peilaus ei muuta pinta-alaa, mutta se vaihtaa kuvion **orientaation**, eli oikeakätinen kuvio muuttuu vasenkätiseksi. Tämän takia C:n determinantti on $\det C = -1$.

Determinantti siis kuvaa tasossa pinta-alan muutosta orientaatio mukaanlukien. Yleisen 2×2-matriisin determinantin voi pienellä vaivalla laskea kaavasta

$$\det \begin{pmatrix} a & b \\ c & d \end{pmatrix} = ad - bc.$$

Tämä luku esiintyi myös Cramerin säännössä, ja se oli nolla tasan silloin, kun matriisi ei ollut kääntyvä. Tämä on myös yleinen fakta determinantista.

Lause 6.1. *Neliömatriisi A on kääntyvä täsmälleen silloin, kun* $\det A \neq 0$.

Yleisemmälle $n \times n$-neliömatriisille determinantti ei kuvaa pinta-alan muutosta, vaan vastaavan n-ulotteisen tilavuuden muutosta, jälleen orientaatio/kätisyys mukaanlukien. Determinantin itseisarvo kertoo tilavuuden varsinaisen muutoksen, ja sen merkki kertoo, vaihtuuko orientaatio vai ei. Ylläolevan lauseen perusteella determinantti paljastaa siis myös, onko lineaarisella yhtälöryhmällä

$$A\mathbf{v} = \mathbf{b}$$

aina yksikäsitteistä ratkaisua olemassa.

Deteminantille pätee myös mainio kaava matriisitulon kanssa:

$$\boxed{\det(AB) = \det A \det B.} \tag{6.1}$$

Tämä kaava on varsin helppo perustella geometrisesti: Jos kuvaus B ensin muuttaa tilavuutta kertoimella $\det B$, ja kuvaus A sitten kertoimella $\det A$, niin yhdistetyn kuvauksen AB tilavuuden muutos on näiden lukujen tulo. Tästä voidaan johtaa, että käänteismatriisin determinantti saadaan kaavasta

$$\det A^{-1} = (\det A)^{-1}.$$

Myös transpoosin determinantille pätee yksinkertainen laskukaava, nimittäin

$$\det A^T = \det A.$$

Transpoosin ottaminen ei siis muuta determinanttia.

Ortogonaalisen matriisin Q determinantti voidaan päätellä laskusäännöistä:

$$\det(Q)^2 = \det(Q^T)\det(Q) = \det(Q^TQ) = \det(I) = 1 \qquad \Rightarrow \qquad \det(Q) = \pm 1.$$

Determinantin laskeminen

Determinantin laskeminen isommille matriiseille on valitettavan työlästä käsin, mutta siihen on pari vaihtoehtoista menetelmää.

Menetelmä 1. Gaussin eliminaatio.

Gaussin eliminaatiolla voidaan myös laskea determinantteja. Otetaan esimerkiksi matriisi (tiivistetysti kirjoitettuna)

$$\begin{matrix} 0 & -1 & 1 \\ 2 & -2 & 4 \\ -1 & 3 & 4 \end{matrix}$$

Idea on, että Gaussin eliminaation jokainen askel ei muuta matriisin determinantin suuruutta, paitsi jokainen kahden rivin vaihto vaihtaa determinantin merkin.

Kun yllä olevalle matriisille tehdään Gaussin eliminaatio, vaihdetaan ensiaskeleella rivit 1 ja 2, ja sitten edetään normaalisti

$$\begin{matrix} 0 & -1 & 1 \\ 2 & -2 & 4 \\ -1 & 3 & 4 \end{matrix} \quad \Rightarrow \quad \begin{matrix} 2 & -2 & 4 \\ 0 & -1 & 1 \\ -1 & 3 & 4 \end{matrix} \begin{matrix} \\ \\ \leftarrow 0.5 \cdot (\text{Rivi } 1) \end{matrix} \quad \Rightarrow \quad \begin{matrix} 2 & -2 & 4 \\ 0 & -1 & 1 \\ 0 & 2 & 6 \end{matrix}$$

Ja vielä lisäämällä kolmanteen riviin $2\times$ toinen rivi saadaan lopullinen muoto

$$\begin{matrix} 2 & -2 & 4 \\ 0 & -1 & 1 \\ 0 & 0 & 8 \end{matrix}.$$

Tällaisen ns. yläkolmiomatriisin determinantti on sen **diagonaalin alkioiden tulo**, eli $2\cdot(-1)\cdot 8 = -16$. Kun muistetaan vielä, että eliminaatiossa piti tehdä yksi vaihto (eli merkkiä pitää vielä vaihtaa kerran), niin lopulta saadaan

$$\det\begin{pmatrix} 0 & -1 & 1 \\ 2 & -2 & 4 \\ -1 & 3 & 4 \end{pmatrix} = (-1)\cdot(-16) = 16.$$

Menetelmä 2. 3×3-Matriisit.

Esittelemme näppärän tavan laskea 3×3-matriisin

$$A = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix}$$

determinantti. Kirjoitetaan avuksi matriisin viereen sen kaksi ensimmäistä saraketta:

$$\left.\begin{matrix} a & b & c \\ d & e & f \\ g & h & i \end{matrix}\right| \begin{matrix} a & b \\ d & e \\ g & h \end{matrix}$$

Nyt determinantti saadaan

- Lisäämällä kaikki alas ja oikealle menevien diagonaalien alkioiden tulot ja
- Vähentämällä kaikki ylös ja oikealle menevien diagonaalien alkioiden tulot

Siis

$$\det A = aei + bfg + cdh - gec - hfa - idb.$$

Vaihtoehtoisesti samat diagonaalit voi hahmottaa suoraan matriisista ilman apukuvaa, kun ajatellaan, että oikean reunan yli mennessä tullaan vasemmasta reunasta takaisin. Esim. diagonaalit bfg ja cdh:

$$A = \begin{pmatrix} a & \mathrm{b} & \mathrm{c} \\ \mathrm{d} & e & \mathrm{f} \\ \mathrm{g} & \mathrm{h} & i \end{pmatrix}.$$

Menetelmä 3: Kofaktorikehitelmä.

Olkoon $A = (a_{ij})$ $n\times n$-matriisi, ja merkitään A_{ij}:llä sitä $(n-1)\times(n-1)$-matriisia, joka saadaan A:sta poistamalla rivi i ja sarake j. Tällöin mille tahansa valitulle riville i determinantti voidaan kehittää kaavalla

$$\det A = \sum_{j=1}^{n} a_{ij}(-1)^{i+j}\det A_{ij}.$$

Täten isomman matriisin determinantti voidaan aina laskea pienempien matriisien avulla, joten jokaisen determinantin voi lopulta laskea toistamalla tätä ja pilkkomalla riittävän pieniin osiin. Tämä menetelmä ei kuitenkaan ole kovin käytännöllinen, joten se mainitaan tässä lähinnä yleissivistyksenä.

Yllä esiintyneistä kofaktoreista $\det A_{ij}$ voidaan muodostaa myös ns. **kofaktorimatriisi** $\operatorname{cof} A$, jonka alkio kohdassa (i, j) on

$$(\operatorname{cof} A)_{ij} = (-1)^{i+j} \det A_{ij}.$$

Jos A on kääntyvä, voidaan käänteismatriisi laskea myös **yleisellä Cramerin säännöllä**

$$A^{-1} = (\det A)^{-1} (\operatorname{cof} A)^T.$$

Ristitulon muistikaava

Vektoreiden yhteydessä mainitsimme lyhyesti myös, että kolmiulotteisille vektoreille $\mathbf{v}, \mathbf{w} \in \mathbb{R}^3$ on mahdollista määritellä ristitulo

$$\mathbf{v} \times \mathbf{w} = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix} \times \begin{pmatrix} w_1 \\ w_2 \\ w_3 \end{pmatrix} = \begin{pmatrix} v_2 w_3 - v_3 w_2 \\ v_3 w_1 - v_1 w_3 \\ v_1 w_2 - v_2 w_1 \end{pmatrix}.$$

Determinantin avulla ristitulolle voidaan myös antaa seuraava muistisääntö

$$\mathbf{v} \times \mathbf{w} = \det \begin{pmatrix} \mathbf{e}_1 & \mathbf{e}_2 & \mathbf{e}_3 \\ v_1 & v_2 & v_3 \\ w_1 & w_2 & w_3 \end{pmatrix} = (v_2 w_3 - v_3 w_2)\mathbf{e}_1 + (v_3 w_1 - v_1 w_3)\mathbf{e}_2 + (v_1 w_2 - v_2 w_1)\mathbf{e}_3.$$

Tässä laskussa esiintyvä "3 × 3-matriisi" ei varsinaisesti ole oikea reaalinen matriisi, sillä sen ensimmäiselle riville on laitettu alkioiksi kantavektorit $\mathbf{e}_i$. Mutta yhdessä 3 × 3-matriisien determinantin muistikaavan kanssa tämä on varsin suora tapa palauttaa mieleen, miten ristitulo lasketaan.

7. Ominaisarvot ja ominaisvektorit

Olkoon A jälleen $n \times n$-neliömatriisi, ja ajatellaan sitä nyt kuvauksena $A : \mathbb{R}^n \to \mathbb{R}^n$. Kun matriisilla A kuvataan vektoria $\mathbf{v}$, saadaan uusi vektori

$$A\mathbf{v},$$

jonka pituus ja suunta ovat tyypillisesti eri, kuin vektorilla $\mathbf{v}$. Mutta on toisinaan mahdollista löytää myös sellaisia vektoreita, joiden suunta ei muutu, eli joita matriisi A ainoastaan venyttää. Näille vektoreille pätee siis

$$A\mathbf{v} = \lambda\mathbf{v} \qquad \text{jollain skalaarilla } \lambda \in \mathbb{R}.$$

Huomaa, että annamme tässä skalaarikertoimen λ olla mahdollisesti myös negatiivinen, missä tapauksessa vektorin $\mathbf{v}$ suunta kääntyy vastakkaiseksi kuvauksessa A.

Mikäli jokin vektori $\mathbf{v} \neq \mathbf{0}$ toteuttaa yhtälön $A\mathbf{v} = \lambda\mathbf{v}$, sanotaan, että $\mathbf{v}$ on matriisin A **ominaisvektori** ja λ on matriisin A **ominaisarvo**.

Ominaisarvot ja -vektorit osoittautuvat erittäin hyödylliseksi käsitteeksi ymmärtämään matriisien ominaisuuksia syvemmin. Tutkitaan ensin, milloin sellaisia voisi löytyä. Yhtälöä

$$A\mathbf{v} = \lambda\mathbf{v}$$

voidaan muokata kirjoittamalla $\lambda\mathbf{v} = \lambda I\mathbf{v}$, jolloin

$$A\mathbf{v} = \lambda I\mathbf{v} \quad \Rightarrow \quad A\mathbf{v} - \lambda I\mathbf{v} = \mathbf{0} \quad \Rightarrow \quad (A - \lambda I)\mathbf{v} = \mathbf{0}.$$

Pohditaan, milloin tällä yhtälöllä on nollasta poikkeava ratkaisu $\mathbf{v}$. Koska $A - \lambda I$ on neliömatriisi, voi yhtälöllä olla ratkaisu vain silloin, kun matriisi $A - \lambda I$ ei ole kääntyvä. Siis Lauseen 4.1 nojalla

$$\det(A - \lambda I) = \mathbf{0}.$$

Jos matriisi A on annettu, tämä on muuttujan λ suhteen yhden tuntemattoman muuttujan yhtälö. On mahdollista osoittaa, että lauseke

$$p(\lambda) = \det(A - \lambda I)$$

on aina muuttujan λ suhteen polynomi astetta n. Tätä sanotaan matriisin A **karakteristiseksi polynomiksi**, ja sen juuret ovat matriisin A ominaisarvot.

Esimerkki 7.1. Olkoon

$$A = \begin{pmatrix} 2 & 1 \\ 0 & -1 \end{pmatrix}.$$

Selvitetään matrisiin A ominaisarvot ja -vektorit. Karakteristinen polynomi on

$$p(\lambda) = \det(A - \lambda I_2) = \det \begin{pmatrix} 2 - \lambda & 1 \\ 0 & -1 - \lambda \end{pmatrix} = (2 - \lambda)(-1 - \lambda).$$

Siis ominaisarvot ovat $\lambda = 2$ ja $\lambda = -1$. Määritetään sitten ominaisvektorit $\mathbf{v}$.

Tapaus $\lambda = 2$**.** Saadaan yhtälö

$$(A - 2I_2)\mathbf{v} = \mathbf{0} \quad \Leftrightarrow \quad \begin{pmatrix} 0 & 1 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Tästä luetaan suoraan $y = 0$, ja x on vapaa parametri. Siis yleinen ominaisvektori on muotoa

$$\mathbf{v} = \begin{pmatrix} x \\ 0 \end{pmatrix} = x \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

mielivaltaisella $x \neq 0$.

Tapaus $\lambda = -1$**.** Saadaan yhtälö

$$(A - (-1)I_2)\mathbf{v} = \mathbf{0} \quad \Leftrightarrow \quad \begin{pmatrix} 3 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Tästä luetaan suoraan $3x + y = 0$. Valitaan x vapaaksi parametriksi, jolloin $y = -3x$, ja yleinen ominaisvektori on muotoa

$$\mathbf{v} = \begin{pmatrix} x \\ -3x \end{pmatrix} = x \begin{pmatrix} 1 \\ -3 \end{pmatrix}$$

mielivaltaisella $x \neq 0$.

Lopputulos. Siis ominaisvektorit ovat (skaalausta vaille) vektorit $\begin{pmatrix} 1 \\ 0 \end{pmatrix}$ ja $\begin{pmatrix} 1 \\ -3 \end{pmatrix}$, ja niitä vastaavat ominaisarvot 2 ja -1.

Esimerkki 7.2. Kaikilla matriiseilla ei ole (reaalisia) ominaisarvoja. Esimerkiksi matriisi

$$A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$$

vastaa tasossa 90-asteen kiertoa, joten nollavektoria lukuunottamatta se muuttaa jokaisen vektorin suuntaa, eli sillä ei voi olla ominaisvektoreita. Tämä näkyy suoraan myös karakteristisesta polynomista $p_A(\lambda) = \lambda^2 + 1$, jolla ei ole reaalisia juuria.

Huom! Ominaisarvojen teoria muuttuu huomattavasti, kun siirrytään reaalisista matriiseista kompleksisiin. Edellisellä matriisilla A on nimittäin kompleksitasossa ominaisarvona kompleksiluku i, sillä voimme laskea, että

$$\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ -i \end{pmatrix} = \begin{pmatrix} i \\ 1 \end{pmatrix} = i \begin{pmatrix} 1 \\ -i \end{pmatrix}.$$

Vastaavasti myös $-i$ on ominaisarvo, ominaisvektorilla $\begin{pmatrix} 1 & i \end{pmatrix}^T$. Lisää kompleksisten matriisien ominaisarvoista myöhemmin tässä luvussa.

Lineaariset rekursiot

Ominaisarvojen ja -vektoreiden hyöty paljastuu erityisesti, kun tutkitaan ns. **lineaarisia rekursioita**. Olkoon A jokin neliömatriisi, ja määritellään vektorijono $(\mathbf{v}_k)$ rekursiivisesti kaavalla:

$$\mathbf{v}_{k+1} = A\mathbf{v}_k.$$

Erityistapaus tästä nähtiin jo Esimerkissä 1.11, jossa tutkittiin säätilan muutosta Markovin ketjulla. Lineaarisilla rekursioilla voidaan kuvata monia reaalimaailman ilmiöitä, ja erityisesti Markovin ketjuilla voidaan mallintaa erilaisia stokastisia prosesseja.

Miten ominaisarvot liittyvät asiaan? Havainnollistetaan esimerkillä, jossa käytössä on Esimerkin 7.1 matriisi

$$A = \begin{pmatrix} 2 & 1 \\ 0 & -1 \end{pmatrix}.$$

Jos vektorijonon $(\mathbf{v}_k)$ ensimmäinen jäsen on jokin matriisin A ominaisvektori, esimerkiksi ominaisarvoa 2 vastaava ominaisvektori $\mathbf{v}_0 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$, niin

$$\mathbf{v}_1 = A\mathbf{v}_0 = 2\mathbf{v_0}, \quad \mathbf{v}_2 = A\mathbf{v}_1 = 4\mathbf{v_0}, \quad \text{ja yleisesti} \quad \mathbf{v}_k = 2^k\mathbf{v_0}.$$

Sen sijaan jos matriisilla A kerrotaan ominaisarvoa -1 vastaavaa ominaisvektoria $\mathbf{w}_0 = \begin{pmatrix} 1 \\ -3 \end{pmatrix}$ toistuvasti, vastaa tämä joka askeleella luvulla -1 kertomista. Siis rekursio tuottaa vektorijonon

$$\mathbf{w}_0,\ -\mathbf{w}_0,\ \mathbf{w}_0,\ -\mathbf{w}_0,\ \mathbf{w}_0,\ -\mathbf{w}_0,\ \ldots$$

Entä jos alkuarvo ei ole kummankaan ominaisvektorin suuntainen, esimerkiksi $\mathbf{u}_0 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$? Huomataan, että ominaisvektorit $\mathbf{v}_0$ ja $\mathbf{w}_0$ ovat lineaarisesti riippumattomia, joten ne muodostavat kaksiulotteiselle avaruudelle $\mathbb{R}^2$ kannan. Täten myös $\mathbf{u}_0$ voidaan esittää kantavektoreiden avulla:

$$\mathbf{u}_0 = x\mathbf{v}_0 + y\mathbf{w}_0 \quad \text{joillain kertoimilla} \quad x, y \in \mathbb{R}.$$

Nämä kertoimet voidaan määrittää ratkaisemalla vastaava lineaarinen yhtälöryhmä, tai vaikka arvaamalla. Vastaukseksi saadaan joka tapauksessa:

$$\mathbf{u}_0 = \frac{2}{3}\mathbf{v}_0 + \frac{1}{3}\mathbf{w}_0.$$

Nyt jos muodostetaan jono $(\mathbf{u}_k)$ samalla rekursiolla $\mathbf{u}_{k+1} = A\mathbf{u}_k$, niin

$$\begin{aligned}
\mathbf{u}_0 &= \frac{2}{3}\mathbf{v}_0 + \frac{1}{3}\mathbf{w}_0 \\
\mathbf{u}_1 = A\mathbf{u}_0 &= 2 \cdot \frac{2}{3}\mathbf{v}_0 + (-1) \cdot \frac{1}{3}\mathbf{w}_0 \\
\mathbf{u}_2 = A\mathbf{u}_1 &= 2^2 \cdot \frac{2}{3}\mathbf{v}_0 + (-1)^2 \cdot \frac{1}{3}\mathbf{w}_0 \\
\mathbf{u}_3 = A\mathbf{u}_2 &= 2^3 \cdot \frac{2}{3}\mathbf{v}_0 + (-1)^3 \cdot \frac{1}{3}\mathbf{w}_0 \\
&\vdots
\end{aligned}$$

Tästä voidaan päätellä yleinen kaava $\mathbf{u}_k = 2^k \cdot \frac{2}{3}\mathbf{v}_0 + (-1)^k \cdot \frac{1}{3}\mathbf{w}_0$, joka antaa rekursiolle tarkan ratkaisun.

Tarinan opetus. Jos matriisin A ominaisvektoreista voidaan muodostaa kanta avaruudelle $\mathbb{R}^n$, niin tässä kannassa matriisilla A kertominen vastaa vain kantavektoreiden

suuntaista venytystä. Tällä tavalla myös monimutkaiset lineaariset rekursioprosessit voidaan ratkaista eksplisiittisesti.

Tässä esitetyssä ilmiössä on kyseessä hieno käsite nimeltä **diagonalisaatio**. Esittelemme hetken päästä, mitä tämä käsite pitää sisällään, mutta pohjustetaan aihetta ensin tutkimalla ominaisvektoreiden perusominaisuuksia.

Ominaisavaruudet

Joissain tapauksissa samaa ominaisarvoa voi vastata useampi erisuuntainen ominaisvektori. Esimerkiksi identiteettimatriisilla on vain yksi ominaisarvo 1, jolle jokainen vektori on ominaisvektori. Tällaisten tapausten takia on luonnollista puhua matriisin A ominaisarvon λ **ominaisavaruudesta**, joka on kaikkien ominaisarvoa λ vastaavien ominaisvektoreiden joukko. Tämä joukko on luonnollisesti aliavaruus (pohdi miksi).

Jos $\lambda = 0$ on matriisin ominaisarvo, niin sitä vastaava ominaisavaruus on sama asia, kuin matriisin A ydin $\operatorname{Ker} A$. Vastaavasti jos ydin $\operatorname{Ker} A$ on joku muu, kuin triviaali aliavaruus $\{0\}$, niin matriisin A eräs ominaisarvo on $\lambda = 0$.

Esimerkki 7.3. Matriisin

$$A = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{pmatrix}$$

Karakteristinen polynomi on

$$\det(A - \lambda I) = -\lambda(2 - \lambda)^2.$$

Sillä on siis kaksi ominaisarvoa, 0 ja 2. Vastaavat ominaisvektorit voidaan laskea samalla tavalla, kuin Esimerkissä 7.1, ja lopputuloksena saadaan pienen laskun jälkeen

$$\lambda = 0: \text{ Ominaisvektori on muotoa } \mathbf{v} = x \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \qquad x \in \mathbb{R}.$$

$$\lambda = 2: \text{ Ominaisvektori on muotoa } \mathbf{v} = x \begin{pmatrix} 1 \\ 2 \\ 0 \end{pmatrix} + y \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}, \qquad x, y \in \mathbb{R}.$$

Tarkista laskemalla, että nämä vektorit todellakin ovat ominaisarvoja vastaavat ominaisvektorit vertaamalla määritelmän kaavaan $A\mathbf{v} = \lambda\mathbf{v}$.

Siis tapauksessa $\lambda = 0$ vastaava ominaisavaruus on yksiulotteinen suora, jonka virittää vektori $\begin{pmatrix} 1 & 0 & 0 \end{pmatrix}^T$, ja tapauksessa $\lambda = 2$ ominaisavaruus on taso, jonka virittävät vektorit $\begin{pmatrix} 1 & 2 & 0 \end{pmatrix}^T$ ja $\begin{pmatrix} 0 & 0 & 1 \end{pmatrix}^T$.

Ominaisavaruuden kannan voi toki valita usealla eri tavalla (kuten aliavaruuksilla yleensä), ja tässä esitimme vain yhdet mahdolliset valinnat.

Jokaisella matriisin A ominaisarvolla λ on siis vastaava ominaisavaruus. Tämän ominaisarvon ulottuvuutta sanotaan ominaisarvon λ **geometriseksi kertaluvuksi**.

Ominaisarvolla on myös ns. **algebrallinen kertaluku**, joka vastaa sitä, kuinka monta kertaa ominaisarvoa λ_j vastaava binomi $\lambda - \lambda_j$ jakaa karakteristisen polynomin $p(\lambda)$. Siis edellisessä esimerkissä, jossa karakteristinen polynomi oli

$$p(\lambda) = -\lambda(2-\lambda)^2,$$

ominaisarvon 0 algebrallinen kertaluku on 1 (koska λ jakaa $p(\lambda)$:n kerran), ja ominaisarvon 2 algebrallinen kertaluku on 2 (koska $\lambda - 2$ jakaa $p(\lambda)$:n kaksi kertaa).

Tässä esimerkissä geometriset kertaluvut olivat myös 1 ja 2, eli samat kuin algebralliset kertaluvut. Näin ei kuitenkaan aina käy: Matriisin

$$A = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$$

karakteristinen polynomi on $p(\lambda) = \lambda^2$, eli ainoa ominaisarvo on $\lambda = 0$ algebrallisella kertaluvulla 2, mutta geometrinen kertaluku on 1, sillä ominaisavaruus on yksiulotteinen suora, jonka virittää vektori $\begin{pmatrix} 1 \\ 0 \end{pmatrix}$.

Diagonalisointi

Matriisia, jonka diagonaalin ulkopuoliset alkiot ovat kaikki nollia, kutsutaan **diagonaalimatriisiksi** tai **lävistäjämatriisiksi**. Tutkitaan yleistä diagonaalimatriisia

$$D = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix}.$$

Tätä voidaan merkitä lyhyemmin myös $D = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$. Matriisin D diagonaalialkiot λ_j ovat täsmälleen sen ominaisarvot, ja niitä vastaavat ominaisvektorit ovat standardikannan vektorit $\mathbf{e}_j$.

Sanomme, että neliömatriisi A on **diagonalisoituva**, mikäli löytyy sellainen kääntyvä matriisi S ja diagonaalimatriisi D, jolle

$$A = SDS^{-1}$$

Matriisin diagonalisointi on läheisessä yhteydessä sen ominaisarvoihin.

Lause 7.1. *$n \times n$-Neliömatriisi A on diagonalisoituva tasan silloin, kun sillä on n kappaletta lineaarisesti riippumattomia ominaisvektoreita $\mathbf{v}_1, \ldots, \mathbf{v}_n$. Jos näitä vastaavat ominaisarvot ovat $\lambda_1, \ldots, \lambda_n$, niin matriisi A diagonalisoituu kaavalla*

$$A = SDS^{-1}, \qquad \text{missä } D = \operatorname{diag}(\lambda_1, \ldots, \lambda_n) \quad \text{ja} \quad S = \begin{pmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{pmatrix}.$$

Matriisin diagonalisaatio kertoo siis kaavana sen ilmiön, jonka huomasimme jo tutkiessa lineaarisia rekursioita: Jos matriisin ominaisvektorit muodostavat kannan avaruudelle

$\mathbb{R}^n$, niin tähän kantaan siirtymällä matriisilla A kertomista voidaan tulkita pelkästään venytyksenä uusien kantavektoreiden suuntaisesti. Kaava

$$A = SDS^{-1}$$

ilmaisee tämän konkreettisesti. Oikean puolen matriisi S^{-1} esittää kannanvaihtoa standardikannasta ominaisvektoreiden muodostamaan kantaan, D esittää venytystä uudessa kannassa, ja vasemmalla oleva S esittää paluuta takaisin standardikantaan. Kuten luvussa Käänteismatriisi esittelemämme kannanvaihtomatriisit, S:n sarakkeet koostuvat uuden kannan (ominaisvektorit) esityksestä vanhassa kannassa (standardikanta).

Huom! Suinkaan jokaista neliömatriisia ei voi diagonalisoida. Esimerkiksi matriisin

$$A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$$

ainoa ominaisarvo on $\lambda = 1$, ja tätä ominaisarvoa vastaa ainoastaan ominaisvektori $\begin{pmatrix} 1 \\ 0 \end{pmatrix}$. Ominaisvektoreiden avulla ei siis voida muodostaa kantaa avaruudelle $\mathbb{R}^2$, joten diagonalisaatio on mahdotonta. Tälle tapaukselle on myös seuraava muistisääntö:

> Jos matriisin A ominaisarvon λ geometrinen kertaluku on pienempi, kuin sen algebrallinen kertaluku, matriisia A ei voi diagonalisoida.

Jos matriisi diagonalisoituu, sen determinantti voidaan myös laskea suoraan ominaisarvoista seuraavasti:

Lause 7.2. *Olkoon $n \times n$-matriisilla A n kappaletta ominaisarvoja, jotka ovat $\lambda_1, \ldots, \lambda_n$. Determinantille pätee tällöin*

$$\det A = \lambda_1 \cdot \lambda_2 \cdot \cdots \cdot \lambda_n.$$

Tämä seuraa varsin suoraan determinantin laskusäännöillä, sillä

$$\det A = \det(SDS^{-1}) = (\det S)(\det D)(\det S)^{-1} = \det D,$$

ja diagonaalimatriisin determinantti on sen alkioidan tulo.

Erityisesti determinantti on nolla tasan silloin, kuin joku ominaisarvoista on nolla. Tämä vastaa luonnollisesti sitä tapausta, kun matriisin A ydin on epätriviaali (vrt. Lause 4.1 ja Lause 6.1).

Esitämme lopuksi vielä täsmällisen todistuksen Lauseelle 7.1.

Lauseen 7.1 todistus. Olkoon matriisi A ensin diagonalisoituva. Jos kerrotaan oikealta puolelta matriisilla S, saadaan diagonalisaatiolle myös muoto $AS = SD$. Jos nyt S on sarakemuodossa $S = \begin{pmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{pmatrix}$, niin standardikantavektoreita $\mathbf{e}_j$ kertomalla saadaan

$$A\mathbf{v}_j = AS\mathbf{e}_j = SD\mathbf{e}_j = S(\lambda \mathbf{e}_j) = \lambda \mathbf{v}_j.$$

Tästä voidaan päätellä suoraan, että diagonalisaatiossa esiintyvän matriisin S sarakkeet paljastavat matriisin A ominaisvektorit, ja niitä vastaavat ominaisarvot löytyvät matriisin D diagonaalilta.

Jos taas matriisilla A on n lineaarisesti riippumatonta ominaisvektoria $\mathbf{v}_1, \ldots, \mathbf{v}_n$, niin määritellään S ja D kuten edellä. Koska matriisin S sarakkeet ovat lineaarisesti riippumattomia, se on kääntyvä. Koska kaava $AS\mathbf{e}_j = SD\mathbf{e}_j$ pätee kaikilla standardikannan vektoreilla $\mathbf{e}_j$, se pätee lineaarisuuden perusteella myös jokaisella avaruuden $\mathbb{R}^n$ vektorilla. Siis $AS = SD$, eli $A = SDS^{-1}$.

Symmetrisen matriisin diagonalisointi

Osoittautuu, että jokaisen symmetrisen matriisin voi diagonalisoida, jopa niin, että matriisi S valitaan ortogonaaliseksi. Tämä tulos tunnetaan myös reaalisten symmetristen matriisien **spektrilauseena**.

Lause 7.3. *Olkoon A symmetrinen matriisi. Tällöin on olemassa ortogonaalinen matriisi Q siten, että*

$$A = QDQ^{-1},$$

missä $D = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$ on diagonaalimatriisi. Tällöin luvut λ_j ovat matriisin A ominaisarvot, ja matriisin Q sarakkeet ovat niitä vastaavat ominaisvektorit.

Symmetrisen matriisin diagonaaliesityksen voi kirjoittaa myös muodossa $A = QDQ^T$, sillä ortogonaalisuudesta seuraa $Q^{-1} = Q^T$.

Diagonaaliesityksen ei missään nimessä tarvitse olla yksikäsitteinen. Matriisin Q sarakkeet voidaan jopa järjestää uudelleen haluttuun järjestykseen, sillä tämä ei muuta matriisin Q ortogonaalisuutta (kts. 5.1). Tällöin myös matriisin D diagonaalialkiot eli A:n ominaisarvot järjestyvät uudelleen samaan järjestykseen, kuin niitä vastaavat ominaisvektorit eli Q:n sarakkeet.

Diagonalisoidun matriisin potensseja on helppo laskea, esimerkiksi

$$A^2 = QDQ^{-1}QDQ^{-1} = QD^2Q^{-1},$$

Ja yleisesti $A^k = QD^kQ^{-1}$, sekä $D^k = \operatorname{diag}(\lambda_1^k, \ldots, \lambda_n^k)$.

Spektrilauseen todistus. Lauseen 7.1 perusteella matriisi A diagonalisoituu, jos matriisilla A on n kappaletta lineaarisesti riippumattomia ominaisvektoreita. Tämän lisäksi täytyy myös osoittaa, että kannanvaihtomatriisi Q voidaan valita ortogonaaliseksi.

Tämä jälkimmäinen väite on varsin suoraviivaista todistaa. Nimittäin jos symmetrisellä matriisilla on kahta eri ominaisarvoa λ_1 ja λ_2 vastaavat ominaisvektorit $\mathbf{v}_1$ ja $\mathbf{v}_2$, niin pistetulon laskusäännöillä ja symmetrisyydellä $A^T = A$ saadaan

$$\lambda_1(\mathbf{v}_1 \cdot \mathbf{v}_2) = (A\mathbf{v}_1) \cdot \mathbf{v}_2 = \mathbf{v}_1 \cdot (A^T\mathbf{v}_2) = \mathbf{v}_1 \cdot (A\mathbf{v}_2) = \lambda_2(\mathbf{v}_1 \cdot \mathbf{v}_2).$$

Siis jos $\lambda_1 \neq \lambda_2$, tästä yhtälöstä seuraa välittömästi, että $\mathbf{v}_1 \cdot \mathbf{v}_2 = 0$. Lopputulos:

Symmetrisen matriisin eri ominaisarvoja vastaavat ominaisvektorit ovat kohtisuorassa.

Jokaisen $\mathbb{R}^n$:n aliavaruuden kannan voi valita ortonormaaliksi, joten erityisesti jokaisen A:n ominaisavaruuden kannan voi valita ortonormaaliksi. Nämä ortonormaalit ominaisvektorit muodostavat yhdessä myös ortonormaalin jonon, sillä edellisen huomion perusteella myös eri ominaisavaruuksien ominaisvektorit ovat kohtisuorassa.

Siis mikäli nämä ominaisvektorit virittävät yhdessä koko avaruuden $\mathbb{R}^n$, niin niiden muodostama ortonormaali jono voidaan asettaa sarakkeiksi kannanvaihtomatriisiin Q, joka on ortonormaali Lauseen 5.1 perusteella.

Seuraavaksi: Osoitetaan vielä, että matriisilla A on todellakin n kappaletta lineaarisesti riippumattomia ominaisvektoreita.

Vaikka väitteemme koskee vain reaalisia matriiseja A, tarvitsemme tähän osaan todistusta myös kompleksilukuja. Syy tähän piilee karakteristisessa polynomissa: Matriisin A ominaisarvot määräytyvät karakteristisen polynomin juurista, mutta kaikilla polynomeilla ei välttämättä ole reaalisia juuria. Sen sijaan kompleksitasossa pätee seuraava vahva tulos.

Algebran peruslause: Jokaisella polynomilla astetta n on tasan n juurta kompleksitasossa, mukaanlukien juurten kertaluvut.

Esimerkiksi polynomilla $x^2 + 1$ ei ole reaalisia juuria, mutta kompleksitasossa sille löytyy helposti juuret $x = \pm i$.

Matriisin normi

Vektoreilla on määritelty pituus, ja tämä tekee myös vektoreiden vertaamisesta toisiinsa helppoa: Kahden vektorin $\mathbf{v}, \mathbf{w}$ etäisyys voidaan määritellä lausekkeeksi $|\mathbf{v} - \mathbf{w}|$.

Mutta monessa tilanteessa myös matriisien vertaaminen toisiinsa on tarpeellista, ja tätä varten meidän täytyy määritellä myös matriiseille pituutta/etäisyyttä vastaava käsite eli **normi**. Tähän on monta mielekästä valintaa, ja useimmat niistä ovat jossain määrin ekvivalentteja keskenään. Tyypillisin tapa mitata matriisin suuruutta on kuitenkin **operaattorinormi**:

$$\boxed{\|A\| = \sup_{|\mathbf{v}|=1} |A\mathbf{v}|}$$

Operaattorinormi siis mittaa matriisin A suurinta mahdollista venytystä yksikkövektoreilla $\mathbf{v}$. Tämä on mielekäs käsite, sillä se toteuttaa normien perusominaisuudet:

- **Kolmioepäyhtälö:** $\|A + B\| \leq \|A\| + \|B\|$.
- **Absoluuttinen homogeenisuus:** $\|\lambda A\| = |\lambda|\|A\|$, kun $\lambda \in \mathbb{R}$.
- **Positiividefiniittiys:** $\|A\| = 0 \Leftrightarrow A = 0$.

Lisäksi operaattorinormilla on se näppärä ominaisuus, että $|A\mathbf{v}| \leq \|A\||\mathbf{v}|$ kaikilla vektoreilla $\mathbf{v}$. Tästä seuraa varsin suoraan myös tärkeä ominaisuus:

$$\boxed{\|AB\| \leq \|A\|\|B\|} \tag{7.1}$$

Muitakin vaihtoehtoja matriisin normille on, kuten esimerkiksi **Hilbert-Schmidt normi**

$$\|A\|_2 = \sqrt{\sum_{i=1}^{m}\sum_{j=1}^{n}|a_{ij}|^2}, \qquad \text{missä } A = (a_{ij}).$$

Operaattorinormi ja Hilbert-Schmidt normi ovat toisiinsa verrannollisia.

Mikäli neliömatriisi A on symmetrinen, voidaan sen operaattorinormi laskea ominaisarvojen avulla. Nimittäin tällöin pätee

$$\|A\| = \max_{i=1,\dots,n} |\lambda_i|,$$

eli A:n operaattorinormi on sen ominaisarvojen itseisarvoista suurin. Tämä voidaan päätellä melko suoraviivaisesti:

- Jos diagonaalimatriisin $D = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$ ominaisarvoista λ_i on se, jonka itseisarvo $|\lambda_i|$ on suurin, niin

  $$|D\mathbf{v}| = \sqrt{|\lambda_1 v_1|^2 + \cdots + |\lambda_n v_n|^2} \leq \sqrt{|\lambda_i|^2\left(|v_1|^2 + \cdots + |v_n|^2\right)} = |\lambda_i||\mathbf{v}|.$$

  Siispä diagonaalimatriisi venyttää vektoreita enintään kertoimella $|\lambda_i|$.

- Ortogonaalinen matriisi säilyttää vektoreiden pituudet (kts. Lause 5.1), joten sellaisella kertominen vasemmalta tai oikealta ei muuta matriisin operaattorinormia.

Siis diagonalisaatiosta $A = QDQ^{-1}$ seuraa

$$\|A\| = \|QDQ^{-1}\| = \|D\| = \max_{i=1,\dots,n} |\lambda_i|.$$

Huom! Tämä väite ei välttämättä päde epäsymmetrisille matriiseille A, esimerkiksi matriisin $\begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$ ainoa ominaisarvo on 0, mutta sen operaattorinormi on 1.

Matriisin normi antaa meille erityisesti tavan puhua myös käsitteistä kuten matriisien suppeneminen. Yksi yllättävä seuraus tästä on mahollisuus määritellä neliömatriisille A eksponenttifunktio e^A.

Matriisien eksponenttifunktio

Tähänastisten matriisien laskusääntöjen opettelemisen jälkeen käsite matriisin A eksponenttifunktiosta e^A voi vaikuttaa hieman järjettömältä. Osoittautuu kuitenkin, että tämä käsite ei ole pelkästään luonnollista määritellä, vaan sillä on myös liuta käytännön sovelluksia, kuten zombiepidemian torjumisessa (kts. Esimerkki 7.4 alla).

Differentiaalilaskennasta on tuttua, että eksponenttifunktio e^x voidaan kehittää Taylorin sarjana

$$e^x = \sum_{k=0}^{\infty} \frac{x^k}{k!} = 1 + x + \frac{x^2}{2} + \frac{x^3}{6} + \cdots.$$

Tämän sarjakehityksen perusteella on järkevä myös määritellä neliömatriisille A **eksponenttifunktio**

$$e^A = \sum_{k=0}^{\infty} \frac{A^k}{k!} = I + A + \frac{A^2}{2} + \frac{A^3}{6} + \cdots,$$

mikäli pystymme selittämään, mitä tällaisen matriisimuotoisen sarjan suppeneminen tarkoittaa. Tämä on mahdollista tehdä tarkasti pienellä vaivalla operaattorinormin avulla, etenkin hyödyntäen kaavaa (7.1). Jokaiselle termille sarjassa pätee

$$\left\| \frac{A^k}{k!} \right\| \leq \frac{\|A\|^k}{k!} \to 0, \qquad \text{kun } k \to 0,$$

sillä kertomafunktio $k!$ kasvaa huomattavasti nopeammin kuin mikään eksponenttifunktio. Samasta syystä saadaan myös vahvempi arvio

$$\frac{2^k \|A\|^k}{k!} \to 0 \qquad \Rightarrow \qquad \frac{\|A\|^k}{k!} \leq \frac{1}{2^k} \quad \text{riittävän suurilla } k.$$

Siis ainakin lausekkeen e^A määrittävän sarjan yksittäisen termin $\frac{A^k}{k!}$ operaattorinormi menee riittävän nopeasti kohti nollaa. Tästä voidaan päätellä, että osasummien muodostama matriisijono

$$I,\ I + A,\ I + A + \frac{A^2}{2},\ I + A + \frac{A^2}{2} + \frac{A^3}{6},\ \ldots$$

suppenee kohti jotain matriisia, ja tätä raja-arvoa merkitään e^A. Tässä on vielä se pieni epätäsmällisyys, että emme vielä tarkasti määritelleet matriisijonon suppenemista. Tarkasta määritelmästä kiinnostunut lukija löytää sen monisteen lopussa olevasta luvusta Täydennyksiä.

Lopputulos: Siis matriisien eksponenttifunktio e^A on hyvin määritelty yllä olevan potenssisarjan kautta jokaiselle neliömatriisille A, ja määrittelee samankokoisen neliömatriisin.

Eksponenttifunktiolle pätee myös seuraava näppärä kaava: Mikäli matriisit A ja B **kommutoivat**, eli $AB = BA$, pätee

$$e^{A+B} = e^A e^B.$$

Tämä ei toki päde yleisesti. Mutta esimerkiksi $e^{(t+s)A} = e^{tA} e^{sA}$ kaikille $t, s \in \mathbb{R}$.

Tutkitaan seuraavaksi matriisieksponenttifunktion sovelluksia, joita on yllättävän paljon.

Esimerkki 7.4. Zombit ovat päässeet valloilleen, ja ihmiskunta pyrkii taistelemaan zombi-invaasiota vastaan. Mallinnetaan ihmispopulaation kehitystä kolmella eri ajasta riippuvalla suureella:

- Ihmisten määrä $H(t)$.
- Kuolleiden määrä $D(t)$.
- Zombien määrä $Z(t)$.

Sovitaan, että nämä ovat derivoituvia reaaliarvoisia funktioita, vaikka todellisuudessa lukumäärät olisivat kokonaislukuja. Selvitetään seuraavaksi, miten suureet riippuvat toisistaan.

Ihmisiä syntyy/kuolee lisää suhteessa ihmisten tämänhetkiseen määrään, ja heitä kuolee lisäksi zombien kanssa taistellessa. Siis saadaan yhtälö

$$H'(t) = \alpha H(t) - \beta Z(t),$$

missä α, β ovat positiivisia vakioita. Kuolleiden määrä kasvaa suhteessa ihmisten määrään, mutta vähenee suhteissa kuolleiden tämänhetkiseen määrään, kun osa kuolleista nousee zombeina ylös. Siis

$$D'(t) = \gamma H(t) - \lambda D(t),$$

missä γ, λ ovat positiivisia vakioita. Zombien määrä kasvaa suhteessa kuolleiden määrään samassa suhteessa $\lambda D(t)$, mutta vähenee suhteessa ihmisten määrään, kun ihmiset taistelevat vastaan. Siis

$$Z'(t) = \lambda D(t) - \tau H(t),$$

missä τ on positiivinen vakio. Nämä kolme yhtälöä voidaan kirjoittaa myös vektorimuodossa

$$\mathbf{v}'(t) = A\mathbf{v}(t), \qquad \text{missä } \mathbf{v} = \begin{pmatrix} H \\ D \\ Z \end{pmatrix}, \ A = \begin{pmatrix} \alpha & 0 & -\beta \\ \gamma & -\lambda & 0 \\ -\tau & \lambda & 0 \end{pmatrix}.$$

Tämä on yleinen esimerkki lineaarisesta vakiokertoimisesta differentiaaliyhtälösysteemistä. Differentiaalilaskennasta saattaa olla tuttua, että tavallisen differentiaaliyhtälön

$$y'(t) = ky(t) \quad \text{ yleinen ratkaisu on } \quad y(t) = Ce^{kt}.$$

Vastaavasta syystä vektorimuotoisen yhtälön ratkaisu saadaan myös eksponenttifunktiosta, nimittäin yleinen ratkaisu tulee kaavasta

$$\mathbf{v}(t) = e^{tA}\mathbf{v}_0 \quad \text{ alkuarvosta määräytyvällä vakiovektorilla } \mathbf{v}_0 \in \mathbb{R}^3.$$

Tämä siksi, että matriisien eksponenttifunktion määrittävää sarjaa voi derivoida termeittäin:

$$\begin{aligned} \frac{d}{dt}\mathbf{v}(t) &= \frac{d}{dt}e^{tA}\mathbf{v}_0 = \frac{d}{dt}\left(\sum_{k=0}^{\infty} t^k \frac{A^k}{k!}\right)\mathbf{v}_0 = \left(\sum_{k=0}^{\infty} \frac{d(t^k)}{dt}\frac{A^k}{k!}\right)\mathbf{v}_0 \\ &= \left(\sum_{k=1}^{\infty} kt^{k-1}\frac{A^k}{k!}\right)\mathbf{v}_0 = \left(\sum_{k=1}^{\infty} At^{k-1}\frac{A^{k-1}}{(k-1)!}\right)\mathbf{v}_0 = \left(A\sum_{k=0}^{\infty} t^k\frac{A^k}{(k)!}\right)\mathbf{v}_0 \\ &= A\mathbf{v}(t). \end{aligned}$$

Siispä $\mathbf{v}(t) = e^{tA}\mathbf{v}_0$ antaa tarkan ratkaisun ongelmalle, kun alkutila $\mathbf{v}(0) = \mathbf{v}_0$ ajanhetkellä $t = 0$ tunnetaan.

Tämä malli ei toki sovellu ainoastaan zombi-invaasioiden ja yleisten populaatiomallien tutkimiseen, vaan lineaarisilla differentiaaliyhtälösysteemeillä voidaan mallintaa monia muita todellisen elämän ilmiöitä kuten lämmön jakautumista, virtapiirejä, ei-diskreettejä Markovin prosesseja, yms.

Esimerkki 7.5. Tyypillinen toisen asteen lineaarinen vakiokertoiminen differentiaaliyhtälö on muotoa

$$f''(t) = \alpha f'(t) + \beta f(t).$$

Kirjoitetaan yhtälö kuitenkin eri muodossa määrittelemällä $g(t) = f'(t)$, jolloin yhtälö menee vektorimuotoon

$$\begin{pmatrix} f'(t) \\ g'(t) \end{pmatrix} = \begin{pmatrix} g(t) \\ \alpha g(t) + \beta f(t) \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ \beta & \alpha \end{pmatrix}\begin{pmatrix} f(t) \\ g(t) \end{pmatrix}.$$

Tämä on samanlainen vektorimuotoinen ensimmäisen asteen differentiaaliyhtälö kuin edellisessä esimerkissä, joten se ratkaistaan jälleen matriisieksponenttifunktion avulla.

Esimerkissä 7.4 toki jäi vielä selvittämättä, mitä ihmiskunnalle lopulta tapahtuu zombi-invaasiossa, eli miten ratkaisu

$$\mathbf{v}(t) = e^{tA}\mathbf{v}_0$$

kehittyy ajan t myötä. Tämä riippuu toki täysin alkuvektorista $\mathbf{v}_0$ ja matriisin A ominaisuuksista. Tärkeä huomio on, että jos A diagonalisoituu muotoon $A = SDS^{-1}$, niin $A^k = SD^kS^{-1}$ ja täten myös eksponenttifunktion määrittävä potenssisarja voidaan sieventää muotoon (pohdi miksi):

$$e^{tA} = e^{tSDS^{-1}} = Se^{tD}S^{-1}.$$

Lisäksi $e^{tD} = \operatorname{diag}(e^{t\lambda_1}, \ldots, e^{t\lambda_n})$. Tästä voidaan päätellä, että matriisin A ominaisarvot vaikuttavat vahvasti ratkaisuvektorin käyttäytymiseen. Ominaisarvojen positiivisuus/negatiivisuus määrää sen, kasvaako ratkaisuvektori rajatta, vai suppeneeko se. Havainnollistetaan esimerkeillä:

- Olkoon matriisi $A = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}$, jonka ominaisarvot ovat 2 ja 1. Tällöin ratkaisuvektori on muotoa
$$\mathbf{v}(t) = e^{tA}\mathbf{v}_0 = \begin{pmatrix} e^{2t}x_0 \\ e^{t}y_0 \end{pmatrix}.$$
Tämä kasvaa molemmissa komponenteissa rajatta, jos alkukoordinaatit $x_0, y_0 \neq 0$.
- Olkoon matriisi $A = \begin{pmatrix} -1 & 0 \\ 0 & -2 \end{pmatrix}$, jonka ominaisarvot ovat -1 ja -2. Tällöin ratkaisuvektori on muotoa
$$\mathbf{v}(t) = e^{tA}\mathbf{v}_0 = \begin{pmatrix} e^{-t}x_0 \\ e^{-2t}y_0 \end{pmatrix}.$$
Tämä vektori lähestyy hyvin nopeasti nollavektoria ajan kasvaessa.
- Olkoon matriisi $A = \begin{pmatrix} 0 & 1 \\ 0 & -1 \end{pmatrix}$, jonka ominaisarvot ovat 0 ja -1. Tällöin ratkaisuvektori voidaan pienellä vaivalla laskea muotoon
$$\mathbf{v}(t) = e^{tA}\mathbf{v}_0 = \begin{pmatrix} x_0 + (1 - e^{-t})y_0 \\ e^{-t}y_0 \end{pmatrix}.$$
Tämä vektori suppenee nopeasti vektoriin $\begin{pmatrix} x_0 + y_0 \\ 0 \end{pmatrix}$.

Mahdolliset kompleksiset ominaisarvot aikaansaavat ratkaisuissa oskillaatiota. Esimerkiksi matriisin

$$A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$$

ominaisarvot ovat $\pm i$, ja ratkaisuvektori voidaan pienellä vaivalla laskea muotoon

$$\mathbf{v}(t) = \begin{pmatrix} \sin(t)x_0 \\ \cos(t)y_0 \end{pmatrix},$$

tai huomata suoralla laskulla, että tälle vektorille $\mathbf{v}'(t) = A\mathbf{v}(t)$ (tarkista!).

Esimerkki 7.6. (Googlen PageRank-algoritmi) 2000-luvun alussa Google nousi verkon suosituimmaksi hakukoneeksi, ja yksi tärkeä syy tähän oli yhtiön käytössä oleva hakualgoritmi PageRank. Google-haussa käyttäjä syöttää hakusanan, ja hakukoneen tehtävänä on

1) Löytää hakusanaa vastaavat verkkosivut.

2) Järjestää ne tärkeysjärjestyksessä.

Nimestä voi ehkä jo arvata, että PageRank-algoritmin tavoite oli ratkaista jälkimmäinen näistä tehtävistä. Mutta tämä herättää kysymyksen:

Mikä tekee yhdestä verkkosivusta tärkeämmän kuin toinen?

Yksi tärkeyden mittari voisi olla se, kuinka monelta muulta verkkosivulta on linkki kyseiselle verkkosivulle. Mutta jos tilanne olisi vaikka seuraava:

- Verkkosivulle A on linkki sadalta eri sivulta, mutta nämä sata sivua eivät ole kovin tärkeitä.
- Verkkosivulle B on linkki vain kymmeneltä sivulta, ja jokainen näistä kymmenestä sivusta on hyvin tärkeä.

Tässä tapauksessa olisi kuitenkin järkevää, että sivu B järjestettäisiin tärkeämmäksi kuin sivu A. On siis mielekästä, että tärkeysjärjestys ottaa jollain tavalla huomioon koko internetin rakenteen, ja korostaa niitä sivuja, jotka ovat jossain mielessä keskeisessä asemassa.

Yksi luonnollinen tapa mallintaa tätä on seuraava: Otetaan käyttäjä A, ja asetetaan hänet satunnaiselle verkkosivulle. Jos verkkosivuja on yhteensä N kappaletta (2000-luvun alussa $N \approx 800$ miljoonaa), niin todennäköisyys, että käyttäjä A on tietyllä verkkosivulla on $1/N$. Tätä voisi ilmaista asettamalla todennäköisyydet pystyvektoriin

$$\mathbf{p}_0 = \begin{pmatrix} 1/N \\ 1/N \\ \vdots \\ 1/N \end{pmatrix}, \qquad \mathbf{p}_0 \in \mathbb{R}^N.$$

Seuraavaksi käyttäjä A lähtee liikkumaan verkkosivuilla. Jos hän on ensin sivulla i, niin hän valitsee sivulta i satunnaisesti jonkin linkin, ja päätyy täten uudelle sivulle j. Tätä siirtymää voidaan ilmaista käyttämällä valtavaa siirtymämatriisia $M \in \mathbb{R}^{N\times N}$, joka muodostetaan seuraavasti:

- Asetetaan ensin matriisin M kohtaan (j, i) alkio 1, jos sivulta i on linkki sivulle j.
- Normalisoidaan jokainen sarake niin, että sarakkeen lukujen summa on 1. Siis jokainen sarake jaetaan sillä olevien ykkösten (eli linkkien) lukumäärällä.
- Jos jollekin sarakkeelle jää pelkkiä nollia (eli sitä vastaavalla sivulla ei ole linkkejä), asetetaan sen alkioiksi tasajakauma $1/N, 1/N, \ldots$. Siis jos käyttäjä A päätyy tällaiselle sivulle, hän hyppää sieltä pois satunnaiselle verkkosivulle.

Näin saatu matriisi ilmaisee siirtymätodennäköisyyksiä eri sivuilta toisille, ja (kuten Esimerkissä 1.11) käyttäjän A todennäköisyysjakauma, kun hän on kulkenut k:n eri linkin kautta, voidaan laskea vektorista $M^k\mathbf{p}_0$. Esimerkiksi kolmen verkkosivun tapauksessa tilanne voisi näyttää tältä:

$$M = \begin{pmatrix} 1/3 & 1/2 & 0 \\ 1/3 & 0 & 1 \\ 1/3 & 1/2 & 0 \end{pmatrix}, \qquad \mathbf{p}_0 = \begin{pmatrix} 1/3 \\ 1/3 \\ 1/3 \end{pmatrix}.$$

Tällöin yhden klikkauksen jälkeen todennäköisyysjakauma on

$$M\mathbf{p}_0 = \begin{pmatrix} 1/3 & 1/2 & 0 \\ 1/3 & 0 & 1 \\ 1/3 & 1/2 & 0 \end{pmatrix} \begin{pmatrix} 1/3 \\ 1/3 \\ 1/3 \end{pmatrix} = \begin{pmatrix} 5/18 \\ 4/9 \\ 5/18 \end{pmatrix}.$$

Lisäksi mallia voidaan hienosäätää vielä seuraavasti: Sen sijaan, että käyttäjä A seuraa aina linkkejä eteenpäin, on myös pieni todennäköisyys $\beta > 0$, että hän hyppää sieltä täysin satunnaiselle verkkosivulle. Tyypillinen esimerkkiarvo on $\beta = 0.15$. Tällöin siirtymämatriisina käytetään matriisia:

$$G = (1 - \beta)M + \beta \frac{1}{N} \mathbf{e}\mathbf{e}^T,$$

missä $\mathbf{e}$ on $N \times 1$-vektori, jonka kaikki alkiot ovat ykkösiä. Tällöin $\mathbf{e}\mathbf{e}^T$ on $N \times N$-matriisi, jonka kaikki alkiot ovat ykkösiä. Siis edellisessä esimerkissämme:

$$G = 0.85 \begin{pmatrix} 1/3 & 1/2 & 0 \\ 1/3 & 0 & 1 \\ 1/3 & 1/2 & 0 \end{pmatrix} + 0.15 \cdot \frac{1}{3} \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix} = \begin{pmatrix} 1/3 & 19/40 & 1/20 \\ 1/3 & 1/20 & 9/10 \\ 1/3 & 19/40 & 1/20 \end{pmatrix}.$$

Jos muodostamme nyt lineaarisella rekursiolla vektorijonon

$$\mathbf{p}_{k+1} = G\mathbf{p}_k, \qquad \mathbf{p}_0 = \frac{1}{N}\mathbf{e},$$

niin osoittautuu, että tämä suppenee varsin nopeasti kohti kiintopistettä $\mathbf{p}$, jolle $\mathbf{p} = G\mathbf{p}$ (Google käytti historiallisesti n. 50-100 iteraatiota päästäkseen sopivan lähelle). Tämä vektori $\mathbf{p}$ ilmaisee komponenteissaan todennäköisyysjakauman, että satunnaisesti internetissä liikkuva käyttäjä A selaa tietyllä hetkellä kutakin verkkosivua. Tätä jakaumaa voidaan käyttää mittarina verkkosivun tärkeydelle hakukoneessa.

Toki jakaumaa ei tarvitse laskea uudestaan jokaisella Google-haulla, vaan Google voi päivittää jakaumansa esim. kerran viikossa, ja käyttää sitä kaikkien hakujen tulosten järjestämiseen.

Pohditaan vielä, mitä tässä oikein tapahtuu matemaattisesti. Muodostetut siirtymämatriisit M ja G ovat ns. **stokastisia matriiseja**, eli niiden kaikki alkiot ovat ei-negatiivisia, ja jokaisen sarakkeen lukujen summa on 1. Stokastiset matriisit kuvaavat satunnaisesti kehittyviä asteittaisia prosesseja, ja niiden muodostamaa lineaarista rekursiota sanotaan siis Markovin ketjuksi.

Selvitettävä kiintopistevektori $\mathbf{p}$, jolle siis $\mathbf{p} = G\mathbf{p}$, on määritelmän mukaan matriisin G ominaisvektori ominaisarvolla 1. On yksinkertainen syy, miksi tällainen ominaisvektori aina löytyy. Nimittäin matriisin G^T rivien alkioiden summa on aina 1, joten vektori

$$\mathbf{e} = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix}$$

on aina ominaisvektori transpoosille G^T (pohdi miksi). Koska transpoosilla G^T on ominaisarvo 1, myös matriisilla G on sama ominaisarvo, sillä karakteristisesta polynomista saadaan

$$0 = \det(G^T - I) = \det(G - I)^T = \det(G - I).$$

Lisäksi stokastiselle matriisille on varsin helppo osoittaa, että $|G\mathbf{v}| \leq |\mathbf{v}|$, joten ykköstä suurempia ominaisarvoja ei voi löytyä. On myös mahdollista osoittaa, että matriisin G ykköstä vastaava ominaisvektori $\mathbf{p}$ on yksikäsitteinen, eli sen geometrinen kertaluku on yksi. Tämä käyttää vahvasti sitä tietoa, että matriisin G kaikki alkiot ovat positiivisia. Esimerkiksi identiteettimatriisi

$$I = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

on stokastinen matriisi, mutta sen ykköstä vastaavan ominaisvektorin geometrinen kertaluku on kaksi.

On myös mahdollista näyttää, että tässä valitulla siirtymätodennäköisyysmatriisilla G iteraatio $\mathbf{p}_{k+1} = G\mathbf{p}_k$ suppenee aina kohti kyseistä kiintopistettä $\mathbf{p}$.

Bonus: Kompleksisten matriisien diagonalisointi

Kompleksisten matriisien diagonalisointi on jossain mielessä yksinkertaisempaa, kuin reaalisten matriisien. Nimittäin spektrilauseen todistuksessa esittelemämme **algebran peruslause** takaa, että jokaisen $n \times n$-kompleksisen matriisin A karakteristisella polynomilla

$$p(\lambda) = \det(A - \lambda I)$$

on kertaluvut mukaanluettuna tasan n kappaletta ominaisarvoja kompleksitasossa.

Siispä kompleksisten matriisien tapauksessa ei tarvitse murehtia siitä, onko ominaisarvoja olemassa tarpeeksi - niiden algebrallisten kertalukujen summa on aina n. Tämän takia kompleksinen matriisi diagonalisoituu täsmälleen silloin, kuin myös geometristen kertalukujen summa on n, eli kun ominaisvektorit virittävät koko avaruuden $\mathbb{C}^n$.

Esimerkiksi luvun alussa esittämämme 90-asteen kiertomatriisi diagonalisoituu kompleksiluvuilla seuraavasti:

$$\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ -i & i \end{pmatrix} \begin{pmatrix} i & 0 \\ 0 & -i \end{pmatrix} \frac{1}{2} \begin{pmatrix} 1 & i \\ 1 & -i \end{pmatrix}.$$

Kompleksisten matriisien vastaava käsite symmetrisille matriiseille on **itseadjungoidut matriisit**. Muistetaan, että kompleksisten matriisien tapauksessa käytetään transpoosin sijasta mielummin adjungaattia A^*. Matriisi A on **itseadjungoitu** eli **hermiittinen**, jos $A^* = A$. Kompleksisten matriisien spektrilause sanoo seuraavaa.

Lause 7.4. *Olkoon A itseadjungoitu kompleksinen matriisi. Tällöin on olemassa matriisi Q siten, että*

- *Matriisi Q on **unitaarinen**, eli $Q^* = Q^{-1}$.*
- *$A = QDQ^*$, missä $D = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$.*

Luvut λ_j ovat matriisin A ominaisarvot, ja matriisin Q sarakkeet ovat niitä vastaavat ominaisvektorit.

8. Neliömuodot

Matematiikassa, erityisesti differentiaalilaskennassa ja optimointiongelmissa, tulee usein vastaan lausekkeita kuten

$$q(x, y) = x^2 + 4xy + 3y^2.$$

Tällainen lauseke on esimerkki (kahden muuttujan) **neliömuodosta**, ja sille on olemassa myös matriisiesitys:

$$q(x, y) = \begin{pmatrix} x & y \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 2 & 3 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}.$$

Matriisiesityksessä kohtiin $(1, 1)$ ja $(2, 2)$ tulee kertoimet termeistä x^2 ja $3y^2$, ja ristitermin $4xy$ kerroin jaettiin kahtia kohtiin $(1, 2)$ ja $(2, 1)$. Näin saatu matriisi $A = \begin{pmatrix} 1 & 2 \\ 2 & 3 \end{pmatrix}$ on symmetrinen. Yleisesti ottaen jokainen symmetrinen $n \times n$-matriisi A määrää **neliömuodon**

$$q : \mathbb{R}^n \to \mathbb{R}, \qquad q(\mathbf{x}) = \mathbf{x}^T A\mathbf{x} = \mathbf{x} \cdot (A\mathbf{x}),$$

jossa esiintyy n muuttujaa, eli $n \times 1$-vektorin $\mathbf{x}$ komponentit.

Huom! Symmetrisyys on tässä lähinnä sopimuskysymys, sillä vaikka lausekkeessa $\mathbf{x}^T B\mathbf{x}$ esiintyvä matriisi B ei olisi symmetrinen, voidaan silti kirjoittaa

$$\mathbf{x}^T B\mathbf{x} = \mathbf{x}^T A\mathbf{x}, \qquad \text{missä } \; A = \frac{B + B^T}{2} \; \text{ on symmetrinen.}$$

Esimerkki 8.1. Kaksi objektia on yhdistetty toisiinsa jousella, ja molemmat on yhdistetty jousilla myös viereisiin seiniin. Jos muuttujat x ja y kuvaavat objektien poikkeamaa lepotilasta, niin suure

$$E(x, y) = \frac{1}{2}k_1 x^2 + \frac{1}{2}k_2 y^2 + \frac{1}{2}k_3 (x - y)^2$$

kuvaa systeemin potentiaalienergiaa kokonaisuudessa. Tämä lauseke on myös neliömuoto.

Definiittiys ja ominaisarvot

Neliömuotojen perusteoria keskittyy ymmärtämään sitä, miten matriisin A ominaisuudet vaikuttavat neliömuodon $q(\mathbf{x}) = \mathbf{x}^T A\mathbf{x}$ saamiin arvoihin. Osoittautuu, että matriisin A ominaisarvot määräävät neliömuodon $q(\mathbf{x}) = \mathbf{x}^T A\mathbf{x}$ yleisen käyttäytymisen täysin. Tämä johtuu siitä, että symmetrinen matriisi A voidaan diagonalisoida

$$A = Q^T DQ, \qquad \text{missä } \; D = \operatorname{diag}(\lambda_1, \ldots, \lambda_n), \; \text{ ja } \; Q \; \text{ on ortogonaalinen.}$$

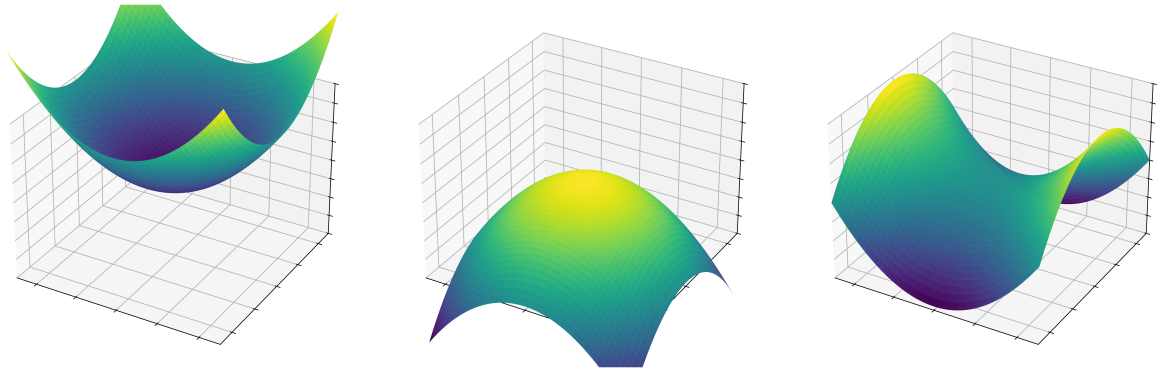
Tällöin voidaan huomata, että koordinaattimuunnos $\mathbf{y} = Q\mathbf{x}$ yksinkertaistaa neliömuotoa huomattavasti muotoon

$$\begin{aligned} q(\mathbf{x}) &= \mathbf{x}^T A\mathbf{x} = \mathbf{x}^T Q^T DQ\mathbf{x} = \mathbf{y}^T D\mathbf{y} \\ &= \lambda_1 y_1^2 + \cdots + \lambda_n y_n^2. \end{aligned}$$

Voimme erityisesti päätellä neliömuodon arvojen positiivisuudesta/negatiivisuudesta suoraan ominaisarvojen perusteella. Oleelliset luokitukset ovat:

Luokka	**Ominaisarvot**	$q(\mathbf{x})$, kun $\mathbf{x} \neq \mathbf{0}$
Positiivisesti definiitti	Kaikki $\lambda_i > 0$	$q(\mathbf{x}) > 0$
Positiivisesti semidefiniitti	Kaikki $\lambda_i \geq 0$	$q(\mathbf{x}) \geq 0$
Negatiivisesti definiitti	Kaikki $\lambda_i < 0$	$q(\mathbf{x}) < 0$
Negatiivisesti semidefiniitti	Kaikki $\lambda_i \leq 0$	$q(\mathbf{x}) \leq 0$
Indefiniitti	Eri merkkisiä ominaisarvoja	$q(\mathbf{x})$ saa molempia merkkejä

Nämä luokitukset koskevat siis sekä neliömuotoja, että niitä vastaavia symmetrisiä matriiseja.



Pos. definiitti Neg. definiitti Indefiniitti

Kuva: Neliömuodon $\mathbf{x} \to \mathbf{x}^T A\mathbf{x}$ kuvaajassa ilmenee sen definiittiys.

Positiivisesti semidefiniitistä matriisista on mahdollista ottaa **matriisimuotoinen neliöjuuri**. Jos nimittäin matriisi A on diagonalisoitu muotoon $A = Q^T DQ$ ja kaikki ominaisarvot λ_i ovat ei-negatiivisia, voidaan määritellä

$$\sqrt{D} = \operatorname{diag}\left(\sqrt{\lambda_1}, \ldots, \sqrt{\lambda_n}\right) \qquad \text{ja} \qquad \sqrt{A} = Q^T DQ.$$

Luonnollisesti tällöin pätee $\left(\sqrt{A}\right)^2 = A$, joten kyseessä todella on järkevä määritelmä matriisin neliöjuurelle.

9. Matriisihajotelmia

Edellisessä luvussa esitelty diagonalisointi on vain yksi monista tavoista jakaa matriisi tuloksi yksinkertaisemmista matriiseista, ja monet muut eri **matriisihajotelmat** ovat vahvoja työkaluja, joita matriisilaskenta tarjoaa käytännön ongelmien ratkaisemiseen. Tutustumme tässä luvussa kahteen uuteen perushajotelmaan nimeltä **LU-hajotelma** ja **SVD-hajotelma**, mutta monia muitakin hyödyllisiä hajotelmia löytyy näiden lisäksi.

LU-hajotelma

Luvussa 3 tutustuimme lineaarisen yhtälöryhmän $A\mathbf{v} = \mathbf{b}$ ratkaisemiseen Gaussin eliminaatiolla. Osoittautuu, että tätä prosessia voidaan soveltaa myös hajoittamaan (harvoja poikkeuksia lukuunottamatta) jokainen neliömatriisi kahden matriisin tuloksi, joista ensimmäinen on **alakolmiomatriisi** ja toinen **yläkolmiomatriisi**. Neliömatriisia sanotaan (ala/ylä)kolmiomatriisiksi, jos sen diagonaalin (ylä/ala)puolella on pelkkiä nollia. Siis esimerkiksi

$$L = \begin{pmatrix} 1 & 0 & 0 \\ 7 & 1 & 0 \\ -1 & 8 & 3 \end{pmatrix} \text{ on alakolmiomatriisi, ja } \quad U = \begin{pmatrix} -2 & 5 & 9 \\ 0 & -1 & 0 \\ 0 & 0 & 4 \end{pmatrix} \text{ on yläkolmiomatriisi.}$$

Jos neliömatriisin A voi esittää muodossa $A = LU$ sopivilla ala/yläkolmiomatriiseilla L ja U, tätä sanotaan sen **LU-hajotelmaksi**. Esimerkiksi 3×3-matriisin LU-hajotelma voisi näyttää tältä:

$$A = \begin{pmatrix} 2 & 1 & 1 \\ 4 & 3 & 3 \\ 8 & 7 & 9 \end{pmatrix} = \underbrace{\begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 4 & 3 & 1 \end{pmatrix}}_{L} \underbrace{\begin{pmatrix} 2 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 2 \end{pmatrix}}_{U} = LU. \tag{9.1}$$

Tulemme näkemään, että LU-hajotelma on oleellisesti matriisimuotoinen Gaussin eliminaatio, ja tästä syystä sen sovelluskohteet ovat myös samat, kuten: Yhtälöryhmien ratkaiseminen, käänteismatriisin muodostaminen, ja determinantin laskeminen. Erityisesti tietokoneet käyttävät pääasiassa LU-hajotelmaa yhtälöryhmien ratkaisemisessa.

LU-hajotelman muodostaminen

Annetun matriisin LU-hajotelman (mikäli sellainen on olemassa) voi löytää soveltamalla Gaussin eliminaatiota matriisiin seuraavasti. Rivioperaatioiden kertoimista täytyy kuitenkin pitää kirjaa, sillä niiden avulla muodostetaan matriisi L. Tutkitaan esimerkkinä matriisia

$$A = \begin{pmatrix} 2 & 1 & 1 \\ 4 & 3 & 3 \\ 8 & 7 & 9 \end{pmatrix}$$

Gaussin eliminaatiolla saadaan

$$\begin{array}{llcllcl} 2 & 1 & 1 & & & 2 & 1 & 1 & & & 2 & 1 & 1 \\ 4 & 3 & 3 & \leftarrow -2 \cdot (\text{Rivi } 1) & \Rightarrow & 0 & 1 & 1 & & \Rightarrow & 0 & 1 & 1 \\ 8 & 7 & 9 & \leftarrow -4 \cdot (\text{Rivi } 1) & & 0 & 3 & 5 & \leftarrow -3 \cdot (\text{Rivi } 2) & & 0 & 0 & 2 \end{array}$$

Lopputulos on porrasmuodossa, ja porrasmuodossa oleva matriisi on täsmälleen haluttu yläkolmiomatriisi U. Alakolmiomatriisi L löytyy palauttamalla mieleen eliminaatiossa tehdyt rivioperaatiot seuraavasti

- Alakolmiomatriisin L diagonaalille asetetaan pelkkiä ykkösiä (ja sen yläpuolelle nollia).
- Jos Gaussin eliminaatiossa riviin j lisättiin rivi i kerrottuna jollain kertoimella a, niin matriisin L kohtaan (j, i) asetetaan tämän kertoimen vastaluku $-a$.

Edellisessä esimerkissä kertoimien vastaluvut olivat 2, 4, ja 3, joten

$$L = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 4 & 3 & 1 \end{pmatrix}.$$

Näin ollaan löydetty hajotelma $A = LU$, joka vastaa yhtälöä (9.1). Sama menetelmä toimii aina, **kun eliminaatiossa rivejä ei tarvitse vaihtaa keskenään**. Mikäli rivien vaihtoja tarvitaan, on olemassa yleisempi PLU-hajotelma, josta lisää hetken päästä. Perustellaan kuitenkin ensin, miksi yllä esitelty menetelmä oikeastaan toimii.

LU-hajotelman todistus: Gaussin eliminaatiossa sovellettuja rivioperaatioita voi tulkita myös matriisimuodossa. Edellisessä esimerkissä matriisille A toteutetut rivioperaatiot

$$\mathbf{R}_2 \Rightarrow \mathbf{R}_2 - 2\mathbf{R}_1, \quad \mathbf{R}_3 \Rightarrow \mathbf{R}_3 - 4\mathbf{R}_1, \quad \text{ja} \quad \mathbf{R}_3 \Rightarrow \mathbf{R}_3 - 3\mathbf{R}_2$$

vastaavat samaa, kuin matriisin A kertoisi vasemmalta puolelta matriiseilla

$$L_{21} = \begin{pmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}, \quad L_{31} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -4 & 0 & 1 \end{pmatrix} \quad \text{ja} \quad L_{32} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -3 & 1 \end{pmatrix}.$$

Siis Gaussin eliminaatiosta saatu lopputulos voidaan ilmaista tässä tapauksessa yhtälönä

$$L_{32}L_{31}L_{21}A = U.$$

Tästä saadaan ratkaistua

$$A = \underbrace{L_{21}^{-1}L_{31}^{-1}L_{32}^{-1}}_{L} U,$$

Sievennetään vielä matriisin L määrittävä tulo. Huomataan, että esimerkiksi rivioperaation L_{32} käänteinen toimenpide on operaatio $\mathbf{R}_3 \Rightarrow \mathbf{R}_3 + 3\mathbf{R}_2$, eli sama operaatio, mutta erimerkkisellä kertoimella. Täten

$$L_{32}^{-1} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 3 & 1 \end{pmatrix}.$$

Jos kirjoitetaan $L = L_{21}^{-1}L_{31}^{-1}L_{32}^{-1}I$, niin voidaan päätellä, että matriisi L voidaan selvittää soveltamalla identiteettimatriisiin I kaikki eliminaatiossa tapahtuneiden operaatioiden käänteisoperaatiot, ja myös käänteisessä järjestyksessä. Tehdään juuri näin:

$$\begin{matrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{matrix} \quad \begin{matrix} \\ \\ \leftarrow +3 \cdot (\text{Rivi } 2) \end{matrix} \quad \Rightarrow \quad \begin{matrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 3 & 1 \end{matrix} \quad \begin{matrix} \\ \\ \leftarrow +4 \cdot (\text{Rivi } 1) \end{matrix} \quad \Rightarrow \quad \begin{matrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 4 & 3 & 1 \end{matrix}.$$

Siis alakolmiomatriisin L diagonaalin alle todellakin tulee eliminaatiossa käytettyjen kertoimien vastaluvut.

PLU-hajotelma

Tarkalleen ottaen syy, miksi rivioperaatioiden kautta muodostuva matriisi L on juuri alakolmiomatriisi perustuu siihen, että rivioperaatioissa jokaiseen riviin lisätään ainoastaan sitä ylempänä olevia rivejä. Tästä syystä LU-hajotelma ei tepsi esimerkiksi matriisille

$$A = \begin{pmatrix} 0 & -1 \\ 1 & 2 \end{pmatrix},$$

sillä tämän matriisin rivit täytyy ensin vaihtaa keskenään. Tämä onnistuu matriisimuodossa kertomalla A vasemmalta ns. **permutaatiomatriisilla**

$$P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix},$$

jolloin siis

$$PA = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & -1 \\ 1 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 2 \\ 0 & -1 \end{pmatrix}.$$

Yleinen permutaatiomatriisi on sellainen neliömatriisi, jonka jokaisella rivillä ja sarakkeella on tasan yksi ykkönen, ja kaikki muut matriisin alkiot ovat nollia. Esimerkiksi

$$P = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix}.$$

Permutaatiomatriisilla kertominen vaihtaa kerrottavan matriisin rivien paikkaa. Esimerkiksi tämä matriisi P vaihtaa rivejä järjestyksessä $1 \to 3 \to 4 \to 2 \to 1$.

Jokaisen neliömatriisin rivit voidaan järjestää uudelleen niin, että edellä esitetty menetelmä tuottaa LU-hajotelma jälleen toimii. Siis jokaiselle neliömatriisille A löytyy permutaatiomatriisi P siten, että

$$PA = LU \qquad \text{tai} \qquad A = P^{-1}LU.$$

Tätä sanotaan PLU-hajotelmaksi.

LU-hajotelman motivaatio

Tässä vaiheessa lukija saattaa vielä pohtia kysymystä:

Miksi tehdä LU-hajotelma? Olemme näyttäneet, että LU/PLU-hajotelman muodostaminen perustuu täysin Gaussin eliminaatioon, joten on syytä pohtia, miksi tehdä tällainen hajotelma, kun voisimme vain käyttää Gaussin eliminaatiota sen sijaan.

Tutkitaan tilannetta, jossa meillä on ratkaistavana tuhat yhtälöryhmää

$$\begin{aligned} A\mathbf{v}_1 &= \mathbf{b}_1 \\ &\vdots \\ A\mathbf{v}_{1000} &= \mathbf{b}_{1000}, \end{aligned}$$

joissa kaikissa esiintyy sama matriisi A. Jokaiseen yhtälöryhmään voidaan toki soveltaa Gaussin eliminaatiota yksitellen, mutta tämä on varsin työlästä. Sen sijaan matriisin

A LU-hajotelma (tai PLU) tarvitsee muodostaa vain kerran, ja sen avulla jokainen yhtälöryhmä $A\mathbf{v}_j = \mathbf{b}_j$ voidaan palauttaa (mahdollista rivien uudelleenjärjestämistä vaille) muotoon $LU\mathbf{v}_j = \mathbf{b}_j$. Tämä voidaan mieltää kahtena eri systeeminä

$$L\mathbf{u}_j = \mathbf{b}_j \qquad \text{ja} \qquad U\mathbf{v}_j = \mathbf{u}_j.$$

Nämä ovat huomattavasti suoraviivaisempia ratkaista, sillä (ylä/ala)kolmiomatriisin määrittävä yhtälöryhmä voidaan ratkaista yksi muuttuja kerrallaan aloittaen alhaalta/ylhäältä.

Siis siinä missä Gaussin eliminaatio on menetelmä yhtälöryhmän ratkaisemiseen, LU/PLU-hajotelma on esitystapa annetulle matriisille, jota voidaan hyödyntää uudelleen aina tarvittaessa.

Singulaariarvohajotelma

Eräs hyödyllisimmistä matriisihajotelmista on ns. **singulaariarvohajotelma** eli **SVD-hajotelma** (eng. *singular value decomposition*), joka on mahollista muodostaa mille tahansa $m \times n$-matriisille A. SVD-hajotelmaa on mahdollista hyödyntää pienimmän neliösumman ratkaisuja etsiessä, kuvatiedostojen pakkauksessa pienempään kokoon, kasvojentunnistuksessa, signaalien prosessoinnissa, ja monissa muissa käytännön ongelmissa.

Singulaariarvohajotelma $m \times n$-matriisille A on muotoa

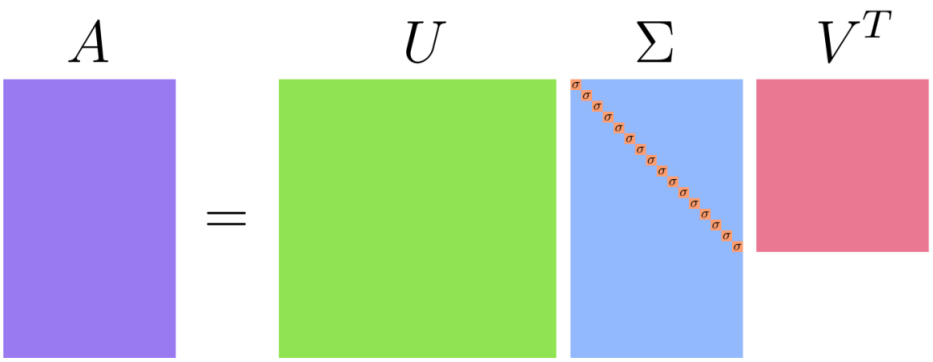
$$\boxed{A = U\Sigma V^T}$$

Missä:

- U on ortogonaalinen $m \times m$-neliömatriisi.
- V on ortogonaalinen $n \times n$-neliömatriisi.
- Σ on $m \times n$-matriisi, jonka ainoat nollasta poikkeavat alkiot ovat sen diagonaalilla, eli kohdissa (i, i). Siis Σ on joko muotoa

  $$\Sigma = \begin{pmatrix} D \\ 0 \end{pmatrix} \qquad \text{tai} \qquad \Sigma = \begin{pmatrix} D & 0 \end{pmatrix},$$

  missä D on diagonaalimatriisi ja 0 on sopivankokoinen nollamatriisi. Diagonaalialkiot σ_i ovat kaikki ei-negatiivisia, ja ne ovat laskevassa järjestyksessä, eli σ_1 on isoin. Näitä kutsutaan matriisin A **singulaariarvoiksi**.



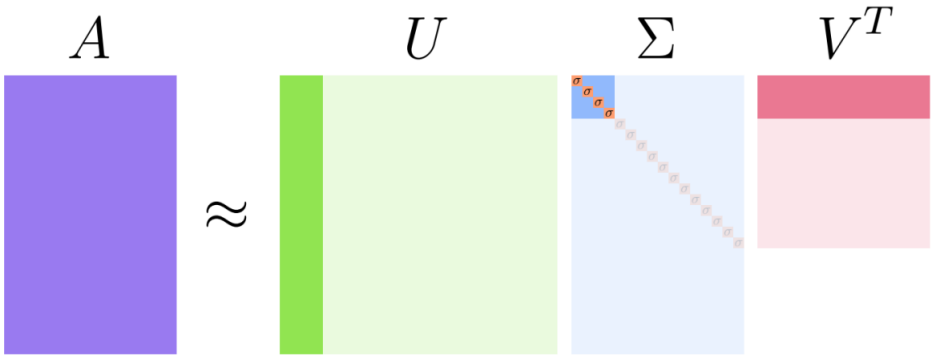
Todistamme singulaariarvohajotelman olemassaolon vasta tämän luvun lopussa. Käydään kuitenkin ensin sovelluksia.

Esimerkki 9.1. Selvitetään, miten SVD-hajotelmalla kuvatiedostoja voi pakata pienempään kokoon (häviöllisesti, eli kuvan laatu heikkenee). Tutkitaan kuvaa, jossa on $m \times n$ pikseliä. Jos kuva on mustavalkoinen, sen voi esittää yhtenä $m \times n$-matriisina A, jossa jokainen alkio vastaa pikselin kirkkautta. Värikuvan voi jakaa kolmeen eri värikanavaan (RGB), joista jokainen voidaan käsitellä erikseen. Oletaan siis yksinkertaisuuden vuoksi, että kuva on mustavalkoinen.

Kuvan matriisi A voidaan esittää singulaariarvohajotelmana

$$A = U\Sigma V^T,$$

missä erityisesti singulaariarvot σ_i on järjestetty laskevaan järjestykseen. Ajatus on, että myöhemmin esiintyvät pienemmät singulaariarvot eivät välttämättä vaikuta niin paljon kuvan todelliseen luonteeseen. Jos unohdamme kaikki paitsi ensimmäiset N kappaletta singulaariarvoja, niin jäljelle jäävistä matriisin Σ singulaariarvoista, matriisin U sarakkeista, ja matriisin V riveistä voidaan muodostaa kolme huomattavasti pienemmän kokoista matriisia kuvan esittämällä tavalla:



Matriisista U siis otetaan vain ensimmäiset N saraketta, matriisista Σ jätetään kaikki paitsi ensimmäinen $N \times N$-neliömatriisin muotoinen palanen pois, ja matriisista V^T otetaan vain ensimmäiset N riviä. Tällöin lopullinen matriisitulo on edelleen kokoa

$$(m \times N)(N \times N)(N \times n) = (m \times n),$$

joten lopputulos on saman kokoinen pikseleissä, mutta sen esitykseen vaaditaan pienempi määrä informaatiota, kunhan N valitaan pieneksi suhteessa lukuihin m ja n. Tutkitaan seuraavaksi, miten tämä muuttaa kuvan laatua käytännössä:



SVD-kuvanpakkaus



Kuva: Kissan kuvaa on sumennettu jättämällä alkuperäisestä n. 1600 singulaariarvosta jäljelle vain 40. Tiedostokoon mielessä pakkaus on 20-kertainen. Kuvan kissan nimi on 'Nachos'.

Kuvatiedostojen pakkaamiseen on monia muita matemaattisia menetelmiä, ja esimerkiksi eräs suosituimmista pakkausmenetelmistä nimeltä JPEG soveltaa ns. diskreettiä kosinimuunnosta.

SVD-hajotelman olemassaolo. Todistamme seuraavaksi, että jokaisella $m \times n$-matriisilla A on edellä mainittu singulaariarvohajotelma. Voimme olettaa, että $m \geq n$, sillä muussa tapauksessa etsitään ensin singulaariarvohajotelma matriisille A^T, ja sitten A:n hajotelma saadaan ottamalla tästä transpoosi puolittain.

Tutkitaan nyt matriisia $A^T A$. Tämä on symmetrinen matriisi, ja lisäksi positiivisesti semidefiniitti, sillä

$$\mathbf{x}^T (A^T A)\mathbf{x} = \mathbf{x} \cdot (A^T A\mathbf{x}) = (A\mathbf{x}) \cdot (A\mathbf{x}) = |A\mathbf{x}|^2 \geq 0.$$

Siis matriisi $A^T A$ voidaan diagonalisoida muotoon

$$A^T A = V D V^T,$$

missä V on ortogonaalinen, ja D on diagonaalinen matriisi, jonka diagonaalialkiot λ_i ovat ei-negatiivisia. Määritellään $\sigma_i = \sqrt{\lambda_i}$, ja olkoon Σ sellainen $m \times n$-matriisi, jonka alkio diagonaalin kohdassa (i, i) on σ_i, ja muut alkiot ovat nollia. Siispä

$$\Sigma = \begin{pmatrix} \sqrt{D} \\ 0 \end{pmatrix}.$$

Väitämme, että löytyy ortogonaalinen matriisi U, jolle

$$A = U \Sigma V^T, \tag{9.2}$$

missä V on sama matriisi kuin edellä. Olkoon $\mathbf{v}_i$ matriisin V i:nnes sarake, eli matriisin $A^T A$ ominaisvektori ominaisarvolla λ_i. Tällöin

$$\Sigma V^T \mathbf{v}_i = \Sigma V^{-1} \mathbf{v}_i = \Sigma\, \mathbf{e}_i = \begin{pmatrix} \sigma_i\, \mathbf{e}_i \\ \mathbf{0} \end{pmatrix}.$$

Erityisesti jos $\sigma_i \neq 0$, niin jotta (9.2) pätisi, täytyy olla

$$U \begin{pmatrix} \mathbf{e}_i \\ \mathbf{0} \end{pmatrix} = \sigma_i^{-1} A\mathbf{v}_i.$$

Siis U:n i:nnes sarake täytyy olla vektori $\sigma_i^{-1} A\mathbf{v}_i$. Väitämme ensinnäkin, että nämä sarakkeet ovat ortonormaali jono. Lasketaan tämä pistetulolla:

$$\left(\sigma_i^{-1} A\mathbf{v}_i\right) \cdot \left(\sigma_j^{-1} A\mathbf{v}_j\right) = \sigma_i^{-1}\sigma_j^{-1} \left(A^T A\mathbf{v}_i\right) \cdot \mathbf{v}_j = \sigma_i^{-1}\sigma_j^{-1}\lambda_i \left(\mathbf{v}_i \cdot \mathbf{v}_j\right).$$

Jälkimmäisestä lausekkeesta tulee 1, kun $i = j$, ja 0, kun $i \neq j$, sillä matriisin V sarakkeet $\mathbf{v}_i$ ovat ortonormaaleja.

Loput U:n sarakkeet pitää vielä valita. Jo valitut sarakkeet muodostavat siis ortonormaalin jonon, joten täydennetään tämä ortonormaali jono koko avaruuden $\mathbb{R}^m$ ortonormaaliksi kannaksi $\mathbf{u}_1, \ldots, \mathbf{u}_m$. Näin matriisista U tulee ortogonaalinen. Tarkistetaan lopuksi, että nyt (9.2) varmasti pätee. Riittää tarkistaa tämä vektoreilla $\mathbf{v}_i$, sillä ne muodostavat avaruuden $\mathbb{R}^n$ kannan.

- Jos $\mathbf{v}_i$ vastaa ominaisvektoria, jolla $\sigma_i = \sqrt{\lambda_i} > 0$, niin aiemman perusteella

$$U\Sigma V^T \mathbf{v}_i = U \begin{pmatrix} \sigma_i \mathbf{e}_i \\ \mathbf{0} \end{pmatrix} = A\mathbf{v}_i.$$

- Jos $\mathbf{v}_i$ vastaa sellaista ominaisvektoria, jolla $\sigma_i = 0$, niin $\mathbf{v}_i \in \operatorname{Ker} A^T A$, joten myös $\mathbf{v}_i \in \operatorname{Ker} A$ (kts. (5.1)). Täten

$$\mathbf{0} = A\mathbf{v}_i, \qquad \text{mutta myös} \qquad U\Sigma V^T \mathbf{v}_i = U \begin{pmatrix} \sigma_i \mathbf{e}_i \\ \mathbf{0} \end{pmatrix} = \mathbf{0}.$$

  Siis kaikki on kunnossa. Kuten diagonalisaatiossa, matriisin V sarakkeet voi järjestää haluttuun järjestykseen muuttamatta sen ortogonaalisuutta, ja tällöin myös matriisin $A^T A$ ominaisarvot λ_i ja samalla myös matriisin A singulaariarvot σ_i järjestyvät halutusti. Siis singulaariarvot σ_i voidaan asettaa laskevaan järjestykseen.

□

Todistuksesta voidaan päätellä, että jos r on nollasta poikkeavien singulaariarvojen lukumäärä, niin $r = \operatorname{rank} A$, ja

- Matriisin U ensimmäiset r saraketta muodostavat kuva-avaruuden $\operatorname{Im} A$, eli matriisin A sarakeavaruuden, kannan.
- Matriisin U viimeiset $m - r$ saraketta muodostavat kannan transpoosin ytimelle $\operatorname{Ker} A^T$.
- Matriisin V ensimmäiset r saraketta muodostavat transpoosin kuva-avaruuden $\operatorname{Im} A^T$, eli matriisin A riviavaruuden, kannan.
- Matriisin V viimeiset $n - r$ saraketta muodostavat kannan ytimelle $\operatorname{Ker} A$.

Pseudoinverssi

Vaikka kaikki matriisit eivät ole kääntyviä, on jokaisella $m \times n$-matriisilla A olemassa ns. **pseudoinverssi** A^+. Tämä määritellään SVD-hajotelman kautta seuraavasti:

$$A = U\Sigma V^T \qquad \Rightarrow \qquad A^+ = V\Sigma^+ U^T,$$

missä Σ^+ muodostetaan ottamalla matriisin Σ transpoosi, ja vaihtamalla kaikki positiiviset singulaariarvot niiden käänteisluvuiksi. Siis esim.

$$\begin{pmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}^+ = \begin{pmatrix} \frac{1}{2} & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}.$$

Pseudoinverssille pätee kaavat

$$AA^+A = A \qquad \text{ja} \qquad A^+AA^+ = A^+.$$

Eräs pseudoinverssin sovelluksista on pienimmän neliösumman ratkaisuja etsiessä. Tutkitaan yleistä lineaarista yhtälöryhmää

$$A\mathbf{v} = \mathbf{b}.$$

Oletamme tässä, että tällä yhtälöllä on yksikäsitteinen pienimmän neliösumman ratkaisu. Tällöin se voidaan laskea pseudoinverssillä suoraan kaavasta

$$\mathbf{v} = A^+\mathbf{b}.$$

Todistus. Muistetaan, että pienimmän neliösumman menetelmässä yhtälöryhmä $A\mathbf{v} = \mathbf{b}$ voidaan palauttaa normaaliyhtälöön

$$A^TA\mathbf{v} = A^T\mathbf{b}.$$

Normaaliyhtälöllä on yksikäsitteinen ratkaisu tasan silloin, kun matriisi A^TA on kääntyvä. Tämä on yhtäpitävää sen kanssa, että matriisin $A^TA = VDV^T$ ominaisarvot ovat nollasta poikkeavia. Siispä kaikki matriisin A singulaariarvot ovat positiivisia. Kun A kirjoitetaan singulaariarvohajotelmana $A = U\Sigma V^T$, normaaliyhtälö palautuu muotoon

$$VDV^T\mathbf{v} = V\Sigma U^T\mathbf{b} \qquad \Leftrightarrow \qquad \mathbf{v} = VD^{-1}\Sigma^T U^T\mathbf{b}.$$

Lopuksi on melko suoraviivaista tarkistaa, että pätee $\Sigma^+ = D^{-1}\Sigma^T$. Esimerkiksi jos singulaariarvot ovat $3, 2, 1$ ja Σ on 4×3-matriisi, niin

$$D^{-1}\Sigma^T = \begin{pmatrix} \frac{1}{9} & 0 & 0 \\ 0 & \frac{1}{4} & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 3 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix} = \begin{pmatrix} \frac{1}{3} & 0 & 0 & 0 \\ 0 & \frac{1}{2} & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix} = \Sigma^+.$$

10. Täydennyksiä

Tässä osiossa käsittelemme asioita, joita ei syystä tai toisesta otettu mukaan aikaisempiin lukuihin. Tyypillisesti nämä ovat teoreettisia todistuksia tai käsitteitä.

Laskusääntöjen todistuksia

Todistamme tässä pari perusominaisuutta matriiseille. Jos A on $m \times n$-matriisi, B on $n \times k$-matriisi, ja C on $k \times l$ matriisi, niin matriisin kertolaskun liitännäisyyslaki sanoo, että

$$(AB)C = A(BC).$$

Tarkistetaan tämä. Matriisitulon määritelmästä saadaan:

$$(AB)_{ij} = \sum_{q=1}^{n} a_{iq}b_{qj} \qquad \text{ja} \qquad (BC)_{ij} = \sum_{q=1}^{k} b_{iq}c_{qj}.$$

Siispä

$$\begin{aligned}((AB)C)_{ij} &= \sum_{q=1}^{k} (AB)_{iq}c_{qj} \\ &= \sum_{q=1}^{k} \left(\sum_{r=1}^{n} a_{ir}b_{rq} \right) c_{qj}. \\ &= \sum_{q=1}^{k} \sum_{r=1}^{n} a_{ir}b_{rq}c_{qj}.\end{aligned}$$

Vastaavasti

$$\begin{aligned}(A(BC))_{ij} &= \sum_{r=1}^{n} a_{ir}(BC)_{rj} \\ &= \sum_{r=1}^{n} a_{ir} \sum_{q=1}^{k} b_{rq}c_{qj}. \\ &= \sum_{r=1}^{n} \sum_{q=1}^{k} a_{ir}b_{rq}c_{qj}.\end{aligned}$$

Lopputulos on sama, joten $(AB)C = A(BC)$. □

Matriisijonon suppeneminen

Olkoon $A^{(k)}$, $k = 1, 2, \ldots$ jono $m \times n$-matriiseja, missä yläindeksi (k) viittaa jonon alkioon, ei matriisin potenssiin. Sanomme, että tämä jono suppenee kohti $m \times n$-matriisia A, merkitään

$$\lim_{k\to\infty} A^{(k)} = A,$$

mikäli jonon jäsenten alkiot suppenevat kohti A:n alkioita, eli

$$\lim_{k\to\infty} (A^{(k)})_{ij} = A_{ij}$$

pätee kaikille i, j tavallisessa reaalilukujen raja-arvon mielessä. Tämä on kuitenkin ekvivalenttia seuraavan ehdon kanssa:

Lause 10.1. *Matriisijono $A^{(k)}$ suppenee matriisiin A tasan silloin, kun*

$$\lim_{k\to\infty} \left\|A - A^{(k)}\right\| = 0,$$

missä $\|\cdot\|$ on operaattorinormi.

Todistus. Tämä seuraa erilaisten matriisinormien vertailulla. Ensinnäkin lauseen ehdosta seuraa matriisijonon suppeneminen, sillä alkioittain jokaiselle matriisille $B = (b_{ij})$ pätee seuraava arvio, missä S_j on B:n j:nnes sarakevektori:

$$|b_{ij}| \leq |S_j| = |Be_j| \leq \|B\|.$$

Erityisesti jos $\|A - A^{(k)}\| \to 0$, myös

$$\left|\left(A - A^{(k)}\right)_{ij}\right| \leq \|A - A^{(k)}\| \to 0.$$

Toinen suunta seuraa vastaavasta yläarviosta operaattorinormille.

$$\begin{aligned}
\|B\| &= \sup_{|\mathbf{v}|=1} |B\mathbf{v}| \\
&= \sup_{|\mathbf{v}|=1} \sqrt{|v_1|^2|S_1|^2 + \cdots + |v_n|^2|S_n|^2} \qquad \text{Huomaa: } |v_j| \leq |\mathbf{v}| = 1 \text{ kaikilla } j \\
&\leq \sqrt{|S_1|^2 + \cdots + |S_n|^2} \\
&= \sqrt{\sum_{i=1}^{m}\sum_{j=1}^{n} |b_{ij}|^2} \\
&\leq \sqrt{mn} \cdot \max_{i,j} |b_{ij}|
\end{aligned}$$

Erityisesti jos jono $A^{(k)}$ suppenee matriisiin A alkioittain, myös

$$\left\|A - A^{(k)}\right\| \leq \sqrt{mn} \max_{i,j} \left|\left(A - A^{(k)}\right)_{ij}\right| \to 0.$$

□

Markovin ketjun suppeneminen

Olkoon M $n\times n$-stokastinen matriisi, jonka jokainen alkio on positiivinen. Esimerkissä 7.6 osoitimme jo, että tällaisella matriisilla on ominaisarvo $\lambda = 1$. Näytämme seuraavaksi, että

- Tätä vastaava ominaisvektori on yksikäsitteinen, eli sen geometrinen kertaluku on yksi.
- Iteraatiojono $\mathbf{p}_{k+1} = M\mathbf{p}_k$ suppenee tähän vektoriin jokaisella alkuarvolla $\mathbf{p}_0$.

Molemmat väitteet voidaan todistaa osoittamalla, että M on ns. **kontraktio**. Selitämme ja todistamme tämän käsitteen seuraavasti. Koska M:n alkiot ovat positiivisia, on myös matriisin $A = M - \beta \mathbf{e}\mathbf{e}^T$ alkiot kaikki positiivisia riittävän pienellä luvulla $\beta > 0$, missä $\mathbf{e}$ on vektori, jonka alkiot ovat kaikki ykkösiä. Valitaan lisäksi β niin pieneksi, että $n\beta < 1$.

Tällöin matriisi M voidaan esittää kahden stokastisen matriisin keskiarvona:

$$M = A + \beta \mathbf{e}\,\mathbf{e}^T = (1 - n\beta)\left[\frac{1}{1-n\beta}A\right] + n\beta\left[\frac{1}{n}\mathbf{e}\mathbf{e}^T\right].$$

Jätämme lukijan tarkistettavaksi, että matriisit

$$B = \frac{1}{1-n\beta}A = \frac{1}{1-n\beta}(M - \beta\mathbf{e}\mathbf{e}^T) \qquad \text{ja} \qquad \frac{1}{n}\mathbf{e}\mathbf{e}^T$$

todella ovat stokastisia.

Olkoon $\mathbf{p}$ ja $\mathbf{q}$ stokastisia vektoreita. Tällöin $\mathbf{e}^T\mathbf{p} = 0 = \mathbf{e}^T\mathbf{q}$. Siispä

$$\begin{aligned} |M\mathbf{p} - M\mathbf{q}| &= (1-n\beta)|B\mathbf{p} - B\mathbf{q} + \beta\mathbf{e}\left(\mathbf{e}^T\mathbf{p} - \mathbf{e}^T\mathbf{q}\right)| \\ &= (1-n\beta)|B(\mathbf{p}-\mathbf{q}) + \mathbf{0}| \\ &\leq (1-n\beta)|\mathbf{p}-\mathbf{q}|. \end{aligned}$$

Tässä hyödynsimme stokastisten matriisien ominaisuutta $|B\mathbf{v}| \leq |\mathbf{v}$ vektoriin $\mathbf{v} = \mathbf{p} - \mathbf{q}$. Edellinen arvio osoittaa, että matriisilla M kertominen lyhentää vektoreiden $\mathbf{p}$ ja $\mathbf{q}$ välistä etäisyyttä vähintään positiivisella kertoimella $1 - n\beta < 1$. Tällainen kuvaus on nimeltään **kontraktio**.

Kontraktiolla voi olla enintään yksi kiintopiste, sillä jos $\mathbf{p}$ ja $\mathbf{q}$ ovat kiintopisteitä, niin

$$|\mathbf{p} - \mathbf{q}| = |M\mathbf{p} - M\mathbf{q}| \leq (1 - n\beta)|\mathbf{p} - \mathbf{q}|,$$

mikä on mahdotonta, ellei $\mathbf{p} = \mathbf{q}$. Lisäksi tällaisella kuvauksella on aina olemassa yksi kiintopiste, jonka takaa topologinen tulos nimeltä **Banachin kiintopistelause**. Emme todista tätä lausetta tässä, mutta kiinnostunutta lukijaa suositellaan tutustumaan siihen enemmän. Lause takaa myös, että jokainen iteraatiojono suppenee kohti tätä kiintopistettä, joten väite on todistettu. □

11. Sanasto

Affiinikuvaus
affine transformation
Lineaarikuvaus sekä vakiotermi, muotoa $T(v) = Av + v_0$.

Algebrallinen kertaluku
algebraic multiplicity
Ominaisarvon λ_i algebrallinen kertaluku kertoo, kuinka monta kertaa λ_i esiintyy karakteristisen polynomin $\det(A - \lambda I)$ juurena, eli kuinka monta kertaa termi $(\lambda - \lambda_i)$ jakaa karakteristisen polynomin. Toisin sanottuna, polynomin $\det(A - \lambda I)$ voi esittää muodossa $\prod_{i=1}^{k}(\lambda_i - \lambda)^{n_i}$, missä λ_i ovat A:n ominaisarvot, ja n_i on ominaisarvon λ_i algebrallinen kertaluku.

Aliavaruus
subspace
Joukko V on $\mathbb{R}^n$:n aliavaruus, jos se sisältää kaikki jäsentensä lineaarikombinaatiot. Triviaaleja aliavaruuksia ovat $\emptyset, \{\mathbf{0}\}$, ja $\mathbb{R}^n$. Yleisemmin vektoriavaruuden V aliavaruus W on osajoukko, joka on itsessään myös vektoriavaruus.

(Säännöllisyys)aste, rangi
rank
Matriisin rivien tai sarakkeiden virittämän vektoriavaruuden ulottuvuus. Riippumattomien sarakkeiden tai rivien lukumäärä.

Cholesky-hajotelma
Cholesky factorization
Muotoa $A = CC^T$ tai $A = (L\sqrt{D})(L\sqrt{D})^T$.

Cramerin sääntö
Cramer's rule
Ratkaisukaava yhtälöryhmälle $Ax = b$. Cramerin sääntö antaa $x_j = \det(B_j)/\det(A)$, missä B_j on muuten kuin A, mutta sarake numero j on korvattu vektorilla b.

Determinantin kaava
formula for determinant
Matriisin A determinantti on $n!$ termin summa. Jokainen termi vastaa yhtä permutaatiomatriisia P niin, että termi on AP:n lävistäjäalkioiden tulo kertaa $\det(P)$. Toisin sanottuna $\det(A) = \sum_P \det(P) \prod_{i=1}^{n}(AP)_{ii}$.

Determinantti
determinant
Määritelty neliömatriiseille. Merkitään $\det(A)$, joskus $|A|$. Determinantti määritellään seuraavan kolmen ominaisuuden kautta; identiteettimatriisille pätee $\det(I) = 1$; jos A:n kahden rivin paikkaa vaihtaa, determinantti pysyy muuten samana, mutta sen merkki vaihtuu; determinantti on lineaarinen jokaisella rivillä. Tästä seuraa, että $\det(A) = 0$ silloin kun A on epäsäännöllinen.

Diagonalisaatio
diagonalization
Hajotelma muotoa $A = SDS^{-1}$, tai vaihtoehtoisesti $AS = SD$, missä D on diagonaalimatriisi joka pitää sisällään A:n ominaisarvot, ja S koostuu A:n ominaisvektoreista. Huom! Diagonalisaatio on olemassa vain jos A:lla on n riippumatonta ominaisvektoria. Diagonalisaatiolla on helppo laskea matriisin potensseja: $A^k = SD^kS^{-1}$. Matriisit A ja D ovat similaarisia.

Diagonalisoituva matriisi
diagonalizable matrix

Matriisi A on diagonalisoituva, jos sille voidaan muodostaa hajotelma $A = SDS^{-1}$, missä D on diagonaalimatriisi. Tämä on mahdollista silloin, kun A:lla on n riippumatonta ominaisvektoria.

Dimensio, ulottuvuus
dimension

Vektoriavaruuden V dimensio on sen kantavektorien lukumäärä. Huom. vaikka kanta voidaan valita usealla eri tavalla, sen vektoreiden lukumäärä on aina sama.

Eliminaatio
elimination

Sarja rivioperaatioita, joilla redusoidaan matriisi A joko yläkolmiomuotoon U tai redusoituun porrasmuotoon R. Tällöin $A = LU$, missä L koostuu *kertoimista* ℓ_{ij}. Vaihtoehtoisesti $PA = LU$, missä P on permutaatiomatriisi joka uudelleenjärjestelee A:n rivit, tai $EA = R$, missä E on jokin kääntyvä (säännöllinen) matriisi.

Eliminaatiomatriisi
elimination matrix

Eliminaatiomatriisi E_{ij} on muuten kuin identiteettimatriisi, mutta sen arvo kohdassa (i, j) on $-\ell_{ij}$. Tämä matriisi vastaa rivioperaatiota, jossa matriisista A vähennetään ℓ_{ij} kertaa rivi j rivistä i. Matriisitulo $E_{ij}A$ on tämän rivioperaation lopputulos.

Ellipsi ja ellipsoidi
ellipse, ellipsoid

Ellipsin kaava voidaan esittää muodossa $x^T Ax = 1$, missä matriisi A on positiivisesti definiitti. Ellipsin akselit ovat matriisin A ominaisvektoreita. Akselien pituus on $1/\sqrt{\lambda}$, missä λ on A:n ominaisarvo.

Ensimmäisen asteen matriisi
rank-1 matrix

Matriisi, jonka rivi- ja sarakeavaruudet ovat yksiulotteisia. Kaikki matriisin sarakkeet (ja rivit) voidaan siis muodostaa yhtä saraketta (riviä) skaalaamalla, eli $A = uv^T$, missä u ja v ovat pystyvektoreita. Huom. $A \neq 0$.

Epäsäännöllinen matriisi, singulaarinen matriisi
singular matrix

Neliömatriisi, jonka aste on pienempi kuin sen koko. Myös, neliömatriisi, jolla ei ole käänteismatriisia tai neliömatriisi jolla on lineaarisesti riippuvia rivejä tai sarakkeita. Neliömatriiseilla $\det(A) = 0$ jos ja vain jos A on epäsäännöllinen.

Erityisratkaisu
special solution

Ratkaisu yhtälöryhmälle $As = 0$, jossa yksi vapaa muuttuja on $s_i = 1$ ja muut vapaat muuttujat ovat nollaa.

Gauss-Jordanin menetelmä
Gauss-Jordan method

Menetelmä käänteismatriisin laskemiseksi. Tehdään rivioperaatioita täydennetylle matriisille $[A\ I]$ kunnes saavutetaan muoto $[I\ A^{-1}]$.

Geometrinen kertaluku
geometric multiplicity

Ominaisarvon λ riippumattomien ominaisvektorien lukumäärä. Vaihtoehtoisesti ominaisvektorien virittämän avaruuden dimensio.

LU-hajotelma
LU factorization

Hajotelma muotoa $A = LU$, missä U on yläkolmiomatriisi. Jos matriisia A eliminoidessa ei tarvitse käyttää rivipermutaatioita, matriisi L on muotoa $L_{ij} = \ell_{ij}$ (ks. kerroin), ja $L_{ii} = 1$.

Hermiittinen matriisi
Hermitian matrix

Kompleksisille matriiseille symmetristä matriisia vastaava käsite. Matriisi on hermiittinen, jos $A^* = \overline{A}^T = A$, missä $\overline{A}$ tarkoittaa A:n alkioittaista kompleksikonjugaattia. Tällöin $a_{ij} = \overline{a_{ji}}$.

Identiteettimatriisi
identity matrix

Matriisi I, jonka lävistäjäalkiot I_{ii} ovat 1 ja muut alkiot nollaa. Matriisille I pätee $AI = IA = A$, eli se toimii matriisitulossa kuin luku 1 skalaarikertolaskussa.

Indefiniitti matriisi
indefinite matrix

Symmetrinen matriisi, jolla on sekä positiivisia että negatiivisia ominaisarvoja.

Jälki
trace

Matriisin lävistäjäalkioiden summa.

Karakteristinen polynomi
characteristic polynomial

Polynomi $\det(A - \lambda I)$, missä λ on muuttuja. Karakteristisen polynomin juuret ovat matriisin ominaisarvoja.

Kerroin ℓ_{ij}
multiplier

Kerroin, jota käytetään i. rivin pivotsarakkeen eliminoimiseen rivin j avulla. Rivi j kerrotaan kertoimella ℓ_{ij} ja vähennetään rivistä i. Jotta haluttu alkio saadaan eliminoitua, kerroin on valittava $\ell_{ij} = A_{ik}/A_{jk}$, missä k on pivotsarake.

Kiertomatriisi
rotation matrix

Kaksiulotteisille vektoreille $R_\theta = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$. Operaatio Rv pyöräyttää vektoria v kulman θ mukaisesti vastapäivään. Matriisin R_θ käänteismatriisi saadaan käyttämällä kulmaa $-\theta$. Huom! $R_\theta^{-1} = R_\theta^T$, eli R_θ on ortogonaalinen matriisi. Matriisin R ominaisarvot ovat $e^{i\theta}$ ja $e^{-i\theta}$, ja sen ominaisvektorit ovat $(1, i)$ ja $(1, -i)$.

Kolmioepäyhtälö
triangle inequality

Vektoreille u ja v pätee $|u + v| \leq |u| + |v|$.

Kolmilävistäjämatriisi, kolmidiagonaalinen matriisi
tridiagonal matrix

Kuin lävistäjämatriisi, mutta myös alkiot lävistäjän "lähellä" voivat olla muuta kuin nollaa. Toisin sanottuna matriisi T on kolmilävistäjämatriisi, jos $T_{ij} = 0$ aina kun $|i - j| > 1$.

Kompleksikonjugaatti
complex conjugate

Kompleksiluvun "peilaus" x-akselin suhteen. Jos $z = x + iy$, niin z:n kompleksi konjugaatti on $\overline{z} = x - iy$. Huom. $z\overline{z} = x^2 + y^2 = |z|^2$.

Kuva-avaruus $\mathrm{Im}(A)$
image space, range, column space

Matriisin A sarakkeiden virittämä vektoriavaruus. A:n sarakkeiden kaikkien mahdollisten lineaariyhdistelyiden joukko.

Käänteismatriisi
inverse

Neliömatriisin A käänteismatriisi A^{-1} toteuttaa $AA^{-1} = I$. Käänteismatriisi on yksikäsitteinen, ja matriisin A^{-1} käänteismatriisi on A. Matriisilla on käänteismatriisi jos ja vain jos $\det(A) \neq 0$, eli kun se on säännöllinen.

Liitännäisyys
associativity

Matriisien tulolle pätee $(AB)C = A(BC)$, eli tulot voi laskea missä järjestyksessä tahansa. Näin ollen sulut voidaan jättää pois ja kirjoittaa vain ABC.

Lineaarikuvaus
linear transformation

Funktio T, joka kuvaa vektorin v joksikin toiseksi vektoriksi $T(v)$. Ollakseen lineaarinen kuvauksen T on täytettävä ehto $T(av + bw) = aT(v) + bT(w)$ kaikille skalaareille a, b ja vektoreille v, w.

Lineaarikombinaatio
linear combination

Vektorien skaalausta ja summausta. Esim. skalaareille $a_1, \ldots, a_n$ ja vektoreille $v_1, \ldots, v_n$ summa $\sum_{i=1}^{n} a_i v_i$ on vektorien $v_1, \ldots, v_n$ lineaariyhdistely.

Lineaarinen riippuvuus
linear dependency

Vektorit $v_1, \ldots, v_n$ ovat lineaarisesti riippuvia, jos on olemassa kertoimet $a_1, \ldots, a_n$ siten että $\sum_{i=1}^{n} a_i v_i = 0$ ja $a_j \neq 0$ jollekin $j = 1, \ldots, n$.

Lohkomatriisi
block matrix

Matriisin voi jaotella osiin niin, että matriisi koostuu pienemmistä matriiseista, joita kutsutaan lohkoiksi.

Lohkomatriisien tulo
block product

Lohkoihin jaettujen matriisien tulon voi laskea lohkojen avulla, mikäli lohkojen koot sopivat yhteen. Esim. $\begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix} = \begin{bmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{bmatrix}$

Lävistäjämatriisi, diagonaalimatriisi
diagonal matrix

Matriisi, jonka alkiot ovat nollaa kaikkialla muualla, paitsi lävistäjällä, eli kohdissa (i, i).

Markovin matriisi
Markov's matrix

Kaikki matriisin M arvot ovat epänegatiivisia ja jokaisen sarakkeen alkioiden summa on 1. Suurin ominaisarvo on 1. Jos $M_{ij} > 0$, matriisin potenssien M^k sarakkeet lähestyvät tasapainotilan ominaisvektoria $Ms = s > 0$.

Matriisitulo
matrix product

Matriisit A ja B voidaan kertoa keskenään, jos niiden koot ovat yhteensopivat; matriisilla A on oltava yhtä monta saraketta kun B:llä on rivejä. Matriisitulon AB alkio (i, j) muodostetaan summana $\sum_{i=1}^{k} A_{ik}B_{kj}$. Toisinsanottuna $(AB)_{ij}$ on rivin A_i ja sarakkeen B_j pistetulo. Jos matriisit A ja B ovat kokoa $m \times k$ ja $k \times n$, matriisi AB on kokoa $m \times n$.

Matriisi-vektoritulo
matrix-vector product

Matriisin A ja pystyvektorin x tulo on lineaariyhdistely A:n sarakkeista; $Ax = \sum_{i=1}^{n} A_i x_i$. Lopputulos on siten $m \times 1$ vektori, jos A on kokoa $m \times n$.

Nilpotentti matriisi
nilpotent matrix

Matriisi A on nilpotentti, jos jollekin $k = 0, 1, \ldots$ pätee $A^k = 0$. Esimerkiksi yläkolmiomatriisit, joiden lävistäjäalkiot ovat nollaa, ovat nilpotentteja.

Nolla-avaruus, ydin $\mathrm{Ker}(A)$
nullspace, kernel

Niiden vektoreiden x joukko, joille $Ax = 0$. Näiden vektorien joukko muodostaa vektoriavaruuden. Jos A on $m \times n$ matriisi jonka säännöllisyysaste on r, nolla-avaruuden dimensio on $n - r$.

Nolla-avaruusmatriisi
nullspace matrix

Nolla-avaruusmatriisin N sarakkeet ovat yhtälöryhmän $As = 0$ erityisratkaisut. Erityisratkaisuja on aina $n - r$, missä n on A:n sarakkeiden lukumäärä ja r on A:n säännöllisyysaste.

Normaali matriisi
normal matrix

Matriisi A, jolle pätee $AA^T = A^TA$. Tällöin A:n ominaisvektorit ovat ortonormaaleja.

Normaaliyhtälö
normal equation

Yhtälöryhmä $A^TA\hat{x} = A^Tb$. Jos A on täysasteinen, normaaliyhtälön ratkaisut ovat pienimmän neliösumman ratkaisuja yhtälöryhmälle $Ax = b$. Yhtälö kertoo, että kaikki A:n sarakkeet ovat ortogonaalisia vektorin $b - A\hat{x}$ kanssa.

Ortogonaalinen matriisi
orthogonal matrix

Matriisi on ortogonaalinen, jos $Q^TQ = I$. Ortogonaalisille matriiseille pätee $Q^T = Q^{-1}$, eli käänteismatriisi on helppo laskea. Ortogonaaliset matriisit säilyttävät vektorien pituudet, eli $|Qx| = |x|$ ja $(Qx)^T(Qy) = x^TQ^TQy = x^Ty$. Kaikki Q:n ominaisarvot ovat kokoa $|\lambda| = 1$, ja ominaisvektorit ovat myös ortogonaaalisia. Esimerkiksi kiertomatriisit, peilausmatriisit ja permutaatiomatriisit ovat ortogonaalisia.

Ortogonaaliset aliavaruudet
orthogonal subspaces

Aliavaruudet V ja W ovat ortogonaalisia, jos kaikki vektorit $v \in V$ ja $w \in W$ ovat ortogonaalisia keskenään, eli $v^Tw = 0$.

Ortonormaalit vektorit
orthonormal vectors

Vektorit $q_1, \ldots, q_n$ ovat ortonormaaleja keskenään, jos $q_i^Tq_j = 0$ aina kun $i \neq j$ ja $|q_i| = 1$. Jos ortonormaalit vektorit järjestetään matriisin Q sarakkeiksi, niin $Q^TQ = I$, eli Q on ortogonaalinen matriisi. Jos Q on neliömatriisi, sen sarakkeet muodostavat ortonormaalin kannan avaruudelle $\mathbb{R}^n$; jokainen vektori $\mathbb{R}^n$:ssä voidaan ilmaista Q:n sarakkeiden lineaariyhdistelynä.

Ominaisarvo, ominaisvektori
eigenvalue, eigenvector

Neliömatriisin A ominaisarvo on luku, jolle on olemassa vektori $x \neq 0$ siten että $Ax = \lambda x$. Tällöin x on ominaisarvoa λ vastaava ominaisvektori. Ominaisarvoille λ pätee myös $\det(A - \lambda I) = 0$

Ominaisarvolause
spectral theorem

Jos A on reaalinen symmetrinen neliömatriisi, niin on olemassa hajotelma $A = QDQ^T$, missä D on reaalinen lävistäjämatriisi, joka pitää sisällään A:n ominaisarvot, ja Q on ortogonaalinen matriisi, jonka sarakkeet ovat A:n ominaisarvoja. Mekaniikassa Q:n sarakkeita kutsutaan pääakseleiksi.

Osittelulaki
distributivity

Matriisitulolle pätee $A(B + C) = AB + AC$.

Peilausmatriisi
reflection matrix

Matriisi muotoa $Q = I - 2uu^T$, missä $|u| = 1$. Matriisi Q peilaa yksikkövektorin u vektoriksi $Qu = -u$. Vektorit, jotka ovat ortogonaalisia u:n kanssa, pysyvät muuttumattomina, sillä ne ovat "peilausakselin" suuntaisia.

Permutaatiomatriisi
permutation matrix

Permutaatiomatriisi on matriisi, jolla kertomalla voi uudelleen- järjestellä matriisin rivit tai sarakkeet. Permutaatiomatriisin sarakkeet ovat samat kuin identiteettimatriisilla I, mutta mahdollisesti toisessa järjestyksessä. Tulo PA järjestelee matriisin A rivit ja AP sen sarakkeet. Erilaisia järjestyksiä n alkiolle on olemassa $n!$ kappaletta, ja siten myös permutaatiomatriiseja on näin monta. Permutaatiomatriisille pätee $\det(P) = \pm 1$.

Pienimmän neliösumman ratkaisu
least-squares solution

Pienimmän neliösumman ratkaisu $\hat{x}$ on ratkaisu, joka minimoi virheen $|e| = |A\hat{x} - b|$. Se on myös ratkaisu normaaliyhtälölle $A^T A\hat{x} = A^T b$.

Pistetulo
dot product

Vektorien v ja w pistetulo on $v \cdot w = \sum_{i=1}^{n} v_i w_i = v^T w = w^T v = v_1 w_1 + \cdots + v_n w_n$.

Pituus
length

Vektorin v pituus $|v|$ on yleistys Pythagoraan lauseesta, ja sen voi laskea kaavalla $|v| = \sqrt{v_1^2 + \cdots + v_n^2} = \sqrt{v^T v}$.

Pivot
pivot

Eliminaatiossa ensimmäinen (vasemmalta laskien) nollasta eroava sarake rivillä, jota sillä hetkellä käsitellään.

Pivot-sarakkeet
pivot columns

Porrasmuodossa olevan matriisin kullekin riville se sarake, jolla on ensimmäinen nollasta poikkeava arvo.

Porrasmuoto
echelon matrix

Eliminoitu matriisi on järjestetty niin, että alempien rivien pivot-sarakkeet ovat ylempien pivot-sarakkeiden oikealla puolella ja nollarivit ovat alimpana. Näin ollen kunkin rivin pivot-alkion alapuolella on vain nollaa. Matriisin nollat muodostavat porrasmaisen kuvion.

Positiivisesti definiitti matriisi
positive-definite matrix

Symmetrinen neliömatriisi, jonka ominaisarvot ovat positiivisia. Määritelmällisesti kaikille vektoreille $x \neq 0$ pätee $x^T Ax > 0$. Porrasmuodossa ollessaan matriisin pivot-alkiot ovat positiivisia.

Projektio suoralle
projection onto a line

Olkoon L origon kautta kulkeva suora, joka kulkee pisteen a läpi. Projektiomatriisi, joka heijastaa vektorin v suoralle L on $P = aa^T/a^T a$, ja projisoitu vektori on muotoa $Pv = a(a^T v/a^T a)$. Matriisin P säännöllisyysaste on 1.

Ratkeava yhtälöryhmä
solvable system

Yhtälöryhmä $Ax = b$ on ratkeava, jos sille on olemassa ratkaisu x. Yhtälöryhmälle on olemassa ratkaisu täsmälleen silloin kun b kuuluu A:n kuva-avaruuteen. Jos matriisi A on säännöllinen, yhtälöryhmä on aina ratkeava.

Redusoitu porrasmuoto
reduced row echelon form, $\mathrm{rref}(A)$

Matriisi A on eliminoitu siten, että pivot-alkioiden ylä- ja alapuolella on vain nollaa, ja rivit on skaalattu siten, että pivot-alkiot saavat arvon 1. Redusoidun porrasmuodon rivit muodostavat kannan matriisin A kuva-avaruudelle.

Riippumattomat vektorit
independent vectors

Vektorit $v_1, \ldots, v_n$ ovat riippumattomia jos ja vain jos ei ole olemassa lineaariyhdistelyä jossa $c_1v_1 + \cdots + c_nv_n = 0$ ja $c_j \neq 0$ jollekin $j = 1, \ldots, n$. Toisin sanottuna, yhtäkään vektoreista v_i ei voi muodostaa vektoreiden $v_1, \ldots, v_{i-1}, v_{i+1}, \ldots, v_n$ lineaariyhdistelynä.

Ristitulo
cross product

Ristitulo kolmiulotteisten vektorien u ja v välillä on niille kohtisuora vektori, jonka pituus on $|u||v|| \sin\theta|$. Sen koordinaatit saadaan matriisin $[i\ j\ k; u_1\ u_2\ u_3; v_1\ v_2\ v_3]$ determinantin avulla.

Riviavaruus $\mathrm{Im}(A^T)$
row space

Matriisin A rivien lineaariyhdistelyiden virittämä vektoriavaruus.

Semidefiniitti matriisi
semidefinite matrix

Symmetrinen matriisi A on positiivisesti semidefiniitti, jos $x^TAx \geq 0$ kaikille $x \in \mathbb{R}^n$. Vastaavasti matriisi on negatiivisesti semidefiniitti, jos $x^TAx \leq 0$.

Permutaation signum
sign of a permutation

Jokaista permutaatiota σ vastaa permutaatiomatriisi P_σ, jonka voi rakentaa identiteettimatriisin sarakkeita keskenään vaihtamalla. Permutaation signum, $\mathrm{sgn}(\sigma)$, on 1, jos P_σ voidaan muodostaa I:stä parillisella määrällä sarakevaihtoja, -1 muuten. Pätee myös $\mathrm{sgn}(\sigma) = \det(P_\sigma)$. Voidaan myös laskea kaavalla $\mathrm{sgn}(\sigma) = \prod_{i<j} \frac{\sigma(i)-\sigma(j)}{i-j}$.

Similaariset matriisit
similar matrices

Matriisit A ja B ovat similaarisia, jos on olemassa jokin säännöllinen matriisi M siten että $B = M^{-1}AM$. Matriisit ovat similaarisia, jos niiden ominaisarvot ovat samat.

Skalaarikolmitulo
volume of a box

3×3 matriisin A rivit (tai sarakkeet) määrittävät suunnikkaan, jonka tilavuus on $|\det(A)|$.

Spektri
spectrum

Matriisin ominaisarvojen joukko $\{\lambda_1, \ldots, \lambda_n\}$. Arvo $\max|\lambda_i|$ on matriisin spektrisäde.

Symmetrinen hajotelma
symmetric factorization

Hajotelma muotoa $A = LDL^T$ tai $A = QDQ^T$ (L alakolmiomatriisi ja Q ortogonaalinen). Matriisi D on diagonaalinen ja koostuu matriisin A ominaisarvoista. Matriisin D positiiviset pivot-alkiot ja A:n positiiviset ominaisarvot ovat yhtäsuuret.

Symmetrinen matriisi
symmetric matrix

Matriisi on symmetrinen, jos $A = A^T$.

Standardikanta vektoriavaruudelle $\mathbb{R}^n$
standard basis for $\mathbb{R}^n$

Identiteettimatriisin sarakkeet, eli n-ulotteiset vektorit, joiden ainoa nollasta eroava alkio on 1, muodostavat kannan avaruudelle $\mathbb{R}^n$.

Säännöllinen matriisi, täysiasteinen matriisi
full-rank matrix

Matriisi, jonka säännöllisyysaste on $\min(m, n)$. Neliömatriisi, jolla on käänteismatriisi. Matriisi, jonka sarakkeet (tai rivit) ovat lineaarisesti riippumattomia.

Takaisinsijoitus.
back-substitution

Kun yhtälöryhmä on saatettu yläkolmiomuotoon, voidaan ratkaisu selvittää muuttuja kerrallaan "alhaalta ylös", muuttujasta x_n muuttujaan x_1.

Transpoosi
transpose

Matriisin "peilaaminen" sen lävistäjän suhteen. Pätee $(A^T)_{ij} = A_{ji}$.

Täydellinen ratkaisu.
complete solution

Yhtälöryhmän kaikkien ratkaisujen ilmaiseminen muodossa $x = x_p + x_n$, missä x_p on yksittäisratkaisu ja x_n toteuttaa yhtälöryhmän $Ax_n = 0$ (eli $x_n \in N(A)$).

Täydennetty matriisi.
augmented matrix

Yhtälöryhmä $Ax = b$ ilmaistuna muodossa $[Ab]$, missä matriisia A on täydennetty sarakkeella b.

Täysi sarakeaste, täysi riviaste
full column rank, full row rank

Matriisin kaikki sarakkeet (tai rivit) ovat lineaarisesti riippumattomia. Vastaavasti matriisin nolla-avaruus on triviaali $N(A) = \emptyset$ ja sen kuva-avaruuden ulottuvuus on matriisin sarakkeiden lukumäärä.

Ulkotulo
outer product

Vektorioperaatio kahden pystyvektorin välillä, merkitään uv^T. Jos $u \in \mathbb{R}^m$ ja $v \in \mathbb{R}^n$, tuloksena on $m \times n$ matriisi jonka rangi on yksi. Lasketaan $(uv^T)_{ij} = u_i v_j$.

Unitaarinen matriisi
unitary matrix

Matriisi U on unitaarinen jos $U^*U = I$. Toisinsanottuna, matriisin U konjugaattitranspoosi on myös sen käänteismatriisi.

Vaihdannaisuus
commutativity

Jos matriiseille A ja B pätee $AB = BA$, sanotaan että matriisit kommutoivat keskenään. Ei yleensä päde matriisitulolle. Jos matriisit lisäksi diagonalisoituvia, niiden ominaisvektorit ovat samat.

Vandermonde-matriisi
Vandermonde matrix

Matriisi V, jolle $Vc = b$ määrittelee polynomin $p(x) = c_0 + \cdots + c_{n-1}x^{n-1}$ jolle $p(x_i) = b_i$. Määritellään $V_{ij} = (x_i)^{j-1}$. Matriisin V determinantti on $\prod_{j>i}(x_j - x_i)$.

Vapaa muuttuja
free variable

Muuttuja x_i on vapaa, jos eliminaatiossa sarakkeella i ei ole pivot-alkiota. Yhtälöryhmä ratkeaa millä tahansa vapaiden muuttujien x_i arvoilla, ja loput muuttujat voidaan ratkaista niiden suhteen (jos ratkaisu on olemassa).

Vapaat sarakkeet
free columns

Sarakkeet joilla ei ole pivot-alkiota eliminaatiossa.

Vektori avaruudessa $\mathbb{R}^n$
vector in $\mathbb{R}^n$

Vektori avaruudessa $\mathbb{R}^n$ on n reaaliluvun sekvenssi $(x_1, \ldots, x_n)$.

Vektoriavaruuden kanta
basis of a vector space

Joukko lineaarisesti riippumattomia vektoreita, joiden lineaariyhdistelyinä voidaan esittää mikä tahansa avaruuden vektori. Vektoriavaruudella voi olla monta erilaista kantaa, mutta niiden koko on aina sama (ks. dimensio).

Vektoriavaruuden virittävä joukko
spanning set of a vector space

Vektorit $v_1, \ldots, v_k$ virittävät vektoriavaruuden V, jos kaikki vektorit V:ssä voidaan muodostaa niiden lineaariyhdistelyinä. Huom! Virittävä joukko ei ole välttämättä kanta; vektorit saavat olla lineaarisesti riippuvia. Siispä avaruuden V dimensiota ei voida laskea virittävän joukon koosta.

Vektoriavaruuksien summa, suora summa
direct sum

Vektoriavaruus $V + W$, joka koostuu vektoreista $v + w$. Jos V:n ja W:n ainoa yhteinen alkio on 0, niin $V + W$:tä kutsutaan myös suoraksi summaksi. Tällöin $\dim(V + W) = \dim V + \dim W$.

Vektorien yhteenlasku
vector sum

Kahden vektorin alkiottainen summa. Vektorien on oltava saman kokoiset. $(v + w)_i = v_i + w_i$.

Vinosymmetrinen matriisi
skew-symmteric matrix

Matriisi on vinosymmetrinen jos $A^T = -A$. Matriisilla A ei tällöin ole reaalisia ominaisarvoja, vaan kaikki ovat imaginäärisiä. Ominaisvektorit ovat ortogonaalisia, ja e^{Kt} on ortogonaalinen matriisi.

Yksittäisratkaisu
particular solution

Mikä tahansa yksittäinen ratkaisu yhtälöryhmälle $Ax = b$. Jos yhtälöryhmällä ei ole vapaita muuttujia, yksittäisratkaisu on myös ainoa ratkaisu.